এক্সপার্ট সিস্টেম ও মেশিন লার্নিং

জ্ঞান ভিত্তিক · উপসংহান যন্ত্র · ফরওয়ার্ড ও ব্যাকওয়ার্ড চেইনিং · DENDRAL, MYCIN, XCON · ওভারফিটিং ও বৈষম্য–পরিবর্তন্যা: ১২ পাতায়



↑ পুরো টপিক এক পাতায়: লাল = বেশি আসে, সবুজ = যে IF–THEN নিয়মের ওপর সব নির্ভর করে

সিলেবাসের যে অংশ

কৃত্রিম বুদ্ধিমত্তার সিলেবাসে আছে "**এক্সপার্ট সিস্টেমের পরিচিতি**" এবং "**মেশিন লার্নিংয়ের পরিচিতি; শেখার অ্যালগরিদম: সুপারভাইজড ও ক্লাস্টারিং (আনসুপারভাইজড)**"। এই নোটবুক ঠিক ওই দুটি লাইন নেয়। সার্চ, প্রোব্যাবিলিস্টিক যুক্তি ও NLP এই অধ্যায়ের পাশের লেসন; রিগ্রেশন ও ব্যবহারিক প্রয়োগ পরের লেসন।

হাই-ইল্ড তালিকা

① KB + IE + UI + EF
② match → fire → update → test
③ ফরওয়ার্ড: তথ্য ঠেলে দেয়
④ ব্যাকওয়ার্ড: লক্ষ্য টেনে আনে
⑤ DENDRAL, MYCIN, XCON
⑥ লেবেল থাকলে সুপারভাইজড
⑦ ৬০ / ২০ / ২০ বিভাজন
⑧ ওভারফিটিং = বেশি মনে রাখা

সংকেত: **হলুদ** = মূল শব্দ · **লাল বৃত্ত** = অবশ্যই মুখস্থ · **বেগুনি বক্স** = মনে রাখার কৌশল · **লাল বক্স** = পরীক্ষার ফাঁদ · **সবুজ** = সমাধানকৃত উদাহরণ

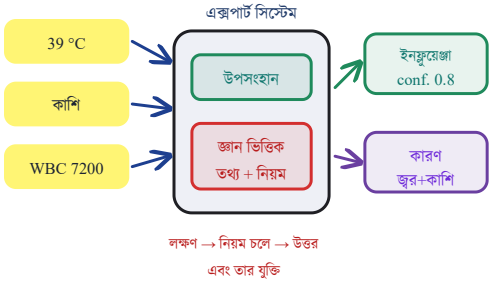
সূচিপত্র

✓ এক্সপার্ট সিস্টেম কী … পৃ. ২
✓ এক্সপার্ট সিস্টেমের আর্কিটেকচার … পৃ. ৩
✓ নিয়ম, চক্র ও চেইনিং … পৃ. ৪
✓ DENDRAL, MYCIN, XCON … পৃ. ৫
✓ মেশিন লার্নিং ও তিন প্যারাডাইম … পৃ. ৬
✓ সুপারভাইজড লার্নিং … পৃ. ৭
✓ বিভাজন ও ওভারফিটিং … পৃ. ৮
✓ মডেলের মূল্যায়ন … পৃ. ৯
✓ ট্রি · k-NN · নেইভ বেয়েস … পৃ. ১০
✓ রাতের পাতা পৃ. ১১ · অনুশীলন পৃ. ১২

১ এক্সপার্ট সিস্টেম কী?

সংজ্ঞা: একটি **এক্সপার্ট সিস্টেম (expert system)** হলো এমন প্রোগ্রাম যা একটি সরু **ডোমেইনের** মধ্যে মানব বিশেষজ্ঞের যুক্তির পদ্ধতি অনুকরণ করে। এটি ওই ডোমেইনের তথ্য ও নিয়ম সংরক্ষণ করে, সেগুলোর ওপর যুক্তি চালিয়ে পরামর্শ, নির্ণয় বা সুপারিশ দেয়, এবং — সবচেয়ে জরুরি — **কীভাবে সিদ্ধান্তে পৌঁছাল তা ব্যাখ্যা করে**।

জ্ঞান ভিত্তিক · নিয়ম ভিত্তিক · প্রতীকী



দুটি গুরুত্বপূর্ণ ফলাফল: সিদ্ধান্ত, আর তার পুরো যুক্তি

ডোমেইম এত সরু হতে হবে যে তা **লিখে রাখা যায়**: ব্যাকটিরিয়েমিয়া, কর হিসাব, একটি কম্পিউটার পরিবারের কনফিগারেশন। সহজ হওয়ার দরকার নেই — কঠিন ডোমেইনও চলবে, যদি প্রতিটি বিচার লেখা যায়। যা একটি ডোমেইনকে বাদ দেয় তা কঠিনত্ব নয়, বরং **অব্যক্ত জ্ঞান**: বিশেষজ্ঞ যা না ভেবেই করে ফেলেন।

বৈশিষ্ট্য	কী বোঝায়	উদাহরণ
ডোমেইন-নির্দিষ্ট	শুধু একটি সরু ক্ষেত্র	ব্যাকটিরিয়া সংক্রমণ
নিয়ম ভিত্তিক	IF–THEN উৎপাদন নিয়ম	IF জ্বর > 38 °C THEN ফ্লু
অনিশ্চয়তা	নিশ্চয়তা ফ্যাক্টর, ফাজি লজিক	MYCIN-এর নিশ্চয়তা ফ্যাক্টর
নিজেই ব্যাখ্যা দেয়	যেসব নিয়ম চলল তা দেখায়	"কারণ X ও Y তাই Z"
শেখে না	নিয়ম মানুষ হাতে লেখে	চলাকালে কিছু ফিট হয় না

মনে রাখার কৌশল: চারটি ক্রিয়া, চারটি অংশ: এটি যা **জানে** তা **সংরক্ষণ** করে, যা **বের করে** আনে, **কেন** বলে দেয়, এবং বাকিটা **আপনাকে জিজ্ঞেস** করে।

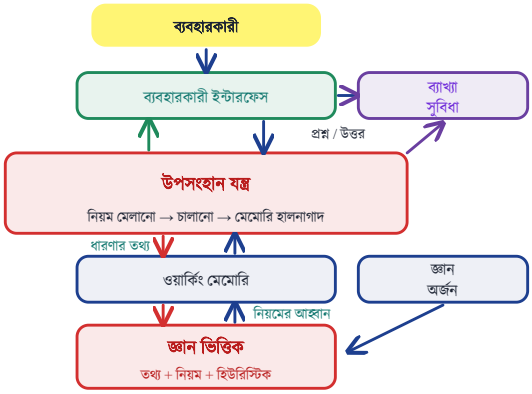
পরীক্ষার ফাঁদ: এটি **শেখা ব্যবস্থা নয়** — চলাকালে ডেটা থেকে কিছু শেখে না। এটি **সাধারণ-উদ্দেশ্যনিরপেক্ষও নয়**: সরু ডোমেইনই এর নকশা।

সমাধানকৃত উদাহরণ ✍️ একটি নিয়ম-ভিত্তিক, তিন ধাপ: **R1** IF তাপমাত্রা > 38 °C AND কাশি AND শ্বেত কোষ > 6000 THEN ইনফ্লুয়েঞ্জা (0.8) · **R2** IF ইনফ্লুয়েঞ্জা AND শ্বাসকষ্ট THEN নিউমোনিয়া (0.9) · **R3** IF তাপমাত্রা > 38 °C AND ফুসফুসরুচ্ছি AND কাশি নেই THEN বসাম (0.7)।
সংলাপ শেষে ওয়ার্কিং মেমোরি: তাপমাত্রা 39, কাশি আছে, শ্বেত কোষ 7200, শ্বাসকষ্ট আছে। চক্র ১: শুধু R1 মিলছে → চালাও → *ইনফ্লুয়েঞ্জা 0.8* যোগ। চক্র ২: এখন R2 মিলছে → চালাও → *নিউমোনিয়া 0.9* যোগ। চক্র ৩: R3 মিলছে না। ফলাফল: **নিউমোনিয়া**, ব্যাখ্যা — "ইনফ্লুয়েঞ্জা, জ্বর, কাশি ও বর্ধিত শ্বেত কোষ থেকে, সঙ্গে শ্বাসকষ্ট"। প্রতি চক্রে একটি নিয়ম — পুরো এক্সপার্ট-সিস্টেম যুক্তি এটুকুই।

আইটি সংযোগ: আজকাল প্রতিটি ঋণ-যাচাই নিয়ম, কর-হার ও প্রতারণা-নিয়ম আসলে একটি ক্ষুদ্র এক্সপার্ট সিস্টেম: নিয়মের দোকান, সেগুলো মেলানো যন্ত্র, সিদ্ধান্তের লগ — একে বলে **পলিসি ইঞ্জিন**। ১৯৮০-এর সিস্টেম থেকে পার্থক্য একটাই: নিয়মগুলো ইন্টারভিউ করে নয়, কনফিগারেশন করে বসানো হয়।

২ এক্সপার্ট সিস্টেমের আর্কিটেকচার

সংজ্ঞা: **জ্ঞান ভিত্তিক (knowledge base)** ডোমেইনের তথ্য, নিয়ম ও হিউরিস্টিক সংরক্ষণ করে। **উপসংহান যন্ত্র (inference engine)** জানা তথ্যের সঙ্গে নিয়ম মেলায় ও মিলে যাওয়া নিয়মগুলো চালায়। **ওয়ার্কিং মেমোরি** ধারণা মাত্রের তথ্য রাখে। **ব্যবহারকারী ইন্টারফেস** হলো সংলাপ। **ব্যাখ্যা সুবিধা** যুক্তি ছাপে।



প্রতিটি এক্সপার্ট সিস্টেমের পাঁচটি বাক্স, আর পেছনে ষষ্ঠটি

অংশ	কাজ	এটি কোন প্রশ্নের উত্তর দেয়
জ্ঞান ভিত্তিক	তথ্য + নিয়ম + হিউরিস্টিক	"কী জানা আছে?"
উপসংহান যন্ত্র	মেলায়, চালায়, হালনাগাদ করে	"তা থেকে কী বেরোয়?"
ওয়ার্কিং মেমোরি	এই ধারণার তথ্য	"এখন আমরা কী জানি?"
ব্যবহারকারী ইন্টারফেস	প্রশ্ন করে, উত্তর নেয়	"আপনার কী দরকার?"
ব্যাখ্যা সুবিধা	চলা নিয়মগুলোর ছায়া লেখে	"কেন এটি বললেন?"
জ্ঞান অর্জন	নতুন নিয়ম সংগ্রহ ও যোগ	"নিয়ম কীভাবে আসে?"

মনে রাখার কৌশল: চারটি প্রশ্ন এই ক্রমে ভাবো — **কী** জানা (জ্ঞান ভিত্তিক), তাহলে **কী** বেরোয় (উপসংহান যন্ত্র), **কেন** (ব্যাখ্যা), আর **আর কী** দরকার (ইন্টারফেস)।

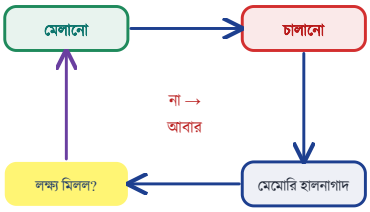
পরীক্ষার ফাঁদ: উপসংহান যন্ত্র **নিয়ম সংরক্ষণ করে না** — জ্ঞান ভিত্তিক করে; যন্ত্র শুধু মেলায় ও চালায়। ব্যাখ্যা সুবিধা **ব্যবহারকারী ইন্টারফেস নয়**।

সমাধানকৃত উদাহরণ ✍️ কোন অংশ কোন প্রশ্নের উত্তর দেয়?: (ক) "এই বুকে ব্যথা হার্ট অ্যাটাকি কি?" — প্রশ্ন করে **ব্যবহারকারী ইন্টারফেস**, সিদ্ধান্ত নেয় **উপসংহান যন্ত্র**। (খ) "কেন বললেন?" — **ব্যাখ্যা সুবিধা**। (গ) "ওজন কত?" — ইন্টারফেস, উত্তর যায় **ওয়ার্কিং মেমোরিতে**। (ঘ) "নিয়ম ১ ও ৪ দুটোই মিলছে — কোনটি চলবে?" — যন্ত্রের ভেতরে দ্বন্দ্ব সমাধান।

আইটি সংযোগ: একই পাঁচটি বাক্স প্রতিটি কনফিগারেশন-চালিত সিস্টেমে ফিরে আসে: রাউটারের অ্যাক্সেস-লিস্ট ম্যাচার, কর ইঞ্জিন, স্প্যাম নিয়ম তালিকা — শুধু ব্যাখ্যা সুবিধার জায়গায় এখন অডিট লগ।

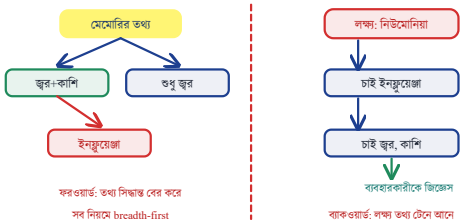
৩ নিয়ম, উপসংহান চক্র ও দুই চেইনিং

সংজ্ঞা: একটি উৎপাদন নিয়ম লেখা হয় **IF <অগ্রপতাক> THEN <পরপতাক>**; অগ্রপতাক হলো ওয়ার্কিং মেমোরির তথ্যের ওপর রাখা শর্তের সংযোগ। **উপসংহান চক্র** হলো **match → fire → update → test**: প্রতিটি নিয়ম ওয়ার্কিং মেমোরির সঙ্গে মেলাও, মিলে যাওয়া নিয়মগুলো **চালাও**, প্রতিটি সিদ্ধান্ত মেমোরিতে লিখে ফেলো, তারপর লক্ষ্য যাচাই করো।



চক্রের এক টার্ন

নিয়মের অংশ	উদাহরণ
অগ্রপতাক (IF)	তাপমাত্রা > 38 °C
সংযোকার শব্দ	AND / OR / NOT
পরপতাক (THEN)	ইনফ্লুয়েঞ্জা, CF 0.8
নিশ্চয়তা ফ্যাক্টর	MYCIN: −1 … +1
চালানো (firing)	THEN অংশ মেমোরিতে লেখা



একই নিয়ম-ভিত্তিক, দুই দিকে যাত্রা

বৈশিষ্ট্য	ফরওয়ার্ড চেইনিং — তথ্যনির্ভর	ব্যাকওয়ার্ড চেইনিং — লক্ষ্যনির্ভর
শুরু হয়	ওয়ার্কিং মেমোরির তথ্য থেকে	একটি লক্ষ্য বা অনুমান থেকে
অনুসন্ধানের ধরন	breadth-first, নিম্নমুখী	depth-first, উর্ধ্বমুখী
উত্তর দেয়	"আর কী বের করা যায়?"	"এই লক্ষ্য কি প্রমাণযোগ্য?"
সেরা ব্যবহার	পর্যবেক্ষণ, পূর্বানুমান	নির্ণয়, পরিকল্পনা
দুর্বলতা	প্রতিটি নিয়ম দেখে	লক্ষ্যের নিয়ম নেই
ধারণাগত ব্যবহারকারী	XCON (কনফিগারেশন)	MYCIN (নির্ণয়)

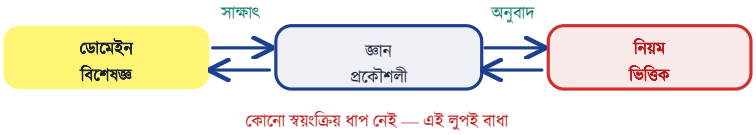
মনে রাখার কৌশল: **"দুধ এখানে আছে, তাই দুধ নষ্ট"** — এটা ফরওয়ার্ড। **"দুধ কি নষ্ট? তাহলে তারিখ দেখো"** — এটা ব্যাকওয়ার্ড। তথ্য সিদ্ধান্ত বের করে; লক্ষ্য তথ্য টেনে আনে।

পরীক্ষার ফাঁদ: ফরওয়ার্ড চেইনিং **কখনো নেতিবাচক প্রমাণ করতে পারে না**: "ফুসকুরুচ্ছি নেই" লিখে কোনো নিয়ম চলে না, তাই "বসাম নয়" কখনোই বেরোয় না।

সমাধানকৃত উদাহরণ ✍️ পৃষ্ঠা ২-এর নিয়মে দুইভাবে চাল: তথ্য: তাপমাত্রা 39, কাশি আছে, শ্বেত কোষ 7200, শ্বাসকষ্ট আছে। **ফরওয়ার্ড:** চক্র ১ R1 চালায় → *ইনফ্লুয়েঞ্জা 0.8*; চক্র ২ R2 চালায় → *নিউমোনিয়া 0.9*; চক্র ৩ R3 মেলে না। ফল: নিউমোনিয়া। **ব্যাকওয়ার্ড:** লক্ষ্য = নিউমোনিয়া → এটির পরপতাক একমাত্র R2 → তার চাই ইনফ্লুয়েঞ্জা → তার পরপতাক একমাত্র R1 → তার চাই তাপমাত্রা, কাশি, শ্বেত কোষ → **ব্যবহারকারীকে তিনটি প্রশ্ন**, সব "হ্যাঁ" → R1 প্রমাণ → R2 সত্য।

৪ ধর্মীয় সিস্টেম ও জ্ঞান-অর্জনের বাধা

সংজ্ঞা: **জ্ঞান অর্জনের বাধা (knowledge-acquisition bottleneck)** যেকোনো এক্সপার্ট সিস্টেমের কঠিন অংশ: বিশেষজ্ঞের জ্ঞান অব্যক্ত, মৌখিক ও প্রসঙ্গহীন; তাকে সুস্পষ্ট নিয়মে বদলাতে লাগে অনেক সাক্ষাৎ, কয়েক মাসের কাজ ও অসংখ্য যাচাই। শৃঙ্খলাটি চলে **ডোমেইন বিশেষজ্ঞ ⇄ জ্ঞান প্রকৌশলী ⇄ নিয়ম ভিত্তিক**; এর কোনো অংশই নিজে থেকে শেখে না।



প্রতিটি নিয়ম এই লুপ দিয়ে হাতে গেছে

সিস্টেম	ডোমেইন, যুক্তি ও সময়	সীমাবদ্ধতা / পরিণতি
DENDRAL ১৯৬৫–১৯৭২	রসায়ন — মাস স্পেকট্রাম থেকে অণুর গঠন বের করে, অণুকে উপগঠনে ভেঙে নিয়ম দিয়ে	প্রথম এক্সপার্ট সিস্টেম; রাসায়নিকের মিনিটের বদলে ঘণ্টা কম্পিউটার সময়
MYCIN ১৯৬০–৭০ EMYCIN ১৯৭৭	চিকিৎসা — ব্যাকটিরিয়েমিয়া নির্ণয় ও চিকিৎসা, ≈ ৬০০ নিয়ম, ব্যাকওয়ার্ড চেইনিং ও নিশ্চয়তা ফ্যাক্টর; EMYCIN হলো একই যন্ত্র, নিয়ম ছাড়া	অন্ধ পরীক্ষায় ≈ ৬৫ % সঠিক, যাচাইকারী চিকিৎসকদের চেয়েও বেশি; রুটিন চিকিৎসায় ঢোকেনি — তবে EMYCIN প্রমাণ করে যন্ত্রটি পুনর্ব্যবহারযোগ্য
XCON (R1) ১৯৮০	DEC — গ্রাহকের অর্ডার থেকে VAX-11/780 কনফিগার করে, ফরওয়ার্ড চেইনিং; পরীক্ষা ১৯৭৮–৮০	এক কোম্পানির এক পণ্য; বছরে কোটি কোটি ডলার বাঁচানোর কথা বলা হয়

সমাধানকৃত উদাহরণ ✍️ MYCIN নিয়ে ভাইভা: প্রশ্ন। হাসপাতালে MYCIN কেন চালু হয়নি? **উত্তর।** কারণ তার বাধা ও সামাজিক কারণ, তুলনীয়তা নয়: নিয়ম-ভিত্তিক হাতে সাক্ষাৎ করে তৈরি হয়েছিল, সংক্রামক রোগের বাইরে এটি কিছু জানত না, আর দায়, নৈতিকতা ও রোগীর সম্মতি একটি চিকিৎসা-প্রস্তাব দেওয়া যন্ত্রকে আটকে দিয়েছিল।

সীমাবদ্ধতা	কী মানে
জ্ঞান অর্জন	ধীর, দামি, হাতে নিয়ম
সরু ডোমেইন	বাইরে গেলে উত্তর নেই
ভঙ্গুরতা	ধীরে ভাঙে না, হঠাৎ ভাঙে
শেখে না	নতুন তথ্য = নতুন সাক্ষাৎ
বিশ্বজ্ঞতা নেই	পৃথিবীর কোনো মডেলই নেই

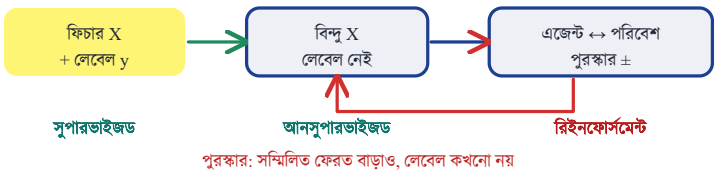
পরীক্ষার ফাঁদ: DENDRAL ছিল **রসায়ন**-বিষয়ক, চিকিৎসার নয়। MYCIN রোগীর রেকর্ড থেকে **শেখেনি** — তার ≈ ৬০০ নিয়ম মানুষ লিখেছিল।

মনে রাখার কৌশল: "**D**ENDRAL মানে গঠন, **M**YCIN মানে লক্ষণ, XCON মানে কন**ফিগারেশন**" — রসায়ন, চিকিৎসা, হার্ডওয়্যার। আজ তিনটিই নিষ্ক্রিয় কোড: এক্সপার্ট সিস্টেম শেষ করেছে বাধা, সিলিকন নয়।

৫ মেশিন লার্নিং ও তিন প্যারাডাইম

সংজ্ঞা: **মেশিন লার্নিং (machine learning)** হলো সেই AI-এর শাখা যেখানে সিস্টেম কোনো নিয়ম হাতে লেখার বদলে **ডেটার** ওপর কাজ করে নিজের কর্মক্ষমতা বাড়ায়। স্যামুয়েল শব্দটি ব্যবহার করেন **১৯৫৯**-এ; মিচেলের প্রামাণিক সংজ্ঞা: অভিজ্ঞতা **E**, কাজ **T** ও মাপ **P** নিয়ে একটি প্রোগ্রাম শেখে বলা হয় যদি **T**-তে তার মাপা কর্মক্ষমতা **E**-র সঙ্গে বাড়ে।

পরিভাষা	অর্থ	পরিভাষা	অর্থ
ডেটা / উদাহরণ	একটি তথ্য-সারি	মডেল	শেখা ফাংশন $f : X \to y$
ফিচার (X)	একটি ইনপুট বৈশিষ্ট্য	প্যারামিটার	ফিট যে সংখ্যা বদলায়
লেবেল (y)	যে উত্তর চাই	হাইপার-প্যারামিটার	আপনি যে সেটিং ঠিক করেন
প্রশিক্ষণ	প্যারামিটার ফিট করা	পূর্বানুমান	ফ্রোজেন মডেল চালানো
ক্ষতি ফাংশন	ফিটের সময় ছোট হয়	এপক	প্রশিক্ষণের এক চক্র



ফিডব্যাক পাওয়ার তিন রকম — লেবেল, লেবেলের অনুপস্থিতি, বা পরে একটি সংখ্যা

বিষয়	সুপারভাইজড	আনসুপারভাইজড	রিইনফোর্সমেন্ট
ডেটা	লেবেলসহ (X, y)	লেবেলবিহীন X	কাজের পর পুরস্কার
লক্ষ্য	জানা উত্তর পূর্বানুমান	গঠন আবিষ্কার	পুরস্কার বাড়ানো
কাজ	ক্লাসিফিকেশন, রিগ্রেশন	ক্লাস্টারিং, PCA	নিয়ন্ত্রণ, গেম, চলাচল
অ্যালগরিদম	ট্রি, k-NN, নেইভ বেয়েস, SVM	k-মিনস, PCA, DBSCAN	Q-লার্নিং, পলিসি গ্রেডিয়েন্ট
উদাহরণ	স্প্যাম ফিল্টার, ক্রেডিট স্কোর	বাজার বিভাজন	হাঁটতে শেখা রোবট

মনে রাখার কৌশল: **"লেবেল থাকলে পূর্বানুমান বেরোয়, লেবেল না থাকলে গ্রুপ বেরোয়, পরে সংখ্যা এলে আচরণ বেরোয়।"** যেকোনো অ্যালগরিদমের ক্ষেত্রে একটিই প্রশ্ন: *ফিডব্যাক কোথা থেকে আসে?*

সমাধানকৃত উদাহরণ ✍️ কোন প্যারাডাইম?: (ক) বাড়ির দাম পূর্বানুমান → **রিগ্রেশন, সুপারভাইজড**; (খ) ইমেইল স্প্যাম নয় স্প্যাম → **ক্লাসিফিকেশন, সুপারভাইজড**; (গ) ১০ লক্ষ ক্রেতাকে ভাগ করা → **ক্লাস্টারিং, আনসুপারভাইজড**; (ঘ) ৯০০ টি কলাম থেকে ২০ → **মাত্রা হ্রাস**; (ঙ) রোবট প্রতি ধাপে পুরস্কার পেয়ে হাঁটে শেখে → **রিইনফোর্সমেন্ট**।

পরীক্ষার ফাঁদ: ML হলো AI-এর একটি **উপসেট**; যে এক্সপার্ট সিস্টেম কখনো শেখে না সেটাও AI। ক্লাস্টার নামানোর পরেও k-মিনস আনসুপারভাইজড থাকে।

৬ সুপারভাইজড লার্নিং ও শেখার প্রক্রিয়া

সংজ্ঞা: সুপারভাইজড লার্নিং লেবেলসহ উদাহরণ (X, y) থেকে $\mathbf{f : X \to y}$ মানচিত্র বানায়। **ক্লাসিফিকেশন (classification)** **বিচ্ছিন্ন** লেবেল আউটপুট করে — স্প্যাম/স্প্যাম নয়, রোগ ক/খ/গ; **রিগ্রেশন (regression)** **ধারাবাহিক** সংখ্যা — দাম, বৃষ্টিপাত, চাহিদা। লেবেল কেবল প্রশিক্ষণের সময়ই জানা থাকে।

বিষয়	ক্লাসিফিকেশন	রিগ্রেশন
আউটপুট	সীমিত সেট থেকে একটি শ্রেণি	একটি বাস্তব সংখ্যা
উদাহরণ	স্প্যাম ফিল্টার, টিউমারের ধরন	বাড়ির দাম, বৃষ্টিপাত, চাহিদা
ত্রুটির মাপ	accuracy, precision, recall, F1	MAE, MSE, RMSE, R^2
সাধারণ লস	ক্রস-এনট্রপি	বর্গ ত্রুটি
সাধারণ মডেল	ট্রি, k-NN, নেইভ বেয়েস, SVM	লিনিয়ার রিগ্রেশন, ট্রি রিগ্রেশন
প্রশ্নের উত্তর	"কোনটি?"	"কত?"



যে লুপ সবাই ভুলে যায়: ৭ → ৫

আট ধাপ — দুটিই সবাই ভুলে যায়:

1. **সংগ্রহ** লেবেলসহ ডেটা — বেশির ভাগ কাজ
2. **প্রি-প্রসেসিং** — মিসিং ভ্যালু, ডুপ্লিকেট
3. **ফিচার ইঞ্জিনিয়ারিং** — সংকেত রাখো
4. **বিভাজন** — গুলিয়ে দিয়ে **60 / 20 / 20**
5. **মডেল বাছাই** — সহজ দিয়ে শুরু
6. **প্রশিক্ষণ** — শুধু প্রশিক্ষণে ফিট
7. **মূল্যায়ন** — k-fold CV ভালো
8. **ডিপ্লয় ও পর্যবেক্ষণ** — ডেটা বদলায়

সমাধানকৃত উদাহরণ ✍️ সম্পূর্ণ এক চাল: ১০০০ লেবেলসহ ইমেইল, ১২ ফিচার। বিভাজন **৬০০ / ২০০ / ২০০**। গভীরতা ৩-এর ট্রি: **প্রশিক্ষণে ৯৬ %, ভ্যালিডেশনে ৮৪ %**; গভীরতা ১২-এর ট্রি: **১০০ % বনাম ৭৯ %** — ময়লা মুখস্থ, তাই গভীরতা ৩ই রাখো। পরীক্ষা সেট **একবার** খোলো: ৮৫ %। কখনো ৯৬ % লেখো না।

মনে রাখার কৌশল: "**সংগ্রহ, পরিষ্কার, ফিচার, বিভাজন, ফিট, মূল্যায়ন, ডিপ্লয়**।" যে দুটি ধাপ সবাই ভুলে যায় তা হলো **বিভাজন** আর **পর্যবেক্ষণ**।

পরীক্ষার ফাঁদ: **পরীক্ষা সেটের ওপর কখনো টিউনিং হয় না।** বিভাজনের পরে স্কেলিং করলে পরীক্ষার তথ্য ফাঁসে। বেশি ট্রি মানে ভালো নয়: সংকেতের বাইরে গভীরতা মানে ওভারফিটিং।

আইটি সংযোগ: বাস্তব প্রকল্পের বেশির ভাগ সময় ধাপ ১–৩-এ যায়। মডেল এক লাইনের বস্তু; পরিষ্কার লেবেলসহ ডেটাসেট ও ন্যায্য বিভাজনই আসল সম্পদ।

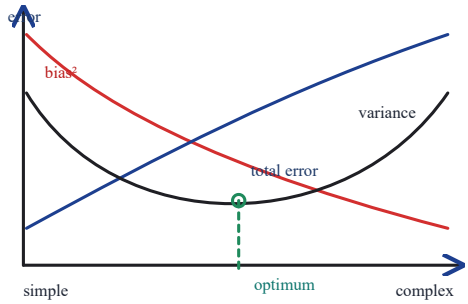
৭ বিভাজন, ওভারফিটিং ও বৈষম্য–পরিবর্তন্যা

সংজ্ঞা: ডেটা ভাগ করো: ফিট করতে **প্রশিক্ষণ**, মডেল ও তার সেটিং বাছতে **ভ্যালিডেশন**, আর শেষ ফল একবার জানাতে **পরীক্ষা** সেট। প্রচলিত ভাগ **৬০ / ২০ / ২০**; **k-fold ক্রস-ভ্যালিডেশন** ($k = ৫$ বা ১০) ভাগটি k বার করে যাতে একটি ভাগ্যক্রমে ভাগ উত্তর না ঠিক করে।

সেট	ভাগ	কী কাজে	কী কাজে নয়
প্রশিক্ষণ	৬০ %	প্যারামিটার ফিট করা	মডেলের নম্বর দেওয়া
ভ্যালিডেশন	২০ %	মডেল ও হাইপার-প্যারামিটার বাছা	প্যারামিটার ফিট করা
পরীক্ষা	২০ %	একমাত্র চূড়ান্ত রিপোর্ট	কোনো সিদ্ধান্ত নয়

মডেলের জটিলতা	প্রশিক্ষণ ত্রুটি	ভ্যালিডেশন ত্রুটি	রায়
১ ফিচার, রেখীয়	১৪ %	১৫ %	আন্ডারফিটিং — বেশি বৈষম্য
গভীরতা ৩-এর ট্রি	৪ %	৬ %	ঠিক আছে — সেরা পছন্দ
গভীরতা ২০ + ময়লা	0.5 %	২২ %	ওভারফিটিং — বেশি পরিবর্তন্যা

আন্ডারফিটিং ও ওভারফিটিং: **ওভারফিটিং (overfitting)**: মডেল প্রশিক্ষণের তথ্য এত কাছ থেকে মানিয়ে নেয় যে তার ময়লা মুখস্থ করে ফেলে — **প্রশিক্ষণ-ত্রুটি** << **পরীক্ষা-ত্রুটি**, বেশি পরিবর্তন্যা, সাধারণীকরণ নেই। **আন্ডারফিটিং (underfitting)**: মডেল এত সহজ যে গঠন ধরতে পারে না — **দুটো ত্রুটিই বেশি**, বেশি বৈষম্য। যুক্ত ত্রুটি = **বৈষম্য²** + **পরিবর্তন্যা** + **অপরিহার্য নয়স**।



মোট ত্রুটি = বৈষম্য² + পরিবর্তন্যা + নয়স

সমাধানকৃত উদাহরণ ✍️ দুই মডেলের তুলনা: মডেল ক: বৈষম্য² = 0.09, পরিবর্তন্যা = 0.02, নয়স = 0.01 → মোট **0.12**। মডেল খ: বৈষম্য² = 0.01, পরিবর্তন্যা = 0.16, নয়স = 0.01 → মোট **0.18**। ক জেতে — খ ময়লা মুখস্থ করেছে। বেশি ডেটা খ-এর **পরিবর্তন্যা** কমায়, **বৈষম্য** কমায় না।

পরীক্ষার ফাঁদ: **প্রশিক্ষণে ৯৯ % সঠিক মানে সফলতা নয়** — উত্তর মুখস্থ করা কার্ডও ১০০ % পায়। বেশি ডেটা শুধু **পরিবর্তন্যা** কমায়; **বৈষম্য** কমাতে হলে বেশি সক্ষম মডেল লাগে।

ওভারফিটিং কীভাবে কমানো যায়: আরও ও বেশি ডেটা · রেগুলারাইজেশন (L1 / L2) · **k-fold ক্রস-ভ্যালিডেশন** · সহজ মডেল · ডিসিশন ট্রি **প্রুনিং** · **আর্লি স্টপিং** · ড্রপআউট · ফিচার সিলেকশন।

৮ মডেলের মূল্যায়ন: কনফিউশন ম্যাট্রিক্স

সংজ্ঞা: **কনফিউশন ম্যাট্রিক্স** দ্বিবিভাগীয় (binary) কাজে শ্রেণিবিন্যাসকারী আসলে কী করল তা গোনে: ট্রু পজিটিভ, ফলস পজিটিভ, ট্রু নেগেটিভ, ফলস নেগেটিভ। পরীক্ষায় আসা প্রতিটি ক্লাসিফিকেশন মেট্রিক এই চারটি সংখ্যার এক লাইনের হিসাব।

পূর্বানুমান ইতিবাচক	পূর্বানুমান নেতিবাচক	
TP = **45** — ধরা পড়ে, সত্যিই খারাপ	TN = **140** — ছাড়া পড়ে, সত্যিই ভালো	185 ঠিক
FN = **5** — বাদ পড়ে, সত্যিই খারাপ	FP = **10** — ভুলে অভিযোগ	15 ভুল

পাঁচটি সংখ্যা, প্রতিটি এক লাইনে:

নির্ভুলতা = (TP + TN) / সর্বমোট

যথার্থতা (precision) = TP / (TP + FP)

স্মরণযোগ্যতা (recall) = TP / (TP + FN)

নির্দিষ্টতা = TN / (TN + FP)

F1 = 2 · P · R / (P + R)

MAE = $\Sigma|y - \hat{y}| / n$

রিগ্রেশনের জন্য: RMSE = $\sqrt{(\Sigma(y - \hat{y})^2/n)}$ এবং $R^2 = 1 - \Sigma(y - \hat{y})^2 / \Sigma(y - \bar{y})^2$, যা নিখুঁত ফিটে 1 এবং গড়ের চেয়েও খারাপ মডেলে ≤ 0।

সমাধানকৃত উদাহরণ ✍️ প্রতারণা-ফিল্টার, ২০০ টি ঘটনা: TP = 45, FN = 5, TN = 140, FP = 10, মোট 200। নির্ভুলতা = 185/200 = **92.5 %** · যথার্থতা = 45/55 = **81.8 %** · স্মরণযোগ্যতা = 45/50 = **90 %** · নির্দিষ্টতা = 140/150 = **93.3 %** · F1 = 2(0.818)(0.900)/(1.718) = **85.7 %**।

গল্পটা পড়ো: 92.5 % চমৎকার মনে হলেও ফিল্টারটি **৫টি সত্যি প্রতারণা** ছাড়ছে আর **১০জন নির্দোষ গ্রাহককে** অভিযোগ করছে। সীমা বাড়ালে স্মরণযোগ্যতা বাড়ে, যথার্থতা কমে।

পরীক্ষার ফাঁদ: **অসম ভারসাম্যযুক্ত** ডেটায় নির্ভুলতা একমাত্র সংখ্যা হওয়া উচিত নয়: ৯৯ % ঘটনা নেতিবাচক হলে "সবসময় নেতিবাচক বলো" কৌশলেই ৯৯ % পাওয়া যায়, অথচ সেটি অকার্যকর। **স্মরণযোগ্যতা** চিকিৎসক চান, **যথার্থতা** ব্যাংক চায়।

মনে রাখার কৌশল: **"যথার্থতা হলো আমি যাদের অভিযোগ করেছি তাদের কতজন সত্যিই দোষী; স্মরণযোগ্যতা হলো দোষীদের কতজন আমি ধরতে পেরেছি।"** F1 হলো হারমোনিক গড়, তাই দুটোই বেশি না হলে সেটিও বেশি হয় না।

আইটি সংযোগ: এই চারটি সংখ্যাই মডেলের রিপোর্ট কার্ড, আর ROC বক্ররেখা এগুলো থেকেই তৈরি (১ – নির্দিষ্টতার বিপরীতে স্মরণযোগ্যতা)। **সীমা** একটি ব্যবসায়িক সিদ্ধান্ত, মডেলিংয়ের নয়।

৯ হাতে গোনা যায় এমন তিন শিক্ষক

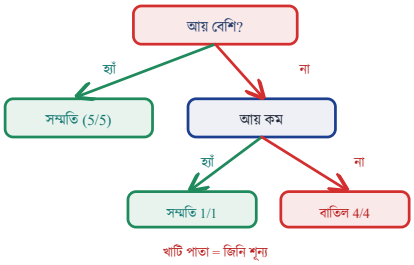
সংজ্ঞা: তিনটি সুপারভাইজড অ্যালগরিদম যেগুলোর হিসাব হাতে করা যায়, কোনো ক্যালকুলাস লাগে না: **ডিসিশন ট্রি** অপবিশুদ্ধতা কমাতে ডেটাকে ভাগ করে, **k-NN** নিকটতম k প্রশিক্ষণ-বিন্দুর উত্তর নকল করে, আর **নেইভ বেয়েস** শ্রেণির শর্তে ফিচারগুলো স্বাধীন ধরে বেয়েসের সূত্র প্রয়োগ করে।

বৈশিষ্ট্য	ডিসিশন ট্রি	k-NN	নেইভ বেয়েস
শেখে কীভাবে	অপবিশুদ্ধতা কমানোর ভাগ	প্রশিক্ষণ তথ্য সংরক্ষণ	প্রতিসংখ্যা গণনা
পূর্বানুমান খরচ	কয়েকটি তুলনা	সব বিন্দুর দূরত্ব	প্রতি ফিচারে এক গুণ
মূল সুইচ	গভীরতা, পাতার আকার	k, দূরত্বের মাপ	লাপ্লাস স্মুদিং
দুর্বলতা	ময়লা টেবিলে ওভারফিট	স্কেলিং লাগে, মাত্রা বেশি	স্বাধীনতার অনুমান
প্রস্তুতি	প্রশ্নের একটি ধারা	কিছু নয় — অলস শিক্ষক	স্কেলিং-মুক্ত

লিখতে পারতে হবে এমন দুটি সূত্র:

অপবিশুদ্ধতা। জিনি $= 1 - \Sigma\, p_i^2$ · এনট্রপি $H = -\Sigma\, p_i \log_2 p_i$। যে ফিচার সবচেয়ে বড় **তথ্য-লাভ (information gain)** দেয় তাতে ভাগ করো: $H(\text{মূল}) - \Sigma\, (n_i/n)\, H(\text{সন্তান})$।

নেইভ বেয়েস। $P(c|x) \propto P(c) \cdot \prod_i P(x_i \mid c)$। শর্তাধীন স্বাধীনতাই এই অনুমান; **লাপ্লাস স্মুদিং** অদেখা মানকে গুণশূন্য করে দেওয়া ঠেকায়।



১০ আবেদক, একটি ট্রি, প্রশিক্ষণে ১০০ %

উদাহরণ ১ ✍ ডিসিশন ট্রি: ১০ আবেদক, ৬ সম্মতি, ৪ বাতিল। মূল জিনি $= 1 - (0.6^2 + 0.4^2) =$ **0.48**। আয়-এ ভাগ: ৫ জন উচ্চ আয় সবাই সম্মতি (জিনি 0), ৫ জন কম আয় ১ সম্মতি ও ৪ বাতিল (জিনি 0.32)। ওজনযুক্ত জিনি = **0.16**। ঐ পাঁচকে ক্রেডিট স্কোর ≥ 700-এ ভাগ করলে জিনি 0। প্রশিক্ষণে 10/10 — অথচ খারাপ স্কোরের উচ্চ-আয় আবেদকও অনুমোদন পেত। এটিই ওভারফিটিং।

উদাহরণ ২ ✍ k-NN: নতুন আবেদকের (আয়, স্কোর) স্থানে তিনটি নিকটতম লেবেলযুক্ত প্রতিবেশী **সম্মতি, সম্মতি, বাতিল**। **k = 3**-এ বেশির ভাগ ভোটে ফল **সম্মতি**। k = 1 হলে নিকটতমটাই নকল করে তার ময়লা নেওয়া হয়; k = 200 হলে পুরো ফাইলের সংখ্যাগরিষ্ঠ শ্রেণিই আসে, অর্থাৎ কিছুই বোঝা যায় না। k-NN একটি **অলস শিক্ষক** — প্রশিক্ষণে কিছু গণনা করে না।

উদাহরণ ৩ ✍ নেইভ বেয়েস, টেনিসের ১৪ দিনের আবহাওয়া: $P(\text{হ্যাঁ}) = 9/14$ এবং $P(\text{না}) = 5/14$। প্রশ্ন: রোদ, গরম, বেশি আর্দ্রতা, জোর বাতাস। হ্যাঁ: $0.643 \times 0.222 \times 0.222 \times 0.333 \times 0.333 =$ **0.0035** · না: $0.357 \times 0.600 \times 0.600 \times 0.800 \times 0.625 =$ **0.0643** ⟹ **খেলা হবে না**, প্রায় ১৮ : ১। স্মুদিং ছাড়া "না" শাখাটি হুবহু 0 হতো।

মনে রাখার কৌশল: ট্রি = **প্রশ্ন করে**। k-NN = **প্রতিবেশীকে জিজ্ঞেস করে**। নেইভ বেয়েস = **সম্ভাবনার গুণফল** — আর শব্দটি *নেইভ* মানেই সতর্কবার্তা যে ফিচারগুলো স্বাধীন ধরা হয়েছে।

পরীক্ষার ফাঁদ: k-NN একটি **সুপারভাইজড** শিক্ষক, আনসুপারভাইজড নয় — লেবেল আছে, শুধু ফিটের সময় ব্যবহার হয় না। এনট্রপি **সম্ভাবনা নয়**; এর মান 0 থেকে 1 বিটের মধ্যে।

পরীক্ষার আগের রাতের পাতা

তথ্য-তালিকা:

KB + IE + UI + EF = এক্সপার্ট সিস্টেম	ওয়ার্কিং মেমোরি = ধারণার তথ্য
match → fire → update → test	দ্বন্দ্ব: নির্দিষ্টতা, নতুনতা
ফরওয়ার্ড = তথ্যনির্ভর, নিম্নমুখী	ব্যাকওয়ার্ড = লক্ষ্যনির্ভর, উর্ধ্বমুখী
DENDRAL ১৯৬৫–৭২, রসায়ন	MYCIN ≈ ৬০০ নিয়ম, ≈ ৬৫ %
EMYCIN ১৯৭৭ · XCON ১৯৮০ থেকে	স্যামুয়েল ১৯৫৯ · মিচেল E-T-P
সুপারভাইজড / আনসুপারভাইজড / RL	ভাগ ৬০ / ২০ / ২০, k-fold CV
ত্রুটি = বৈষম্য² + পরিবর্তন্যা + নয়স	accuracy, precision, recall, F1

MCQ-র জন্য সেরা ১২টি এক-লাইনের তথ্য

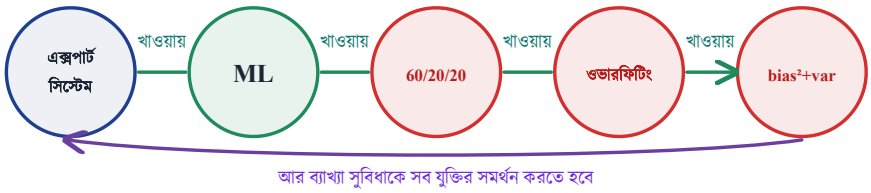
১. যন্ত্র যুক্তি করে, ভিত্তিক জ্ঞান রাখে

৬. যে ES শেখে না সেটাও AI

২. নিয়ম চালানো = THEN অংশ মেমোরিতে লেখা
৩. ফরওয়ার্ড শুরু হয় তথ্য থেকে, লক্ষ্য থেকে নয়
৪. শুধু ব্যাকওয়ার্ডই প্রশ্ন করে
৫. DENDRAL = রসায়ন, MYCIN = চিকিৎসা
৭. সুপারভাইজডে লেবেল লাগে, আনসুপারভাইজডে নয়
৮. পরীক্ষা সেট শেষে একবারই খোলা হয়
৯. ৯৯ % ট্রেন + ৬০ % টেস্ট = ওভারফিটিং
১০. বেশি ডেটা পরিবর্তন্যা কমায়, বৈষম্য নয়
১১. k-NN সুপারভাইজড; নেইভ বেয়েস = স্বাধীনতা

প্রধান ফাঁদ: যন্ত্র নিয়ম সংরক্ষণ করে না · ব্যাখ্যা সুবিধা ইন্টারফেস নয় · ফরওয়ার্ড নেতিবাচক প্রমাণ করতে পারে না · DENDRAL চিকিৎসার সিস্টেম নয় · MYCIN রোগীর রেকর্ড থেকে শেখেনি · XCON সাধারণ-উদ্দেশ্যনিরপেক্ষ নয় · অসম ডেটায় নির্ভুলতা অর্থহীন · যথার্থতা ≠ স্মরণযোগ্যতা · k-NN সুপারভাইজড · এনট্রপি সম্ভাবনা নয়।

সব কৌশল একসাথে: "যা জানে তা রাখে, যা বের হয় তা বের করে, কেন বলে, বাকিটা জিজ্ঞেস করে" · "match, fire, update, test" · "দুধ এখানে আছে তাই নষ্ট" (ফরওয়ার্ড) / "দুধ কি নষ্ট? তারিখ দেখো" (ব্যাকওয়ার্ড) · "D মানে গঠন, M মানে লক্ষণ, X মানে কনফিগারেশন" · "লেবেল থাকলে পূর্বানুমান, না থাকলে গ্রুপ, পরে সংখ্যা এলে আচরণ" · "সংগ্রহ, পরিষ্কার, ফিচার, বিভাজন, ফিট, মূল্যায়ন, ডিপ্লয়" · "প্রশিক্ষণ কম, পরীক্ষা বেশি = ওভারফিটিং" · "যথার্থতা = অভিযোগের সত্যতা, স্মরণযোগ্যতা = ধরার পরিমাণ"।



নিয়ম ঢুকলে চারটি ফল বেরোয় — আর প্রতিটির পেছনে একটি ব্যাখ্যা

✓ অনুশীলন MCQ (পরীক্ষার ধাঁচে, ১০ নম্বর)

১. এক্সপার্ট সিস্টেমের কোন অংশটি নিয়ম প্রয়োগ করে?
ক) জ্ঞান ভিত্তিক খ) উপসংহান যন্ত্র
গ) ব্যাখ্যা সুবিধা ঘ) ব্যবহারকারী ইন্টারফেস

২. MYCIN কোন পদ্ধতিতে যুক্তি করেছিল:
ক) ফরওয়ার্ড খ) k-মিনস
গ) ব্যাকওয়ার্ড ঘ) পুরস্কার-ভিত্তিক

৩. DENDRAL মাস স্পেকট্রাম থেকে বের করে:
ক) অণুর গঠন খ) রোগের নাম
গ) কনফিগারেশন ঘ) বাক্যের অর্থ

৪. ফরওয়ার্ড চেইনিং শুরু হয়:
ক) লক্ষ্য অনুমান থেকে খ) পুরস্কার সংকেত থেকে
গ) প্রশিক্ষণ সেট থেকে ঘ) জানা তথ্য থেকে

৫. সুপারভাইজড লার্নিংয়ের জন্য দরকার:
ক) লেবেলবিহীন ডেটা খ) লেবেলসহ ইনপুট-আউটপুট
গ) প্রতি কাজে পুরস্কার ঘ) হাতে লেখা নিয়ম

৬. ৯৯ % প্রশিক্ষণ, ৬০ % পরীক্ষা মানে:
ক) ওভারফিটিং খ) আন্ডারফিটিং
গ) শুধু বেশি বৈষম্য ঘ) সেরা সমাধান

৭. k-NN, k = 1 হলে পূর্বানুমান করে:
ক) নিকটতমটির শ্রেণি খ) সব লেবেলের গড়
গ) সংখ্যাগরিষ্ঠ শ্রেণি ঘ) এলোমেলো শ্রেণি

৮. শ্রেণি জানা থাকলে নেইভ বেয়েস ধরে নেয়:
ক) ফিচার পৃথকীয় খ) পরীক্ষার বণ্টন
গ) মিসিং তথ্য নেই ঘ) ফিচার স্বাধীন

৯. স্মরণযোগ্যতা সমান:
ক) TP / (TP + FP) খ) TN / (TN + FN)
গ) TP / (TP + FN) ঘ) (TP+TN)/total

১০. ৬০/২০/২০ ভাগের পরীক্ষা সেট কী করে:
ক) প্যারামিটার ফিট করে খ) টিউনিং করে
গ) চূড়ান্ত ফল জানায় ঘ) ফিচার বাছাই করে

উত্তরমালা → ১-খ · ২-গ · ৩-ক · ৪-ঘ · ৫-খ · ৬-ক · ৭-ক · ৮-ঘ · ৯-গ · ১০-গ

লিখিত প্রশ্ন: এক্সপার্ট সিস্টেমের আর্কিটেকচার বিস্তারিত ব্যাখ্যা করো, লেবেলসহ চিত্রসহ। ফরওয়ার্ড ও ব্যাকওয়ার্ড চেইনিং ব্যাখ্যা করো উদাহরণসহ। ওভারফিটিং কী, বৈষম্য–পরিবর্তন্যা ভারসাম্য কীভাবে একে ব্যাখ্যা করে, আর কীভাবে কমানো যায়? ১০ নম্বর

১ **আর্কিটেকচার (৩)। জ্ঞান ভিত্তিক** = ডোমেইনের তথ্য, নিয়ম, হিউরিস্টিক। **উপসংহান যন্ত্র** = ওয়ার্কিং মেমোরির সঙ্গে নিয়ম মেলায়, চালায়, সিদ্ধান্ত ফিরিয়ে দেয়। **ব্যবহারকারী ইন্টারফেস** = প্রশ্ন করে। **ব্যাখ্যা সুবিধা** = কেন বলে ছাপে। চক্র: **match → fire → update → test**। ৩

২ **ফরওয়ার্ড চেইনিং (২)।** তথ্যনির্ভর, নিম্নমুখী: তথ্য থেকে শুরু, অগ্রপতাক মেলে এমন প্রতিটি নিয়ম চালাও, সিদ্ধান্ত যোগ করো, আর কোনো নিয়ম না চলা পর্যন্ত চালিয়ে যাও। Breadth-first; পর্যবেক্ষণ ও পূর্বানুমান; XCON। ২

৩ **ব্যাকওয়ার্ড চেইনিং (২)।** লক্ষ্যনির্ভর, উর্ধ্বমুখী: একটি অনুমান থেকে শুরু, সেটির পরপতাক নিয়মটি খুঁজো, তার শর্তে ঢোকো, যা অনুপস্থিত ব্যবহারকারীকে জিজ্ঞেস করো। Depth-first; নির্ণয়; MYCIN। ২

৪ **ওভারফিটিং ও বৈষম্য–পরিবর্তন্যা (৩)।** মডেল প্রশিক্ষণের তথ্য এত কাছ থেকে মানায় যে ময়লা মুখস্থ করে ফেলে, তাই **প্রশিক্ষণ-ত্রুটি ≪ পরীক্ষা-ত্রুটি** — বেশি পরিবর্তন্যা। যুক্ত ত্রুটি = **বৈষম্য²** + **পরিবর্তন্যা** + **অপরিহার্য নয়স**। প্রতিকার: বেশি ডেটা, রেগুলারাইজেশন, k-fold CV, সহজ মডেল, প্রুনিং, আর্লি স্টপিং, ড্রপআউট। ৩

পরীক্ষার আগে যাচাই ✓

- ✓ চক্রসহ আর্কিটেকচার আঁকতে পারি
- ✓ এক ধাপ ফরওয়ার্ড চক্র করতে পারি
- ✓ DENDRAL, MYCIN, XCON সালসহ বলতে পারি
- ✓ accuracy, recall ও F1 হিসাব করতে পারি