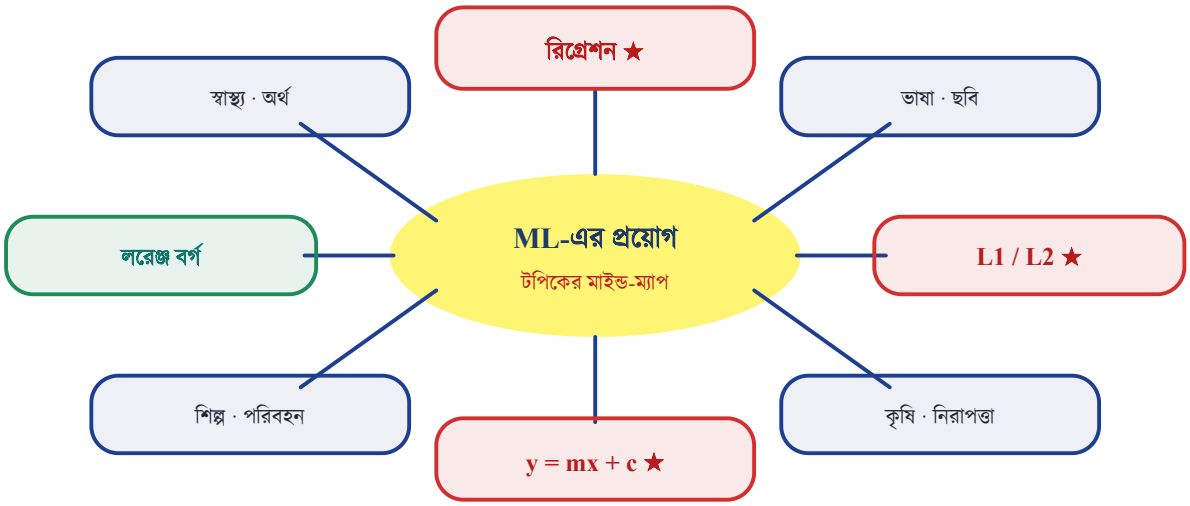
ব্যবহারিক ML অ্যাপ্লিকেশন ও রিগ্রেশন

y = mx + c · ন্যূনতম বর্গ · MAE / MSE / RMSE / R² · L1 ও L2: ১১ পাতায়



↑ পুরো টপিক এক পাতায়: লাল = বেশি আসে, সবুজ = যে নিয়মে সব মাপা হয়

সিলেবাসের যে অংশ

কৃত্রিম বুদ্ধিমত্তার সিলেবাসে আছে: পুরোনো ও নতুন AI কৌশল; জ্ঞান উপস্থাপন; প্রস্তাবমূলক ও প্রথম ক্রম যুক্তি; সার্চ; সম্ভাবনাভিত্তিক যুক্তিবিদ্যা; NLP; এক্সপার্ট সিস্টেম; মেশিন লার্নিং; তত্ত্বাবধান ও তত্ত্বাবিহীন শেখা; **মেশিন লার্নিংয়ের ব্যবহারিক প্রয়োগ**; **রিগ্রেশন**। এই নোটবুক ঠিক শেষ দুই লাইন নেয় — তিন প্যারাডাইগম ML-ফাউন্ডেশনস লেসনে, বেইজ ও NLP তত্ত্ব প্রোবাবিলিস্টিক রিজনিং লেসনে।

হাই-ইল্ড তালিকা

① রিগ্রেশন = সংখ্যা, শ্রেণিবিন্যাস = লেবেল
② $\hat{y} = \beta_0 + \beta_1 x$, অর্থাৎ $y = mx + c$
③ OLS ন্যূনতম করে $\Sigma(y_i - \hat{y}_i)^2$
④ MAE = গড়$|y - \hat{y}|$ · MSE = গড়$(y - \hat{y})^2$
⑤ RMSE = √MSE, y-এর একই এককে
⑥ $R^2 = 1 - SSres / SStot$; $R^2 = r^2$
⑦ ওভারফিটিং = train ≫ test; L2 / L1
⑧ $r \in [-1, 1]$ কারণ নয়

সংকেত: **হলুদ** = মূল শব্দ · **লাল বৃত্ত** = অবশ্যই মুখস্থ · **বেগুনি** = মনে রাখার কৌশল · **লাল** = পরীক্ষার ফাঁদ · **সবুজ** = সমাধানকৃত উদাহরণ

সূচিপত্র

✓ ML পাইপলাইন ও কাজ … পৃ. ২
✓ প্রয়োগ ১: স্বাস্থ্য থেকে বাণিজ্য … পৃ. ৩
✓ প্রয়োগ ২: ভাষা থেকে নিরাপত্তা … পৃ. ৪
✓ রিগ্রেশন ও y = mx + c … পৃ. ৫
✓ ন্যূনতম বর্গ · মেট্রিক্স … পৃ. ৬, ৭
✓ রাতের পাতা ১০ · অনুশীলন ১১

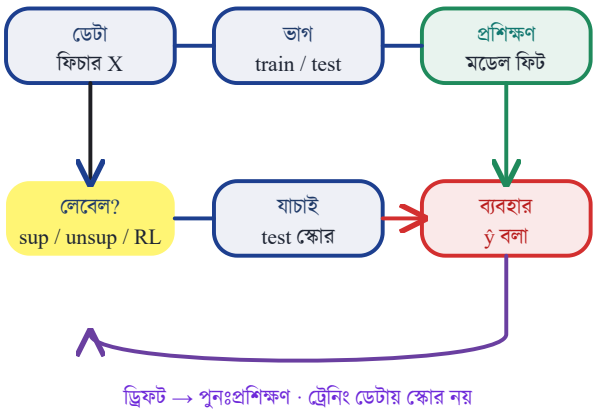
১ ML-এর ব্যবহার: পাইপলাইন ও কাজ

সংজ্ঞা: একটি মেশিন লার্নিং সিস্টেম হলো ডেটা থেকে **ফিট করা একটি ফাংশন**, হাতে লেখা নিয়মের সংগ্রহ নয়। ইনপুট ফিচার **X** থেকে আউটপুট **y** — আর আউটপুটের ধরনই পদ্ধতি ঠিক করে: **সংখ্যা মানে রিগ্রেশন**, **লেবেল মানে শ্রেণিবিন্যাস**, **গোষ্ঠী মানে ক্লাস্টারিং**, **কাজের পর পুরস্কার মানে রিইনফোর্সমেন্ট লার্নিং**।

কাজ	আউটপুট	সাধারণ পদ্ধতি	এক লাইনের উদাহরণ
রিগ্রেশন	বাস্তব সংখ্যা $\hat{y}$	রৈখিক / বহুপদী রিগ্রেশন, SVR, GBM	আগামীকালের বিক্রি
শ্রেণিবিন্যাস	লেবেল + সম্ভাবনা	লজিস্টিক রিগ্রেশন, সিদ্ধান্ত গাছ, SVM, CNN	স্প্যাম না না
ক্লাস্টারিং	একটি গ্রুপ নম্বর	k-means, হায়ারার্কিক্যাল, DBSCAN	ক্রেতাদের ভাগ
রিইনফোর্সমেন্ট	একটি পলিসি	Q-learning, SARSA, DQN	হাঁটতে শেখা রোবট

মনে রাখার কৌশল: প্রশ্নে একটিই প্রশ্ন করো — **"উত্তর কি মাপার ফিতা, না হ্যাঁ-না?"** ফিতা → রিগ্রেশন। হ্যাঁ-না → শ্রেণিবিন্যাস। দুটোই নয় → গোষ্ঠীকরণ (তত্ত্বাবিহীন), বা কাজের পর পুরস্কার (RL)।

পরীক্ষার ফাঁদ: "ML ভবিষ্যৎবাণী করে" — এটি **ভুল**: ML অতীতের **ডেটা** থেকে ফাংশন ফিট করে, তারপর বহির্কৃত করে। টেস্ট সেট অবশ্যই **অদেখা** থাকতে হবে — ট্রেনিং ডেটাতে স্কোর দিলে মুখস্থ মাপা হয়।



পরের দুই পাতার সব প্রয়োগের জন্য একই পাইপলাইন

উদাহরণ ১ ✍ কাজ চিনো: (i) ফ্ল্যাটের বিক্রয়মূল্য বলা → **রিগ্রেশন**; (ii) লেনদেন জাল না না → **শ্রেণিবিন্যাস**; (iii) ATM-এর ব্যবহারে ভাগ, লেবেল ছাড়া → **ক্লাস্টারিং**; (iv) এজেন্ট লেনদেন করে, লাভ বা জরিমানা পায় → **রিইনফোর্সমেন্ট লার্নিং**।

উদাহরণ ২ ✍ একই ডেটা, দুই মডেল: ব্যাংকের **ডিফল্টের সম্ভাবনা** লাগে (লজিস্টিক রিগ্রেশন → ০…১-এর সংখ্যা), আর ঋণ মঞ্জুরি হলে **আনুমানিক ক্ষতির টাকা** লাগে (রৈখিক রিগ্রেশন → যেকোনো বাস্তব সংখ্যা)।

কেন ব্যবহারিক দিকটি কঠিন: অফলাইনে ০.৯২ স্কোর করা মডেল উৎপাদনে ব্যর্থ হতে পারে: ইনপুটের বণ্টন বদলে গেছে, শ্রেণির ভারসাম্য বদলে গেছে, বা পুনঃপ্রশিক্ষণের দায়িত্ব কেউ নেননি। পরীক্ষায় এর নাম **মডেল ড্রিফট**।

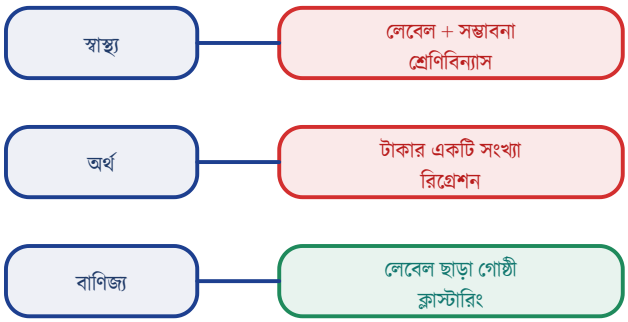
ফিচার মানে কী: ফিচার হলো মডেলের ইনপুট কলাম — ক্ষেত্রফল, বয়স, RMS, লেখার শব্দ। সংখ্যায় প্রকাশ করা ইনপুট ভালো; শুধু নাম বা লেখালিপি হলে সেটা শ্রেণিবিন্যাসের কাজ।

২ প্রয়োগ ১: স্বাস্থ্য, অর্থ, বাণিজ্য

সংজ্ঞা: **মেশিন লার্নিংয়ের ব্যবহারিক প্রয়োগ** মানে ফিট করা মডেলকে একটি সত্যিকারের সিদ্ধান্তের পিছনে বসানো: একটি রোগনির্ণয়, একটি ঋণ, একটি তাক, একটি যন্ত্রাংশ। নিচের প্রতিটি সারিই একটি **পূর্বাভাস**, আর পরীক্ষায় চায় **কাজ** ও **মডেল পরিবার**।

প্রয়োগ	মডেল যা করে	কাজ
স্বাস্থ্য · রোগনির্ণয়	X-ray বা MRI-তে টিউমার চিহ্নিত করা (CNN)	শ্রেণিবিন্যাস
স্বাস্থ্য · ঔষধ আবিষ্কার	যৌগের কার্যকারিতা ও বিষাক্ততা	রিগ্রেশন
স্বাস্থ্য · রোগী পর্যবেক্ষণ	ICU সেন্সর থেকে অবনতি	রিগ্রেশন
স্বাস্থ্য · পুনঃভর্তির ঝুঁকি	৩০ দিনের মধ্যে ফিরে আসবে?	শ্রেণিবিন্যাস
অর্থ · ক্রেডিট স্কোর	ঋণগ্রহীতা ডিফল্ট করবের সম্ভাবনা	শ্রেণিবিন্যাস
অর্থ · জালিয়াতি	0.01 % ভুয়া লেনদেন চিহ্নিত করা	তত্ত্বাবিহীন
অর্থ · ট্রেডিং	পরবর্তী দামের চল	রিগ্রেশন
অর্থ · নগদের চাহিদা	ATM-এ পরের সপ্তাহে কত লাগবে	রিগ্রেশন
বাণিজ্য · সুপারিশ	"X কিনলে Y-ও কেনে"	র‍্যাঙ্কিং
বাণিজ্য · ভাগ	k-means দিয়ে ক্রেতা ভাগ	তত্ত্বাবিহীন
বাণিজ্য · চাহিদা	পরের মাসে কত পণ্য রাখবে	রিগ্রেশন

মনে রাখার কৌশল: প্রশ্নের **আউটপুট শব্দটি** পড়ো: দাম, চাহিদা, তাপমাত্রা, পরিমাণ, ঝুঁকি স্কোর → **রিগ্রেশন**; স্প্যাম, জাল, রোগ, ডিফল্ট, ত্রুটি → **শ্রেণিবিন্যাস**; ভাগ, গ্রুপ, ক্লাস্টার → **তত্ত্বাবিহীন**। "র‍্যাঙ্ক" বা "সুপারিশ" মানে মডেল সাজায়, সংখ্যা বলে না।



একই ডেটা, তিন লক্ষ্য — আউটপুট ধরনেই পদ্ধতি

পরীক্ষার ফাঁদ: ক্রেডিট স্কোরিং হলো **শ্রেণিবিন্যাস** (ঋণগ্রহীতা ডিফল্ট করবে?), রিগ্রেশন নয় — যদিও ব্যাংক "স্কোর" বলে। সুপারিশকারী ইউটিলিটি **র‍্যাঙ্কিং** দেয়, দাম নয়। আর **জালিয়াতির ডেটা ক্ষুদ্র-শ্রেণির**: সাধারণ লেনদেন দেখে অ্যানোমালি শনাক্তকরণই কার্যকর, আর অ্যাকুরেসি এখানে অর্থহীন।

উদাহরণ ✍ মেট্রিক বাছাই: জালিয়াতির ডেটায় ৯৯ ৯০০ সাধারণ, ১০০ জালিয়াতি। "সবই সাধারণ" বলা মডেল **৯৯.৯ % অ্যাকুরেসি দেয়, অথচ একটিও জাল ধরে না**। সঠিক স্কোর হলো **জালিয়াতি শ্রেণির recall** আর প্রতিদিন পরিষ্কার করতে হবে **মিথ্যা ইতিবাচক**।

অন্য লেসনের সঙ্গে সংযোগ: **এক্সপার্ট সিস্টেম** লেসনে প্রতিটি সারির পুরোনো নিয়মভিত্তিক বিকল্প আলোচিত হয়েছে; তিন প্যারাডাইগম **ML ফাউন্ডেশনস** লেসনে। এখানে শুধু *খাত* → *কাজ* → *মডেল পরিবার* মানচিত্রটি দরকার।

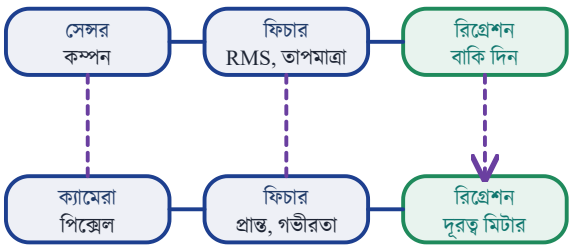
৩ প্রয়োগ ২: ভাষা থেকে নিরাপত্তা

সংজ্ঞা: একই পাইপলাইন, কিন্তু ইনপুট টেবিলের পরিবর্তে। লেখা হয় টোকেন ও এম্বেডিং, ছবি হয় পিক্সেল, যন্ত্র হয় **সেন্সর টাইম সিরিজ**, রাস্তা হয় ডিটেক্টরের সংখ্যার ধারা। মডেল পরিবার বদলায়, কাজের ব্যাকরণ বদলায় না।

প্রয়োগ	ইনপুট → আউটপুট	কাজ
NLP · সেন্টিমেন্ট	রিভিউ → ইতিবাচক / নেতিবাচক	শ্রেণিবিন্যাস
NLP · অনুবাদ	ক-ভাষার বাক্য → খ-ভাষার বাক্য	ম্যাপিং
NLP · স্প্যাম ফিল্টার	ইমেল → রাখো বা আটকাও	শ্রেণিবিন্যাস
দৃশ্য · স্বয়ংচালিত গাড়ি	ফ্রেম → বস্তু, লেন, দূরত্ব	শনাক্তকরণ
দৃশ্য · মান নিয়ন্ত্রণ	লাইন-স্ক্যান ছবি → পাশ / বাদ	শ্রেণিবিন্যাস
শিল্প · প্রেডিক্টিভ মেইনটেন্যান্স	কম্পন → ব্যর্থতার দিন	**রিগ্রেশন**
শিল্প · প্রক্রিয়া নিয়ন্ত্রণ	সেন্সর → সেরা সেট-পয়েন্ট	রিগ্রেশন
পরিবহন · ট্রাফিক	লুপ ডিটেক্টর → গতি, প্রবাহ	রিগ্রেশন
পরিবহন · রাইড-হেইলিং	ঘণ্টা + আবহাওয়া → ভ্রমণ	রিগ্রেশন
কৃষি · ফসলের ফলন	মাটি + NDVI → টন/হেক্টর	রিগ্রেশন
নিরাপত্তা · অনুপ্রবেশ	নেটওয়ার্ক প্রবাহ → স্বাভাবিক / আক্রমণ	তত্ত্বাবিহীন
নিরাপত্তা · ম্যালওয়্যার	বাইনারি → ম্যালওয়্যার পরিবার	শ্রেণিবিন্যাস

মনে রাখার কৌশল: "ছবি বা সেন্সর ঢোকে, **সংখ্যা বেরোয়** — প্রেডিক্টিভ মেইনটেন্যান্স ও ট্রাফিকে।" প্রশ্নে *কত / কতদিন / কখন* থাকলেই রিগ্রেশন, এমনকি ইনপুট ছবি হলেও।

পরীক্ষার ফাঁদ: প্রেডিক্টিভ মেইনটেন্যান্স হলো **রিগ্রেশন** (কত দিন বাকি), আর **ফল্ট ডিটেকশন** হলো শ্রেণিবিন্যাস (এখনই ত্রুটিপূর্ণ?) — দুটি আলাদা মডেল, পরীক্ষকারীরা বদলে দেন। "অনুপ্রবেশ শনাক্তকরণ"-এ **তত্ত্বাবিহীন** মানে সাধারণ ট্রাফিক দিয়ে প্রশিক্ষণ, তাই নতুন আক্রমণও ধরা পড়ে।



মাঝের বাক্স প্রতিটি খাতেই এক
তৃতীয় বাক্সটিই পরীক্ষার উত্তর

অসংগঠিত ইনপুট, তৈরি ফিচার, সংখ্যায় আউটপুট

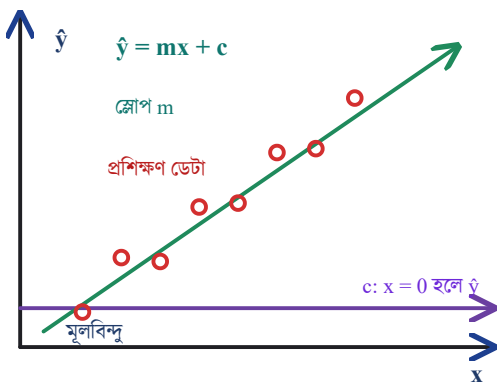
উদাহরণ ✍ মেইনটেন্যান্স, শুরু থেকে শেষ: বিয়ারিং-এর কম্পন RMS ব্যর্থতার আগের শেষ ৪০০ ঘণ্টায় ০.৪ থেকে ১.৮ mm/s-এ প্রায় রৈখিকভাবে বাড়ে। ফিট করুন **remaining life = 400 − 220 × RMS**। RMS = 1.2 mm/s হলে সতর্কতা **১৩৬ ঘণ্টা** আগে, 1.6 mm/s হলে **48 ঘণ্টা** আগে। ব্যর্থতা ঘটার আগেই ডাকা পড়াই এখানে ML-এর সব মূল্য।

৪ রিগ্রেশন ও মডেল y = mx + c

সংজ্ঞা: **রিগ্রেশন (Regression)** হলো **ধারাবাহিক সাংখ্যিক আউটপুটের জন্য তত্ত্বাবধান শেখা**। একটি ফিচার হলে মডেল হয় **সরল রৈখিক রিগ্রেশন** রেখা $\hat{y} = m\,x + c$: এখানে m হলো **স্লোপ** (x এক ধাপ বাড়লে $\hat{y}$-এর পরিবর্তন), c হলো **ইন্টারসেপ্ট** ($x = 0$ হলে $\hat{y}$)। pটি ফিচার হলে এটি **বহুরৈখিক রিগ্রেশন**: $\hat{y} = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p + \varepsilon$.

> c মানে শুধু $x = 0$-এর $\hat{y}$

তুলনার বিষয়	রিগ্রেশন	শ্রেণিবিন্যাস
আউটপুট	যেকোনো বাস্তব সংখ্যা, সীমাহীন	নির্দিষ্ট লেবেলের একটি
সাধারণ লস	বর্গযুক্ত ভুল (MSE), পরম শুদ্ধ ভুল (MAE)	ক্রস এন্ট্রপি, 0–1 লস
সাধারণ স্কোর	**MAE, MSE, RMSE, R^2**	অ্যাকুরেসি, প্রিসিশন, রিকল, F1
ছাপিয়ে যাওয়া বেসলাইন	সবসময় y-এর গড় বলা	সবসময় বেশির ভাগ শ্রেণি বলা
প্রতীকী রূপ	$\hat{y} = mx + c$	$P(Y=1\|X) = 1/(1 + e^{-z})$
উদাহরণ	বাড়ির দাম, তাপমাত্রা	স্প্যাম না না



মডেল হলে সবুজ রেখা; লাল বিন্দুগুলোকেই মানাতে হবে

প্রমাণের ছায়া ✍️ রেখাটি কেন $(\bar{x}, \bar{y})$ দিয়ে যায়:

১. ন্যূনতম বর্গ লম্বভুল ত্রুটি ছোট করতে m, c বাছে

২. দুইটি অন্তরক শূন্য $\Longrightarrow \Sigma\hat{y} = \Sigma y \Longrightarrow c = \bar{y} - m\,\bar{x}$, তাই রেখা **সবসময় $(\bar{x}, \bar{y})$** দিয়ে যায়

যে দুটি সংখ্যা দরকার: $\mathbf{m = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / \Sigma(x_i - \bar{x})^2}$ · $\mathbf{c = \bar{y} - m\,\bar{x}}$, আর $m = r \cdot \sigma_y/\sigma_x$ তাই r-এর চিহ্নই m-এর চিহ্ন।

মনে রাখার কৌশল: **"m সরায়, c ঠিক করে।"** m বলে *x এক বাড়লে ŷ কত বাড়ে?*; c বলে *x = 0 হলে ŷ কত?* ফিট করা রেখা সবসময় গড় বিন্দু $(\bar{x}, \bar{y})$ ভেদ করে — কোনো উত্তর ঠিক কি না তা চোখে বোঝা যায়।

পরীক্ষার ফাঁদ: (i) ইন্টারসেপ্ট হলো **x = 0-এর ŷ**, y-এর গড় নয়। (ii) **লজিস্টিক রিগ্রেশন শ্রেণিবিন্যাস**, নামের ভুল। (iii) সেরা-ফিট রেখাকে মূলবিন্দু দিয়ে যেতে হবে না। (iv) রিগ্রেশনে কোনো **সুষম** শ্রেণি-কাঠামো লাগে না।

উদাহরণ ✍️ মডেল পড়ে তারপর পূর্বাভাস: লক্ষ টাকায় ফ্ল্যাটের মডেল $\hat{y} = 18.5 + 3.2 \times$ **(m²-তে ক্ষেত্রফল)**। 90 m² হলে $\hat{y} = 18.5 + 288 =$ **306.5** লক্ষ। প্রতি বর্ধিত m²-এ **3.2 লক্ষ** যোগ (m = 3.2), আর শূন্য ক্ষেত্রফলের জমির মূল্য **18.5 লক্ষ** (c = 18.5) — বাস্তবে জমি ও নিবন্ধনের দাম।

৫ ন্যূনতম বর্গ (OLS)

সংজ্ঞা: **সাধারণ ন্যূনতম বর্গ (OLS)** এমন গুণাঙ্ক বাছে যা **বর্গীকৃত অবশিষ্টের সমষ্টি** ন্যূনতম করে: প্রতিটি প্রশিক্ষণ বিন্দুতে $SSE = \Sigma(y_i - \hat{y}_i)^2$ ছোট করো। ভুল গোনা শ্রেণিবিন্যাসের কাজ; OLS গোনে না — এটি **বর্গ করে যোগ করে**।

প্রমাণ ✍️ নরমাল সমীকরণ:

১. উদ্দেশ্য: $SSE(a, b) = \Sigma(y_i - a - b\,x_i)^2$

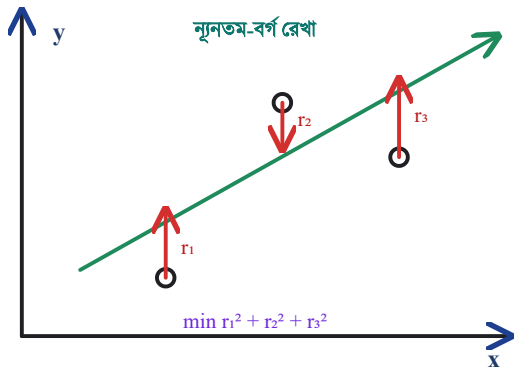
২. অন্তরক শূন্য: $\partial SSE/\partial a = -2\Sigma(y_i - a - b\,x_i) = 0$ এবং $\partial SSE/\partial b = -2\Sigma x_i(y_i - a - b\,x_i) = 0$

৩. দুটি **নরমাল সমীকরণ**: $na + b\,\Sigma x = \Sigma y$ এবং $a\,\Sigma x + b\,\Sigma x^2 = \Sigma xy$

৪. সমাধান: $\mathbf{b = [n\Sigma xy - (\Sigma x)(\Sigma y)] / [n\Sigma x^2 - (\Sigma x)^2]}$, $\mathbf{a = \bar{y} - b\,\bar{x}}$

x	1	2	3	Σ
y	2	4	5	11
xy	2	8	15	25
x^2	1	4	9	14

x	1	2	3	Σ
প্রকৃত y	2.000	4.000	5.000	$\Sigma y = 11$
ফিট $\hat{y}$	2.167	3.667	5.167	$\Sigma \hat{y} = 11$
অবশিষ্ট e	−0.167	+0.333	−0.167	$\Sigma e = 0$
e^2	0.028	0.111	0.028	SSE = **0.167**



অবশিষ্ট $r_i = y_i - \hat{y}_i$ বর্গ করে যোগ হয়, গোনা হয় না

(1, 2), (2, 4), (3, 5)-এর উত্তর: $n = 3, \Sigma x = 6, \Sigma y = 11, \Sigma xy = 25, \Sigma x^2 = 14 \Rightarrow$ **$b = [3(25) - 6(11)] / [3(14) - 6^2] = (75 - 66) / (42 - 36) = 9/6 = 1.5$** এবং **$a = 11/3 - 1.5(2) = 2/3 \approx 0.67$**, তাই **$\hat{y} = 0.67 + 1.5x$**।

মনে রাখার কৌশল: "**O**ne line, **L**east **S**quares" — তাই ছোট হয় **সমষ্টি**। যাচাইয়ের সুলভ চিহ্ন: সঠিক OLS ফিটে অবশিষ্টের **সমষ্টি শূন্য** আর ফিট করা মানের **সমষ্টি প্রকৃত মানের সমান**, কারণ রেখা $(\bar{x}, \bar{y})$ ভেদ করে।

পরীক্ষার ফাঁদ: OLS-কে **সাধারণ** বলা হয় কারণ প্রতিটি বিন্দুর ওজন সমান — যারা সমান নয় তার নাম **ওজনযুক্ত ন্যূনতম বর্গ**। বর্গ করলে একটি বড় অবশিষ্ট ফিটকে **একাইটে নিয়ে যায়**, তাই আউটলায়ার থাকলে MAE-ফিটিং, হুবার লস বা কোয়ান্টাইল রিগ্রেশন ব্যবহার করো।

IT সংযোগ ✍️ একই গণিত কোডে:

```
b = (n*Sxy - Sx*Sy) / (n*Sxx - Sx^2);  a = ybar - b*xbar
```

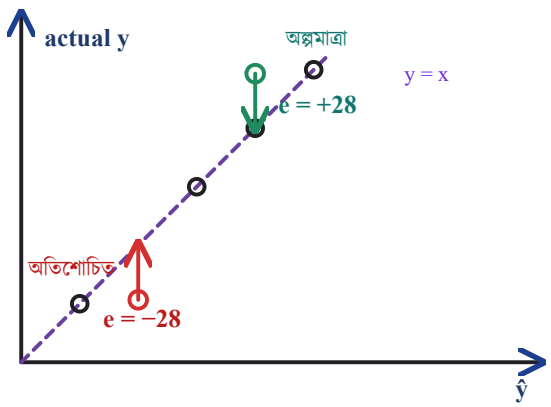
৬ MAE, MSE, RMSE ও R^2

সংজ্ঞা: প্রতিটি মেট্রিক তৈরি হয় অবশিষ্ট $e_i = y_i - \hat{y}_i$ থেকে। MAE ও MSE দুটি ভিন্নভাবে গড় করে, RMSE হলো MSE-কে y-এর এককে ফিরিয়ে আনা, আর **R^2 মডেলকে "সবসময় গড় বলা" বেসলাইনের সঙ্গে মিলিয়ে দেখায়**।

মেট্রিক	সূত্র	ধর্ম ও কখন ব্যবহার
MAE	$(1/n)\,\Sigma\lvert y_i - \hat{y}_i\rvert$	গড় পরম শুদ্ধ ভুল: y-এর এককে; **মজবুত** — আউটলায়ার প্রায় কিছুই বদলায় না
MSE	$(1/n)\,\Sigma(y_i - \hat{y}_i)^2$	গড় বর্গযুক্ত ভুল: একক y^2; **বড় ভুলকে অনেক বেশি শাস্তি**; মডেল প্রশিক্ষণে ব্যবহৃত
RMSE	$\sqrt{\text{MSE}}$	আবার y-এর এককে; "গড়ে X একক ভুল" বলা যায়
R^2	$1 - SS_{res}/SS_{tot}$	ব্যাপিত ভ্যারিয়েন্সের ভাগ; **ঋণাত্মকও হতে পারে**; সরল রেখায় $R^2 = r^2$

উদাহরণ ১ ✍️ পাতা ৬-এর OLS ফিট: অবশিষ্ট −0.167, +0.333, −0.167: **MAE** = 0.667/3 = **0.222** · **MSE** = 0.167/3 = **0.0556** · **RMSE** = √0.0556 = **0.236**, y-এর এককে। SS_{res} = 0.167, SS_{tot} = 2.778 + 0.111 + 1.778 = 4.667, তাই **R^2 = 1 − 0.167/4.667 = 0.964**: y-এর ভ্যারিয়েন্সের ৯৬.৪ % ব্যাখ্যা করে।

মনে রাখার সম্পর্ক: **MAE ≤ RMSE** সবসময় · **MSE ≥ MAE²** সবসময়, সমতা কেবল সব অবশিষ্ট সমান হলে · SStot = SSreg + SSres · R^2 = SSreg/SStot · স্থানান্তরিত $R^2 = 1 - (1 - R^2)(n - 1)/(n - p - 1)$।



প্রতিটি বিন্দু একটি পূর্বাভাস; ফারাকই অবশিষ্ট, আর SSE তার বর্গ যোগ করে

উদাহরণ ২ ✍️ একটি আউটলায়ার MSE উল্টে দেয়: 10, 10, 10, 10 অবশিষ্টে MAE = 10, MSE = 100। শেষটি 40 করলে MAE = 17.5, MSE = 475, RMSE = 21.8 — **MAE বাড়ল ৭৫ %, MSE বাড়ল ৩৭৫ %**।

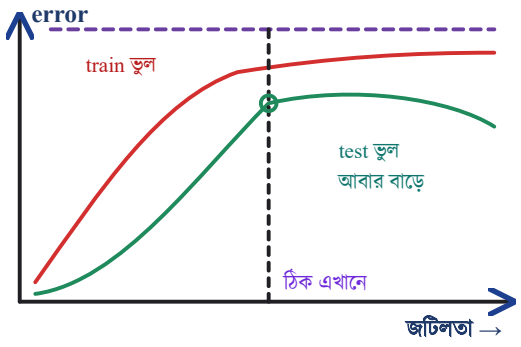
মনে রাখার কৌশল: **"বর্গ, গড়, বর্গমূল"**। MSE = বর্গের গড়, RMSE = তার বর্গমূল, তাই RMSE = √MSE এবং একক y-এর। R^2-এ: **১** পূর্ণ, **০** গড়ের চেয়ে ভালো নয়, **ঋণাত্মক** গড়ের চেয়েও খারাপ।

পরীক্ষার ফাঁদ: R^2 শতাংশ নয় এবং **ঋণাত্মক** হতে পারে। MSE-এর একক y^2, তাই পড়ার যায় শুধু RMSE। MAE "বেশি নির্ভুল" নয়, শুধু আলাদা আচরণ করে।

৭ ওভারফিটিং, বায়াস-ভ্যারিয়েন্স, L1/L2

সংজ্ঞা: **ওভারফিটিং (Overfitting)** মানে প্রশিক্ষণ ডেটাকে — তার নয়েজসহ — এত কাছ থেকে ফিট করা যে অদেখা ডেটায় মডেল ব্যর্থ হয়। লক্ষণ **train–test ফারাক**: প্রশিক্ষণে ৯৯ %, পরীক্ষায় ৬০ %। আনুষ্ঠানিক নাম **উচ্চ ভ্যারিয়েন্স**। উল্টো ব্যর্থতা, অর্থাৎ দুই জায়গাতেই খারাপ স্কোর, হলো **আন্ডারফিটিং = উচ্চ বায়াস**।

লক্ষণ	train	test	রোগনির্ণয়
নয়েজ মুখস্থ	99%	60%	ওভারফিটিং, উচ্চ ভ্যারিয়েন্স
মডেল খুব সরল	58%	55%	আন্ডারফিটিং, উচ্চ বায়াস
সুস্থ ফিট	88%	86%	সাধারণীকরণ ✓



train ভুল সবসময় কমে, test ভুল আবার বাড়তে শুরু করে

পদ্ধতি	শাস্তি	গুণাঙ্কের ওপর প্রভাব
L2 রিজ	$\lambda \Sigma\beta^2$	সব কমে, **0 হয় না**
L1 লাসো	$\lambda \Sigma\|\beta\|$	কিছু $\beta = \mathbf{0} \rightarrow$ **বাছাই**
ইলাস্টিক নেট	$\lambda_1\Sigma\|\beta\|+\lambda_2\Sigma\beta^2$	L1-এর বিরলতা + L2-এর স্থায়িত্ব
λ খুব ছোট	$\lambda \downarrow$	কম নিয়ন্ত্রণ
λ খুব বড়	$\lambda \uparrow$	বেশি নিয়ন্ত্রণ, বায়াস বাড়ে

মনে রাখার কৌশল: **"লাসো শূন্য করে, রিজ ছোট করে।"** L1-এর পরম মানের শাস্তি শূন্যের দিকে ভাঁজ করা, তাই অপ্রয়োজনীয় গুণাঙ্ক পুরোপুরি 0 হয়ে ফিচারটি বাদ পড়ে; L2-এর বর্গ শাস্তি কেবল 0-এর দিকে টানে।

রিজ ও লাসোর উদ্দেশ্য: ন্যূনতম করো $\Sigma(y_i - \beta_0 - \Sigma\beta_j x_j)^2 + \lambda\,\Sigma\beta_j^2$ (L2) বা $+\,\lambda\,\Sigma|\beta_j|$ (L1)। বড় λ = ভারী সংকোচন = বেশি বায়াস, কম ভ্যারিয়েন্স। β_0 শাস্তি দেয় না।

পরীক্ষার ফাঁদ: (i) ওভারফিটিং হলো **উচ্চ ভ্যারিয়েন্স**, আন্ডারফিটিং **উচ্চ বায়াস** — উল্টো নয়। (ii) **বড়** λ মানে **বেশি** নিয়ন্ত্রণ, তাই বেশি বায়াস ও কম ভ্যারিয়েন্স। (iii) নিয়ন্ত্রণ কোনো তথ্য যোগ করে না। (iv) ফিচার বাছাই শুধু **L1** করে।

উদাহরণ ✍ ফারাক পড়া: প্রশিক্ষণে ৯৯ %, পরীক্ষায় ৬০ % ⟹ ৩৯ পয়েন্ট ফারাক ⟹ ওভারফিটিং। খরচের ক্রমে সমাধান: **(১)** আরও ডেটা, **(২)** L2 / L1 নিয়ন্ত্রণ, **(৩)** ক্রস-ভ্যালিডেশনে λ বাছা, **(৪)** সরল মডেল, **(৫)** আর্লি স্টপিং।

শুধু প্রশিক্ষণ সেট কেন যথেষ্ট নয়: যথেষ্ট সক্ষমতা থাকলে যেকোনো মডেল প্রশিক্ষণ ভুল শূন্যে নামাতে পারে। ফারাক কেবল **আলাদা রাখা টেস্ট সেট** বা ক-ফোল্ড ক্রস-ভ্যালিডেশনই দেখায়।

তিন ভাগে ভাগ: ট্রেনিং (ফিট), ভ্যালিডেশন (λ ও মডেল বাছা) ও টেস্ট (শেষ স্কোর) — সাধারণ ভাগ ৬০ / ২০ / ২০; k-ফোল্ড ক্রস-ভ্যালিডেশন ভাগটি k বার করে।

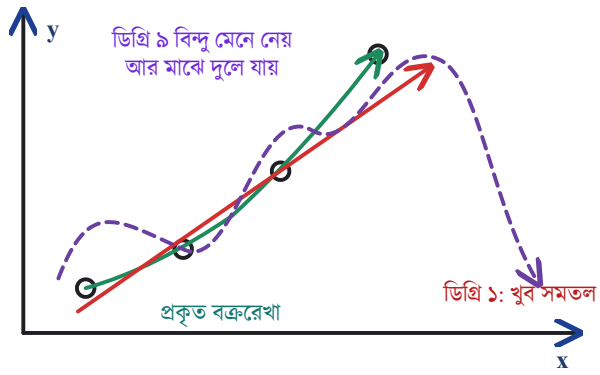
৮ বহুপদী রিগ্রেশন ও সম্পর্ক ≠ কারণ

সংজ্ঞা: **বহুপদী রিগ্রেশন** রৈখিক ন্যূনতম-বর্গের কাঠামো রাখে, কিন্তু ফিচারের ঘাত যোগ করে: $\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \ldots + \beta_n x^n$। **সম্পর্ক (Correlation)** হলো *রৈখিক* সম্পর্কের প্রমাণিত শক্তি — পিয়ারসনের $r = \mathrm{cov}(x, y)/(\sigma_x \sigma_y)$ — আর তা সবসময় **[−1, +1]**-এর মধ্যে থাকে।

মডেল	রূপ	আকৃতি ও প্রধান ঝুঁকি
রৈখিক	$\hat{y} = mx + c$	একটি সরলরেখা; বাঁকতে পারে না, তাই বাঁকা ডেটায় আন্ডারফিট করে
বহুপদী, ডিগ্রি n	$\hat{y} = \beta_0 + \beta_1 x + \ldots + \beta_n x^n$	সর্বোচ্চ $n - 1$ বাঁক; **ওভারফিট** করে বিন্দুর মাঝে দোলে
লজিস্টিক	$1/(1 + e^{-z})$	0…১ সম্ভাবনার S-আকৃতি; কেবল শ্রেণিবিন্যাস, সীমানা রৈখিক

উদাহরণ ✍️ রেখা আন্ডারফিট করে, বক্ররেখা ঠিক করে: ডেটা (0, 1), (1, 3), (2, 7), (3, 13)। দ্বিতীয় পার্থক্য 2, 2 — ধ্রুব, তাই ডেটা ঠিক বহুপদী: $\hat{y} = 1 + x + x^2$, SSE = **0**। **রৈখিক** ফিটে $b = 20/5 = 4$, $a = 0$, তাই $\hat{y} = 4x$, অবশিষ্ট **+1, −1, −1, +1**: MAE = 1, MSE = 1, $R^2 = 1 - 4/84 = 0.952$।

মনে রাখার কৌশল: রৈখিক ফিট ভুল হলেও **এলোমেলো না** হলে অবশিষ্টের ধরন থেকে বোঝা যায়: + − − + মানে বক্রতা, **এলোমেলো চিহ্ন** মানে শুধু নয়েজ।



ক্ষমতা বাড়লে প্রশিক্ষণ ভুল সবসময় কমে, আর মডেল নষ্ট হতে পারে

সম্পর্ক মানে কারণ নয়: আইসক্রিম বিক্রয় ও ডুবে যাওয়ার মধ্যে $r = 0.98$, তবু কোনোটিই অন্যটিকে ঘটায় না: দুটোই চালিত **একটি গোপন কারণে** — গরমের আবহাওয়ায়। r **দিক** বলে না, অরৈখিক সম্পর্ক বলে না, আর সমষ্টিগত ডেটায় শক্তিশালী r ব্যক্তিগতে মিলিয়ে পায় না (**সিম্পসনের প্যারাডক্স**)।

পরীক্ষার ফাঁদ: (i) $r = 0.9$ কারণ প্রমাণ করে না। (ii) $r = 0$ স্বাধীনতা প্রমাণ করে না — এটি কেবল **রৈখিক** সম্পর্ক বাদ দেয়। (iii) **সরল** রেখায় $R^2 = r^2$ ঠিক; একাধিক ফিচারে তা নয়। (iv) ডিগ্রি-n বহুপদী সর্বোচ্চ **n − 1** বার বাঁকে।

উদাহরণ ✍️ একই ডেটা, দুটি গুণাঙ্ক: একই চার বিন্দুর জন্য $r = 20/\sqrt{(5 \times 84)} =$ **0.976** এবং রৈখিক $R^2 = r^2 = 0.952$। x^2 যোগ করলে $R^2 = 1.000$ হয় কিন্তু r অপরিবর্তিত: **R^2 মাপে ফিট, r মাপে রৈখিক সম্পর্ক**।

রাতের আগের পাতা

সূত্র পাতা:

মডেল $\hat{y} = mx + c$ (m স্লোপ, c ইন্টারসেপ্ট)

সাধারণ $\hat{y} = \beta_0 + \Sigma\beta_j x_j + \varepsilon$

ফিট রেখা ভেদ করে $(\bar{x}, \bar{y})$

$\mathbf{m} = \Sigma(x-\bar{x})(y-\bar{y}) / \Sigma(x-\bar{x})^2$

$\mathbf{m} = [n\Sigma xy - \Sigma x\Sigma y] / [n\Sigma x^2 - (\Sigma x)^2]$

$\mathbf{c} = \bar{y} - m\,\bar{x}$

অবশিষ্ট $e = y - \hat{y}$ · OLS ন্যূনতম করে Σe^2

MAE = গড়$|e|$ · **MSE** = গড়(e^2)

RMSE = √MSE, y-এর একক

$\mathbf{R^2} = 1 - SSres/SStot$

স্থানান্তরিত $\mathbf{R^2} = 1 - (1-R^2)(n-1)/(n-p-1)$

$\mathbf{r} = cov/(\sigma x \sigma y) \in [-1, 1]$

সরল রেখায় $R^2 = r^2$ · **L2** $+ \lambda\Sigma\beta^2$

L1 লাসো $+ \lambda\Sigma|\beta|$

লজিস্টিক $1/(1 + e^{-z})$

সবসময় $MAE \le RMSE$, $MSE \ge MAE^2$

MCQ-র জন্য সেরা ১২টি এক লাইনের কথা

1. রিগ্রেশন ভবিষ্যৎবাণী করে না
2. রিগ্রেশন **ধারাবাহিক সংখ্যা** বলে
3. শ্রেণিবিন্যাস **লেবেল** ও সম্ভাবনা বলে
7. c মানে **x = 0-এর ŷ**, গড় নয়
8. RMSE = √MSE, y-এর এককে
9. MAE মজবুত; MSE বড় ভুল শাস্তি দেয়

4. লেবেল ছাড়া k-means = **তত্ত্ববিহীন**

5. কাজের পর পুরস্কার = **রিইনফোর্সমেন্ট**

6. OLS ন্যূনতম করে $\Sigma(y - \hat{y})^2$, গোনে না

10. R^2 **ঋণাত্মক** হতে পারে

11. ওভারফিটিং = **উচ্চ ভ্যারিয়েন্স**

12. L1 শূন্য করে, L2 ছোট করে

সবচেয়ে বড় ফাঁদগুলো: লজিস্টিক রিগ্রেশন শ্রেণিবিন্যাস · ইন্টারসেপ্ট গড় নয় · MSE-এর একক y^2, পড়া যায় শুধু RMSE · R^2 শতাংশ নয় · বড় λ = বেশি সংকোচন = বেশি বায়াস · ফিচার বাছায় লাসো, রিজ নয় · ডিগ্রি-n বহুপদী $n - 1$ বার বাঁকে · জাল ও অনুপ্রবেশের ডেটা ক্ষুদ্র-শ্রেণির, তাই অ্যাকুরেসি অর্থহীন · টেস্ট সেট অবশ্যই অদেখা · $r = 0$ মানে স্বাধীনতা নয়।

সব কৌশল একসঙ্গে: "ফিতা না হ্যাঁ-না" দিয়ে রিগ্রেশন বনাম শ্রেণিবিন্যাস · "m সরায়, c ঠিক করে" · ফিট $(\bar{x}, \bar{y})$ ভেদ করে ও অবশিষ্টের সমষ্টি 0 · "বর্গ, গড়, বর্গমূল" · "লাসো শূন্য করে, রিজ ছোট করে" · অবশিষ্টের + − − + ধরন মানে মডেল বাঁকাও, দোষধার্য নয় · দুটি জিনিস একসঙ্গে নড়া মানে তৃতীয় কিছুই চালাতে পারে।



ডেটা ঢোকে, চারটি সংখ্যা বেরোয়, তারপর প্রতিবার একই চারটি সিদ্ধান্ত

✓ অনুশীলন MCQ (১০ নম্বর)

১. রিগ্রেশন কী বলে?

ক) গ্রুপ নম্বর — খ) বাস্তব সংখ্যা

গ) হ্যাঁ/না লেবেল — ঘ) সেরা চাল

২. OLS কী ন্যূনতম করে?

ক) ভুল গণনা — খ) $\Sigma(y - \hat{y})^2$

গ) x-এর যোগ — ঘ) সম্পর্ক r

৩. একটি বড় আউটলায়ারে কম ক্ষতি:

ক) MAE — খ) MSE

গ) RMSE — ঘ) কোনোটিই নয়

৪. সরল রেখায় R^2 কী?

ক) স্লোপ — খ) SSres/SStot

গ) গড় $\bar{y}$ — ঘ) r বর্গ

৫. L1 (লাসো) কী করতে পারে?

ক) সমান ছোট করা — খ) লেবেল উপেক্ষা

গ) কিছু β শূন্য — ঘ) কোনো শাস্তি নয়

৬. train 99%, test 60%:

ক) ওভারফিটিং — খ) আন্ডারফিটিং

গ) সেরা ফলাফল — ঘ) রেট খুব ছোট

৭. সম্পর্ক নিয়ে ঠিক কথা:

ক) r কারণ প্রমাণ — খ) শুধু রৈখিক

গ) কারণে $r = 1$ — ঘ) p মান প্রমাণ

৮. MAE = 4 হলে MSE:

ক) ≤ 4 — খ) $= 4$

গ) < 16 — ঘ) ≥ 16

৯. লজিস্টিক রিগ্রেশন কী বলে?

ক) সিগময়েড লেবেল — খ) বাস্তব দাম

গ) ক্লাস্টার — ঘ) কম ফিচার

১০. বহুপদী কী যোগ করে?

ক) কোনো পদ নয় — খ) ওভারফিটের ঝুঁকি নয়

গ) $x^2, x^3 \ldots$ পদ — ঘ) শুধু ছবি

উত্তরমালা → ১-খ · ২-খ · ৩-ক · ৪-ঘ · ৫-গ · ৬-ক · ৭-খ · ৮-ঘ · ৯-ক · ১০-গ

লিখিত প্রশ্ন: (1, 2), (2, 4), (3, 5) বিন্দুগুলোর সাধারণ ন্যূনতম-বর্গ রেখা ফিট করো। স্লোপ, ইন্টারসেপ্ট, ফিট করা মান, MAE, MSE, RMSE ও R^2 দাও এবং ফিট সম্পর্কে মন্তব্য দাও। ১০ নম্বর

১ **সাজানো (২)** — $n = 3$; $\Sigma x = 6$, $\Sigma y = 11$, $\Sigma xy = 25$, $\Sigma x^2 = 14$; ন্যূনতম করো $SSE = \Sigma(y_i - a - b\,x_i)^2$। ২

২ **গুণাঙ্ক (৩)** — $b = [n\Sigma xy - (\Sigma x)(\Sigma y)]/[n\Sigma x^2 - (\Sigma x)^2] = (75 - 66)/(42 - 36) = \mathbf{1.5}$; $a = \bar{y} - b\,\bar{x} = 11/3 - 3 = \mathbf{2/3} \approx \mathbf{0.67}$, তাই $\hat{y} = \mathbf{0.67 + 1.5x}$। ৩

৩ **ফিট করা মান (২)** — $\hat{y} = 2.167, 3.667, 5.167$; অবশিষ্ট $e = -0.167, +0.333, -0.167$। যাচাই: $\Sigma e = 0$ ও $\Sigma\hat{y} = \Sigma y$, কারণ রেখা $(\bar{x}, \bar{y})$ ভেদ করে। ২

৪ **মেট্রিক (২)** — MAE = 0.667/3 = **0.222**; MSE = 0.167/3 = **0.0556**; RMSE = √0.0556 = **0.236**, y-এর এককে। ২

৫ **R^2 ও মন্তব্য (১)** — SSres = 0.167, SStot = 4.667, $R^2 = 1 - 0.167/4.667 = \mathbf{0.964}$: y-এর ভ্যারিয়েন্সের ৯৬.৪ % ব্যাখ্যা হয় এবং এই আকারে কোনো train–test ফারাক নেই। ১

পরীক্ষার আগে যাচাই ✓

- ✓ যেকোনো প্রয়োগকে রিগ্রেশন / শ্রেণিবিন্যাস / ক্লাস্টারিং / RL বলতে পারি
- ✓ দুই রূপেই m ও c বের করতে পারি
- ✓ অবশিষ্টের তালিকা থেকে MAE, MSE, RMSE, R^2 বের করতে পারি
- ✓ R^2 কেন ঋণাত্মক হতে পারে এবং r কেন কারণ নয়