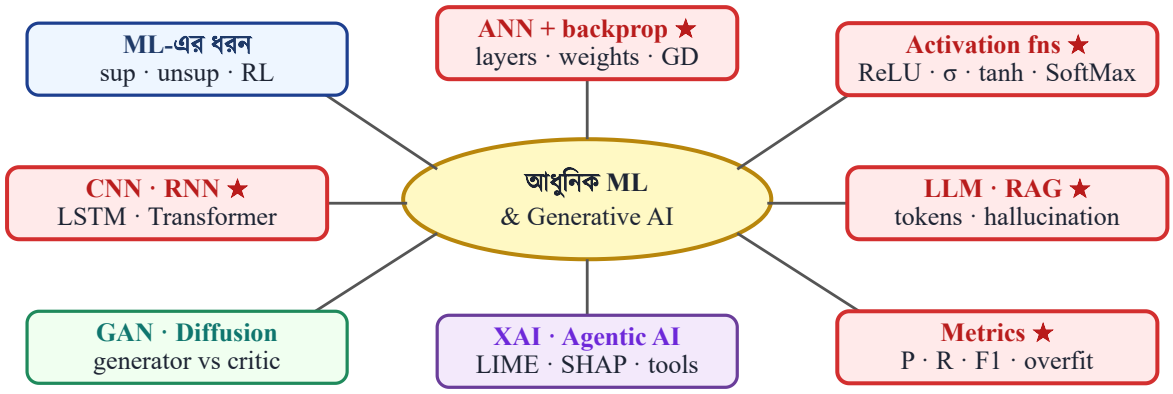
আধুনিক ML ও Generative AI

ML-এর ধরন · নিউরাল নেট · ডিপ লার্নিং · LLM · GenAI · XAI · এজেন্ট · মেট্রিক: পরীক্ষা-প্রস্তুত ১০টি শিটে



সংকেত: **হলুদ**=মূল শব্দ · ●=অবশ্যই মুখস্থ · =স্মৃতি-কৌশল · =পরীক্ষার ফাঁদ

সিলেবাসের যে অংশ: মেশিন লার্নিং, নিউরাল নেটওয়ার্ক, ডিপ লার্নিং, Generative AI ও LLM, Explainable AI, মডেল মূল্যায়ন। Expert system, search, Bayes/NLP ও regression এই অধ্যায়ের আলাদা লেসনে আছে।

শীর্ষ ৩ ফাঁদ:
① sigmoid (0,1), tanh (−1,1)
② RAG hallucination কমায়, পুরো দূর করে না
③ উঁচু accuracy-র আড়ালে recall = 0 থাকতে পারে

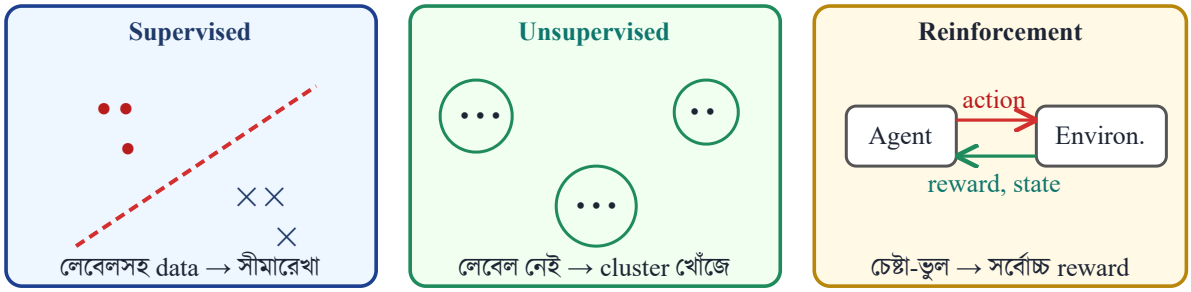
উচ্চ-yield তালিকা
① time-series → RNN / LSTM
② ছবি (image) → CNN
③ backprop: MLP, CNN, RNN = সবগুলো
④ softmax = multiclass output
⑤ GAN = generator বনাম discriminator
⑥ LIME local · SHAP Shapley
⑦ F1 = P ও R-এর harmonic mean

বিষয়বস্তু

১. ML-এর ধরন ও transfer learning … পৃ.২
২. ANN, backprop ও gradient descent … পৃ.৩
৩. Activation function … পৃ.৪
৪. ডিপ লার্নিং: CNN · RNN · Transformer … পৃ.৫
৫. LLM, RAG ও prompting … পৃ.৬
৬. Generative AI ও XAI … পৃ.৭
৭. Agentic AI · over/underfitting … পৃ.৮
৮. মূল্যায়ন মেট্রিক … পৃ.৯
৯. পরীক্ষার আগের রাত + অনুশীলন … পৃ.১০

১ মেশিন লার্নিং ও এর তিন ধরন ★ প্রায় সবসময় আসে

সংজ্ঞা: **মেশিন লার্নিং (Machine Learning, ML)** হলো AI-এর সেই শাখা যেখানে system নিয়ম দিয়ে explicitly programmed না হয়ে **data থেকে pattern শেখে** এবং অভিজ্ঞতায় উন্নত হয়। AI ⊃ ML ⊃ Deep Learning।



ধরন	কী থেকে শেখে	অ্যালগরিদম	উদাহরণ
Supervised	labelled (x, y)	regression, SVM, tree, KNN	spam filter, fraud
Unsupervised	unlabelled x	K-means, PCA, Apriori	গ্রাহক segment
Reinforcement	reward সংকেত	Q-learning	AlphaGo, রোবট
Self-supervised	data থেকেই তৈরি লেবেল	next-token prediction	LLM pre-training

স্মৃতি-কৌশল: **শিক্ষক · অভিযাত্রী · খেলোয়াড়**: supervised-এর আছে *শিক্ষক* (লেবেল), unsupervised হলো *অভিযাত্রী* (নিজেই দল খুঁজে নেয়), reinforcement হলো গেমের *খেলোয়াড়* (স্কোর = reward)।

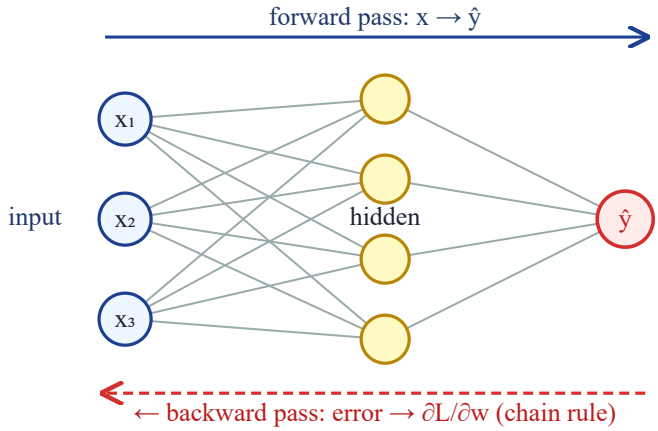
Transfer learning: বিশাল dataset-এ trained একটি **pre-trained model** নিয়ে ছোট, নির্দিষ্ট কাজের dataset-এ **fine-tune** করা। Data, সময় ও GPU খরচ বাঁচে। যেমন: BERT → **বাংলা sentiment analysis**-এর জন্য fine-tune; ImageNet CNN → X-ray classifier।

পরীক্ষার ফাঁদ: Classification ও regression = **supervised**; clustering = **unsupervised**। **K-means ≠ KNN**: K-means লেবেলহীন data-কে cluster করে; KNN লেবেলসহ প্রতিবেশী দেখে classify করে।

উদাহরণ: শ্রেণি নির্ণয়: (১) আয়তন থেকে বাড়ির দাম → supervised (regression); (২) আচরণ অনুযায়ী মোবাইল ব্যাংকিং গ্রাহকদের দলে ভাগ → unsupervised; (৩) গাড়ির সারি দেখে শিখে নেওয়া ট্রাফিক সিগন্যাল → reinforcement; (৪) আগের লেবেলসহ ঘটনা থেকে fraud শনাক্ত → supervised (classification)।

২ ANN, Backpropagation ও Gradient Descent ★ শীর্ষ ক্লাস্টার

ANN: জৈব নিউরন দ্বারা অনুপ্রাণিত একটি গাণিতিক মডেল: **input layer → hidden layer(s) → output layer**। প্রতিটি সংযোগে একটি **weight** থাকে; প্রতিটি নিউরন একটি **bias** যোগ করে ও **activation function** প্রয়োগ করে। Training = loss সর্বনিম্ন করে এমন weight খোঁজা।



একটি নিউরন (perceptron)

$z = \Sigma\, w_i x_i + b$

output = f(z)

update: $w \leftarrow w - \eta \cdot \partial L/\partial w$

η = learning rate

L = loss (MSE / cross-entropy)

১ **Forward pass**: input স্তরে স্তরে এগিয়ে prediction ŷ দেয়।

২ **Loss**: ŷ-কে আসল y-এর সঙ্গে তুলনা (MSE / cross-entropy)।

৩ **Backpropagation**: **chain rule** দিয়ে error পেছনে পাঠিয়ে প্রতিটি weight-এর $\partial L/\partial w$ বের করে।

৪ **Gradient descent**: gradient-এর বিপরীতে প্রতিটি weight একটু সরাও; বহু **epoch** ধরে চলে।

উদাহরণ: $x_1=1, x_2=0, w_1=0.5, w_2=0.3, b=0.1$, sigmoid। $z = 0.5\times1 + 0.3\times0 + 0.1 = \mathbf{0.6}$; $\sigma(0.6) = 1/(1+e^{-0.6}) = 1/(1+0.549) \approx \mathbf{0.646}$।

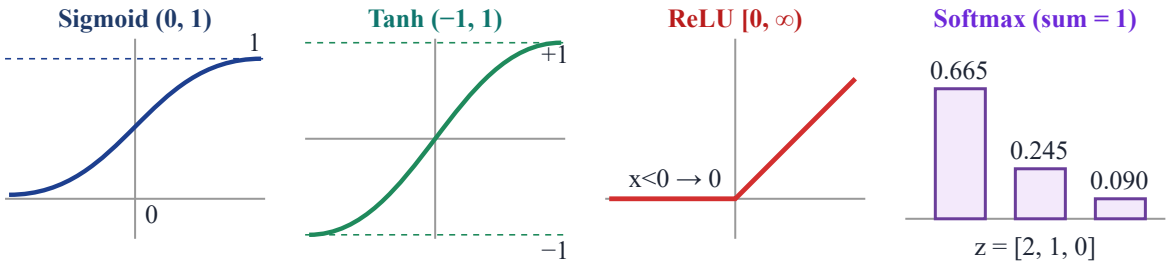
বিষয়	ANN	BNN (মস্তিষ্ক)
একক	কৃত্রিম নিউরন (গণিত)	জৈব নিউরন (~86 billion)
সংকেত	সংখ্যা, digital	electrochemical spike
শেখা	backpropagation weight বদলায়	synaptic plasticity (Hebbian)
গতি / শক্তি	দ্রুত, বেশি শক্তি (GPU)	ধীর নিউরন, ~20 W, ব্যাপক parallel

স্মৃতি-কৌশল: **F-L-B-U**: **F**orward · **L**oss · **B**ackward · **U**pdate। Backprop gradient *খুঁজে বের করে*; GD সেটা *ব্যবহার করে*। η খুব বড় → diverge; খুব ছোট → ধীর।

পরীক্ষার ফাঁদ: "কোন মডেল backpropagation ব্যবহার করে: MLP / CNN / RNN?" → **সবগুলো (All of the above)**।

৩ Activation Function ★ লিখিত প্রশ্নে প্রিয়

কেন দরকার: Activation function **non-linearity** যোগ করে। এটি না থাকলে প্রতিটি layer linear, ফলে পুরো deep net একটি linear map-এ পরিণত হয়: $W_2(W_1x) = (W_2W_1)x$, অর্থাৎ গভীরতার কোনো লাভ নেই। এটি output-কে কাজের পরিসরেও আনে (probability, ±1)।



Function	সূত্র	পরিসর	সেরা ব্যবহার	দুর্বলতা
Sigmoid σ	$1 / (1 + e^{-x})$	**(0, 1)**	binary output (probability)	vanishing gradient ($\sigma' \le 0.25$)
Tanh	$(e^{x} - e^{-x})/(e^{x} + e^{-x})$	**(−1, 1)**	hidden layer, RNN; zero-centred	এটিও saturate করে
ReLU	max(0, x)	[0, ∞)	hidden layer-এর default; দ্রুত	"dying ReLU" (0-তে আটকে)
Leaky ReLU	max(0.01x, x)	(−∞, ∞)	dying ReLU সারায়	বাড়তি hyper-parameter
Softmax	$e^{z_i} / \Sigma e^{z_j}$	(0, 1), Σ = 1	multiclass output layer	শুধু output layer-এ
Linear	f(x) = x	(−∞, ∞)	regression output	non-linearity নেই

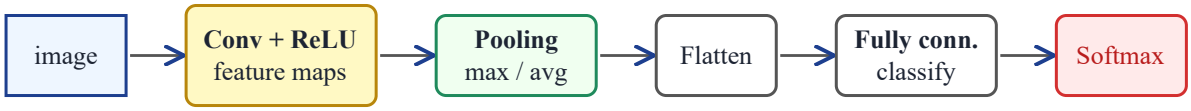
উদাহরণ: z = [2, 1, 0]-এর softmax: $e^2 = 7.389$, $e^1 = 2.718$, $e^0 = 1$, যোগফল = 11.107 → **[0.665, 0.245, 0.090]**, মোট = 1। ReLU(−3) = 0, ReLU(2.5) = 2.5; σ(0) = 0.5; tanh(0) = 0।

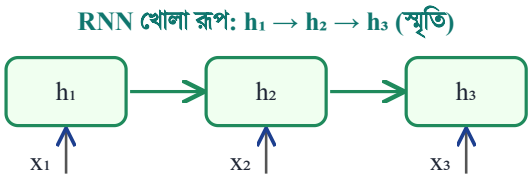
স্মৃতি-কৌশল: **S**igmoid = **S**ingle হ্যাঁ/না; **S**oftmax = **S**everal class; **T**anh = **T**wo-sided (±1); **R**eLU = **R**amp (ঢাল)।

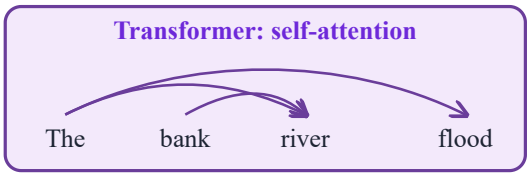
পরীক্ষার ফাঁদ: Sigmoid-এর পরিসর **(0, 1)**; (−1, 1) হলো tanh-এর। Deep net-এর hidden layer-এ **ReLU** বেশি চলে, কারণ x > 0 হলে এর gradient 1, তাই **vanishing gradient** সমস্যা অনেকটা এড়ায়।

৪ ডিপ লার্নিং: CNN · RNN · Transformer ★ MCQ-চুম্বক

ডিপ লার্নিং: **অনেকগুলো hidden layer**-যুক্ত ML, যা কাঁচা data (pixel, শব্দ, শব্দতরঙ্গ) থেকে নিজেই feature শেখে। বড় dataset ও GPU লাগে। Unstructured data-তে সবচেয়ে ভালো।







মডেল	Data	মূল ধারণা	ব্যবহার
CNN	ছবি, grid	shared filter input-এর ওপর সরে; pooling	মুখ/বস্তু শনাক্ত, X-ray
RNN	sequence, time-series	hidden state আগের ধাপের স্মৃতি বহন করে	পূর্বাভাস, speech
LSTM	দীর্ঘ sequence	৩টি gate: forget, input, output; vanishing gradient সারায়	শেয়ার-দর series, অনুবাদ
GRU	sequence	২টি gate: update, reset; হালকা LSTM	LSTM-এর মতোই
Transformer	text, ছবিও	সব position-এ একসঙ্গে self-attention; parallel; positional encoding	BERT, GPT, LLM

উদাহরণ: 32×32 ছবি, 5×5 filter, stride 1, padding নেই: output = (N − F + 2P)/S + 1 = (32 − 5 + 0)/1 + 1 = **28×28**; এরপর 2×2 max-pool → **14×14**।

স্মৃতি-কৌশল: **C**NN = **C**amera (ছবি); **R**NN = **R**emembers order (ক্রম মনে রাখে); **T**ransformer = পুরো **T**ext একসঙ্গে দেখে। Attention(Q,K,V) = softmax($QK^T/\sqrt{d_k}$)·V।

পরীক্ষার ফাঁদ: "Time-series-এর জন্য সেরা: CNN / RNN / DNN / ANN?" → **RNN** (অপশনে থাকলে LSTM)। NLP-তে Transformer RNN-কে সরিয়েছে, কারণ এটি token **parallel-এ** প্রক্রিয়া করে; BERT = encoder, GPT = decoder।

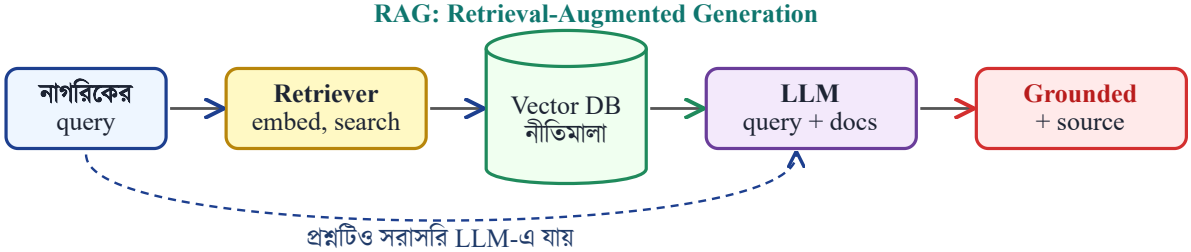
৫ LLM, RAG, Hallucination ও Prompting ★ দ্রুত বাড়ছে

LLM: **Large Language Model** হলো বিপুল text-এ trained Transformer-ভিত্তিক neural network, যা ভাষা বোঝে ও তৈরি করে। এটি **token** (শব্দাংশ) নিয়ে কাজ করে এবং বারবার **পরের token** অনুমান করে। উদাহরণ: GPT (OpenAI), Claude (Anthropic), Gemini (Google), LLaMA (Meta)। ব্যবহার: chatbot, সারাংশ, অনুবাদ, code।

১. **Pre-training**: web-আকারের text-এ self-supervised next-token prediction।
২. **Fine-tuning**: instruction / কাজভিত্তিক data।
৩. **Alignment**: মানুষের feedback (RLHF), যাতে উত্তর সহায়ক ও নিরাপদ হয়।

মূল শব্দ: **token** = text-এর একক; **context window** = একবারে সর্বোচ্চ কত token দেখে; **temperature** = এলোমেলোভাব (কম = কেন্দ্রিক); **embedding** = text-এর vector রূপ।

RAG: Retrieval-Augmented Generation



Hallucination: মডেল **সাবলীল, আত্মবিশ্বাসী কিন্তু ভুল** তথ্য তৈরি করে (ভুয়া উদ্ধৃতি, ভুল তারিখ)। কারণ: এটি সম্ভাব্য text অনুমান করে, নিজস্ব তথ্য-যাচাই নেই। প্রতিকার: **RAG**, যাচাই করা data-তে fine-tuning, উৎস উল্লেখ, confidence flag, গুরুত্বপূর্ণ উত্তরে মানুষের পর্যালোচনা।

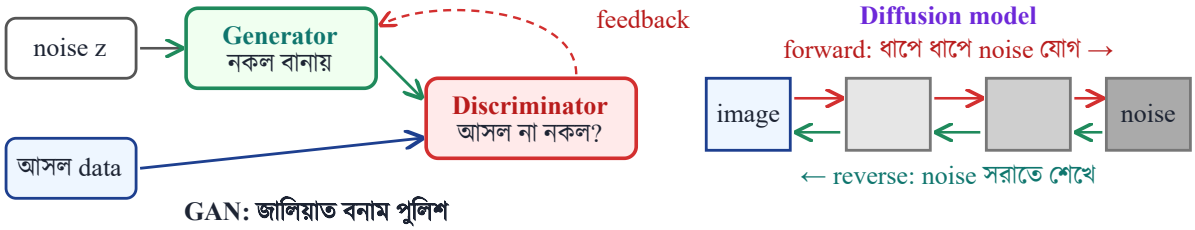
Prompting কৌশল	কী দিতে হয়	উদাহরণ
Zero-shot	শুধু নির্দেশনা	"অভিযোগটি কর / ভূমি / অন্যান্য হিসেবে ভাগ করো।"
Few-shot	আগে কয়েকটি সমাধান-করা উদাহরণ	৩টি লেবেলসহ অভিযোগ, তারপর নতুনটি
Chain-of-thought	ধাপে ধাপে যুক্তি চাওয়া	"VAT ধাপে ধাপে হিসাব করো।"
Role prompting	একটি ভূমিকা দেওয়া	"তুমি NBR help-desk কর্মকর্তা…"

স্মৃতি-কৌশল: সাধারণ LLM = **বই-বন্ধ পরীক্ষা** (মুখস্থ থেকে লেখে, বানিয়েও ফেলতে পারে)। RAG = **বই-খোলা পরীক্ষা** (আগে পাতা দেখে, তারপর লেখে)।

পরীক্ষার ফাঁদ: RAG মডেলকে নতুন করে train **করে না** (fine-tuning weight বদলায়; RAG শুধু context যোগ করে), এবং hallucination **কমায়, দূর করে না**। Hallucination pattern-ভিত্তিক generation-এর স্বাভাবিক ফল, coding bug নয়।

৬ Generative AI: GAN ও Diffusion; XAI ★ ব্যাংক লিখিত

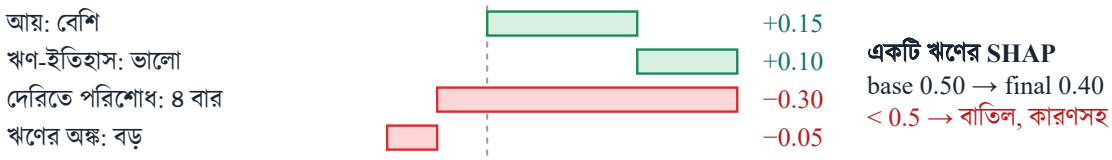
Generative AI: যে AI **নতুন content তৈরি করে**: text (LLM), ছবি (Stable Diffusion, DALL-E, Midjourney), audio, video, code, synthetic data। **Discriminative** মডেল P(y | x) শিখে data-কে লেবেল দেয়; **generative** মডেল P(x) শিখে নতুন নমুনা তৈরি করে।



GAN: জালিয়াত বনাম পুলিশ

মডেল	কীভাবে তৈরি করে	পরিচিত যে কাজে
GAN	Generator বনাম Discriminator, প্রতিযোগিতায় training	মুখের ছবি, deepfake
Diffusion	noise থেকে শুরু, ধাপে ধাপে denoise	Stable Diffusion, DALL-E
VAE	latent space-এ encode, সেখান থেকে decode	মসৃণ রূপভেদ
LLM	Transformer, next-token prediction	text, code, chat

XAI: **Explainable AI** দেখায় মডেল **কেন** একটি output দিল: ঋণ, রোগনির্ণয়, সরকারি সেবা ও audit-এ জরুরি। **LIME** (Local Interpretable Model-agnostic Explanations) একটি input একটু বদলে বদলে তার চারপাশে সরল local মডেল বসায়। **SHAP** (SHapley Additive exPlanations) game theory-র Shapley value দিয়ে প্রতিটি feature-এর ধনাত্মক/ঋণাত্মক অবদান দেয়। **Saliency map / Grad-CAM** ছবির গুরুত্বপূর্ণ অংশ দেখায়।

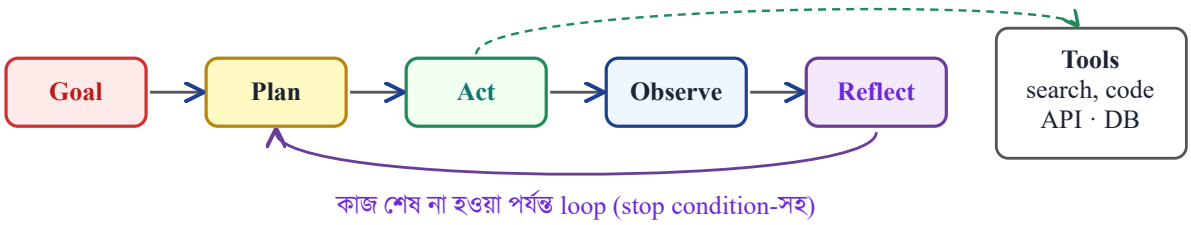


স্মৃতি-কৌশল: **GAN = জালিয়াত বনাম পুলিশ**। LIME = **L**ocal; **SH**AP = **SH**apley। যাচাই: 0.50 + 0.15 + 0.10 − 0.30 − 0.05 = 0.40।

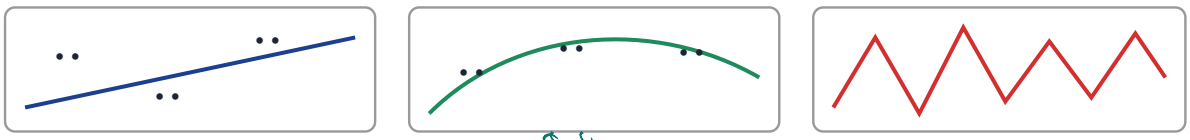
পরীক্ষার ফাঁদ: **Discriminator** আসল-নকল বিচার করে; Generator কখনো আসল data দেখে না, শুধু Discriminator-এর feedback থেকে শেখে। Generative AI **শুধু chatbot নয়**।

৭ Agentic AI বনাম Chatbot; Over- ও Underfitting ★ BUET-এর প্রিয়

Agentic AI: যে AI system একটি **লক্ষ্য (goal)** নিয়ে ধাপ পরিকল্পনা করে, **tool ব্যবহার করে** (web search, code execution, API, database), ফল পর্যবেক্ষণ করে, স্মৃতি রাখে এবং নিজেকে শুধরে লক্ষ্যে পৌঁছায়, মানুষের সামান্য সাহায্যে। মূল: reasoning engine হিসেবে LLM + tool + memory + orchestration loop।



মাত্রা	প্রচলিত chatbot	Agentic AI
যুক্তি	rule / script, FAQ মেলানো	LLM reasoning + পরিকল্পনা
পালা	একটি প্রশ্ন → একটি উত্তর	**বহু-ধাপ**, লক্ষ্যমুখী
স্মৃতি	session-এর বাইরে নেই	স্বল্প + দীর্ঘমেয়াদি memory
Tool	নেই	search, code, API, file
নিজে শোধরানো	না	হ্যাঁ: reflect, retry
ঝুঁকি	ভুল বাঁধা উত্তর	hallucination chain, tool-এর অপব্যবহার, অসীম loop



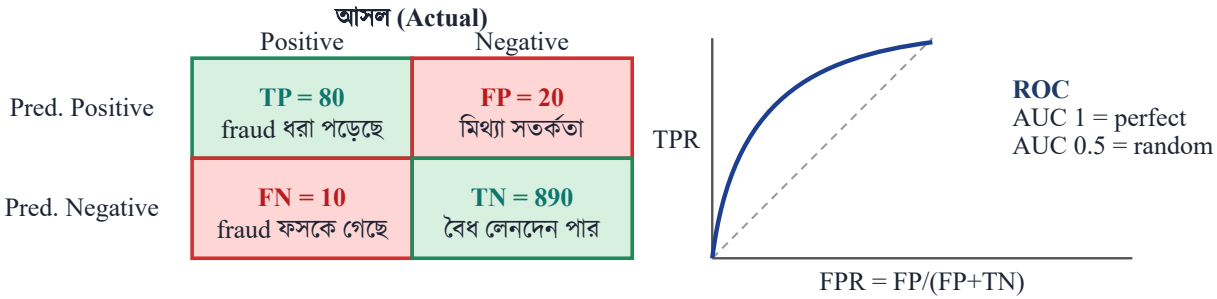
	Train error	Test error	প্রতিকার
Overfitting	খুব কম	বেশি	বেশি data, L1/L2 regularisation, dropout, early stopping, cross-validation, augmentation, সরল মডেল
Underfitting	বেশি	বেশি	বড় মডেল, ভালো feature, বেশিক্ষণ training, কম regularisation

স্মৃতি-কৌশল: Overfit = যে ছাত্র **গত বছরের গাইড মুখস্থ** করে নতুন প্রশ্নে ফেল করে; underfit = যে ছাত্র **পড়েইনি**, তাই দুটোতেই ফেল।

পরীক্ষার ফাঁদ: Overfitting = **high variance, low bias**; underfitting = **high bias, low variance**। Dropout overfitting ঠেকায়, underfitting কখনো নয়।

৮ Confusion Matrix, Precision, Recall, F1 ★ গাণিতিক

Confusion matrix: অনুমিত বনাম আসল class-এর একটি সারণি। **TP** = positive-কে positive বলা; **FP** = negative-কে ভুলে positive বলা (মিথ্যা সতর্কতা, Type I); **FN** = positive ধরা না পড়া (Type II); **TN** = negative-কে ঠিকভাবে negative বলা।



মেট্রিক	সূত্র	যে প্রশ্নের উত্তর দেয়
Accuracy	(TP + TN) / total	কতগুলো অনুমান ঠিক হলো?
Precision	TP / (TP + FP)	যাদের positive বলা হলো, তাদের কতজন সত্যি positive?
Recall (sensitivity, TPR)	TP / (TP + FN)	আসল positive-দের কতজনকে ধরা গেল?
Specificity (TNR)	TN / (TN + FP)	আসল negative-দের কতজনকে ঠিক ছাড়া হলো?
F1-score	2PR / (P + R)	harmonic mean: P ও R-এর ভারসাম্য

উদাহরণ: Fraud মডেল, ১০০০টি লেনদেন: TP = 80, FP = 20, FN = 10, TN = 890।

- Accuracy = (80 + 890)/1000 = **0.97**
- Precision = 80/(80 + 20) = **0.80**; Recall = 80/(80 + 10) = 80/90 = **0.889**
- F1 = 2 × 0.80 × 0.889 / (0.80 + 0.889) = 1.422 / 1.689 ≈ **0.842**; Specificity = 890/910 ≈ 0.978

স্মৃতি-কৌশল: **P**recision দেখে **P**redicted-positive সারি; **R**ecall দেখে **R**eal-positive কলাম। মিথ্যা সতর্কতা ব্যয়বহুল হলে precision জরুরি (spam filter); কেউ ফসকে গেলে ক্ষতি বেশি হলে recall জরুরি (ক্যান্সার, fraud)।

পরীক্ষার ফাঁদ: **Accuracy paradox**: একই data-তে যে মডেল সবসময় "fraud নয়" বলে, তার TP = 0, FN = 90, TN = 910 → accuracy 91% কিন্তু recall **0**। ভারসাম্যহীন data-তে শুধু accuracy নয়, precision, recall, F1 বা AUC দেখাও।

✓ পরীক্ষার আগের রাতের শিট ও অনুশীলনী MCQ

তথ্য-শিট:

- Supervised: লেবেল · unsup.: cluster · RL: reward
- নিউরন: $z = \Sigma wx + b$, $out = f(z)$
- Backprop (chain rule) → GD: $w \leftarrow w - \eta \partial L/\partial w$
- Sigmoid (0,1) · tanh (−1,1) · ReLU [0,∞)
- Softmax = multiclass, যোগফল 1
- CNN ছবি · RNN/LSTM series · Transformer text
- LLM = Transformer, next-token
- RAG = doc খোঁজা → LLM
- GAN = Generator বনাম Discriminator
- XAI: LIME (local), SHAP (Shapley)
- Overfit: dropout, L1/L2, বেশি data
- $P = TP/(TP+FP)$ · $R = TP/(TP+FN)$
- $F1 = 2PR/(P+R)$

১. Time-series data-র জন্য সবচেয়ে উপযুক্ত?

ক) CNN খ) RNN
গ) DNN ঘ) ANN

২. কোনটি backpropagation দিয়ে train হয়?

ক) MLP খ) CNN
গ) RNN ঘ) সবগুলো

৩. Sigmoid-এর output-এর পরিসর:

ক) (−1, 1) খ) [0, ∞)
গ) (0, 1) ঘ) (−∞, ∞)

৪. GAN-এ আসল-নকল বিচার করে:

ক) Discriminator খ) Generator
গ) Encoder ঘ) Retriever

৫. TP = 80, FP = 20, FN = 10। Precision =

ক) 0.889 খ) 0.842
গ) 0.97 ঘ) 0.80

৬. আগে document খুঁজে, পরে উত্তর তৈরি:

ক) Fine-tuning খ) RAG
গ) Dropout ঘ) Pooling

৭. লেবেল ছাড়া গ্রাহকদের দলে ভাগ করা:

ক) supervised খ) reinforcement
গ) unsupervised ঘ) transfer

৮. SHAP-এর ভিত্তি:

ক) Shapley value খ) gradient descent
গ) max pooling ঘ) dropout

৯. ১০-class classifier-এর output activation:

ক) ReLU খ) Tanh
গ) Sigmoid ঘ) Softmax

১০. Training error কম, test error বেশি:

ক) underfitting খ) ঠিকঠাক fit
গ) overfitting ঘ) high bias

উত্তরমালা → ১-খ · ২-ঘ · ৩-গ · ৪-ক · ৫-ঘ · ৬-খ · ৭-গ · ৮-ক · ৯-ঘ · ১০-গ

লিখিত প্রশ্ন: সরকারি নাগরিক-সেবা chatbot-কে Generative AI কীভাবে চালাতে পারে, এবং XAI কীভাবে একে স্বচ্ছ ও জবাবদিহিমূলক রাখে? ১০ নম্বর

১. **GenAI কেন্দ্র:** LLM বাংলা/ইংরেজি প্রশ্ন বোঝে, উত্তর ও সারাংশ লেখে। ২
২. **RAG:** query → আইন ও পরিপত্রের vector DB → শীর্ষ doc + query → LLM → উৎসসহ grounded উত্তর; hallucination কম, retraining লাগে না। ৩
৩. **XAI:** উৎস দেখানো; LIME/SHAP দেখায় কোন শব্দ সিদ্ধান্তে প্রভাব ফেলেছে; কম confidence → কর্মকর্তার কাছে। ৩
৪. **জবাবদিহি ও ঝুঁকি:** audit log, গুরুত্বপূর্ণ উত্তরে মানুষের পর্যালোচনা, bias ও গোপনীয়তা যাচাই। ২

পরীক্ষার আগে ✓: activation-এর পরিসর · CNN/RNN/Transformer · P, R, F1 · RAG · GAN · agent সারণি