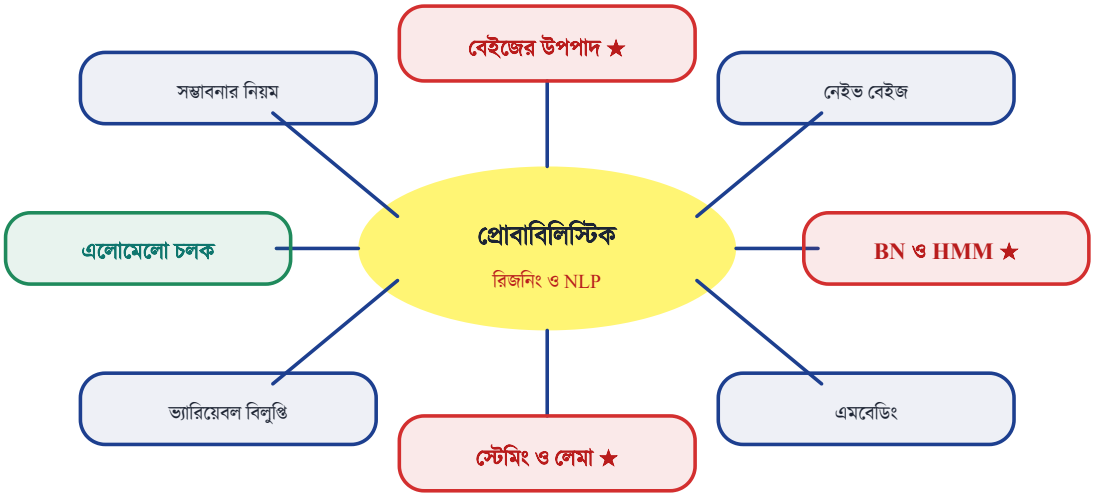
প্রোবাবিলিস্টিক রিজনিং ও NLP

বেইজ · নেইভ বেইজ · BN DAG · HMM ও ভিটার্বি · স্টেমিং · এমবেডিং: ১২ পাতায়



↑ পুরো টপিক এক পাতায়: লাল = বেশি আসে, সবুজ = যে একটি ভিত্তির ওপর সব দাঁড়িয়ে

সিলেবাসের যে অংশ

আর্টিফিসিয়াল ইন্টেলিজেন্সের সিলেবাসে দশটি লাইন। এই নোটবুক ঠিক দুটি নেয়: "**প্রোবাবিলিস্টিক রিজনিং**" এবং "**প্রাকৃতিক ভাষা প্রক্রিয়াকরণ**"। জ্ঞান উপস্থাপন, যুক্তিবিদ্যা, অনুসন্ধান, এক্সপার্ট সিস্টেম ও মেশিন লার্নিং-এর নোট আলাদা।

হাই-ইল্ড তালিকা

① $P(A|B) = P(A \wedge B)/P(B)$
② $P(H|E) = P(E|H)P(H)/P(E)$
③ $P(C|x_1 \ldots x_n) \propto P(C)\prod_i P(x_i|C)$
④ BN: $\prod_i P(x_i|Pa(x_i))$
⑤ নয়জি-ওআর: $1 - \prod_i (1-p_i)$
⑥ $\alpha_t(j) = b_j(o_t)\Sigma_i a_{ij}\alpha_{t-1}(i)$
⑦ স্টেমিং কাটে, লেমা অভিধানে খোঁজে
⑧ পেরপ্লেক্সিটি = exp(NLL)

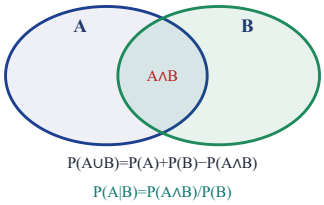
সংকেত: **হলুদ** = মূল শব্দ · **লাল বৃত্ত** = অবশ্যই মুখস্থ · **বেগুনি বক্স** = মনে রাখার কৌশল · **লাল বক্স** = পরীক্ষার ফাঁদ · **সবুজ** = সমাধানকৃত উদাহরণ

সূচিপত্র

✓ অনিশ্চয়তা ও সম্ভাবনার নিয়ম … পৃ. ২
✓ শর্তসম্ভাবনা ও বেইজের উপপাদ … পৃ. ২
✓ নেইভ বেইজ শ্রেণিবিন্যাস … পৃ. ৩
✓ বেইজিয়ান নেটওয়ার্ক: DAG ও CPT … পৃ. ৪
✓ ভ্যারিয়েবল বিলুপ্তি, নয়জি-ওআর, D-S … পৃ. ৫
✓ মার্কভ শৃঙ্খল ও গোপন মার্কভ মডেল … পৃ. ৬
✓ ফরওয়ার্ড, ব্যাকওয়ার্ড ও ভিটার্বি … পৃ. ৭
✓ NLP পত্র ১–৩ … পৃ. ৮–১০ · রাতের পাতা পৃ. ১১ · অনুশীলন পৃ. ১২

১ অনিশ্চয়তা, সম্ভাবনার নিয়ম ও বেইজ

সংজ্ঞা: **প্রোবাবিলিস্টিক রিজনিং** (probabilistic reasoning) হলো অনিশ্চয়তার অধীনে সিদ্ধান্ত নেওয়ার পদ্ধতি, যেখানে সম্ভাবতা দিয়ে বলা হয় কোন বিকল্পে কতটা বিশ্বাস করা উচিত। **এলোমেলো চলক** (random variable) হলো এমন রাশি যা পর্যবেক্ষণের আগে জানা নেই (বৃষ্টি = হ্যাঁ/না): **বিচ্ছিন্ন** রাশির মান সসীম, **অবিচ্ছিন্ন** রাশির মান একটি অংশ। AI-র এটি দরকার, কারণ উপকরণের তথ্য নোয়েজি ও প্রমাণ অসম্পূর্ণ।



সম্ভাবতার পুরো ভাষাই দুই বৃত্তে

পরিভাষা	অর্থ
এলোমেলো চলক	বৃষ্টি = হ্যাঁ বা না
সম্ভাবনা	$P(A) \in [0, 1]$
যৌগ সম্ভাবনা	$P(A \wedge B)$, দুটো একসাথে
শর্তসম্ভাবনা	$\mathbf{P(A\|B)=P(A \wedge B)/P(B)}$
প্রান্তিক সম্ভাবনা	$P(A) = \Sigma_B P(A \wedge B)$
স্বাধীনতা	$P(A \wedge B) = P(A)P(B)$

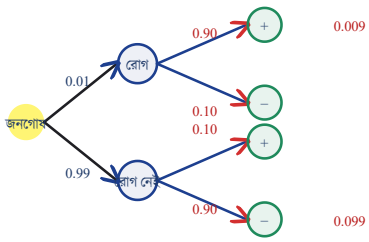
যে নিয়মগুলো আঙুলের ডগায় থাকতে হবে: **স্বীকার্য (কোলমোগরোভ, ১৯৩৩)**: $0 \le P(A) \le 1$, $P(\Omega) = 1$, পৃথক A, B-এর জন্য $P(A \cup B) = P(A)+P(B)$। **পরিপূরক**: $P(A') = 1 - P(A)$। **গাণিতিক শৃঙ্খল**: $P(A \wedge B) = P(A)P(B|A)$। **মোট সম্ভাবনা**: $P(B) = \Sigma_i P(B|h_i)P(h_i)$।

বেইজের উপপাদ (Bayes' Theorem, ১৭৬৩):

$$\mathbf{P(H|E) = P(E|H) \cdot P(H)/P(E)}$$

সমতুপরীয়ভাবে $\mathbf{P(E|H)P(H) = P(H|E)P(E)}$।

অনুপাত আকারে: **পরবর্তী অনুপাত = পূর্ব অনুপাত × সম্ভাবনা অনুপাত**। বেইজের নিবন্ধ মৃত্যুর পর প্রকাশিত হয়; লাপ্লাস (১৮১৩) এই উপপাদের প্রথম ছোট কার্যকর ব্যবহার দেখান।



প্রতিটি শাখা = পিতা × প্রান্তের সংখ্যা

পরীক্ষার ফাঁদ: চারটি নামের অর্থ স্থির: **পূর্ব** $P(H)$ = প্রমাণের আগে; **সম্ভাবনা** $P(E|H)$ = H সত্য হলে প্রমাণ; **সাক্ষ্য** $P(E)$ = স্বাভাবিকীকরণ পদ; **পরবর্তী** $P(H|E)$ = পরে। "লাইকেলিহুড" ও "পোস্টেরিয়র" গুলিয়ে ফেলা এই অংশের সবচেয়ে বেশি ভুল উত্তর।

মনে রাখার কৌশল: **"ভিত্তি ঢোকে, ফল বেরোয়।"** পূর্বকে সম্ভাবনা দিয়ে গুণ করে সাক্ষ্য দিয়ে ভাগ করো। অনুপাত আকারে **ভাগ করতেই হয় না**; প্রমাণ কেবল যাতে উত্তরগুলোর যোগ ১ হয়।

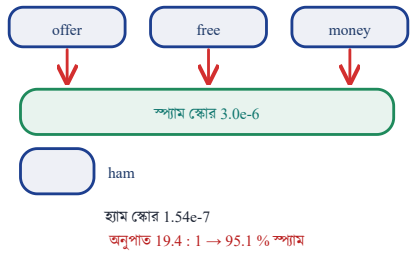
সমাধানকৃত উদাহরণ ১ ✍ বেস-রেট ফাঁদ: রোগ ১ % মানুষের; পরীক্ষা ৯০ % সংবেদনশীল এবং ১০ % ভুল ইতিবাচক। $P(D|+) = (0.9 \times 0.01)/[(0.9 \times 0.01) + (0.1 \times 0.99)] = 0.009/0.108 = \mathbf{0.083}$। পূর্ব সম্ভাবনা ছোট হলে চমৎকার পরীক্ষাও ছোট পরবর্তী সম্ভাবনা দেয় — সাক্ষ্য দিয়ে ভাগ করা কখনো বাদ দেওয়া যায় না।

সমাধানকৃত উদাহরণ ২ ✍️ অনুপাত আকার: পূর্ব অনুপাত = 0.01/0.99 = 1/99; সম্ভাবনা অনুপাত = 0.9/0.1 = 9; পরবর্তী অনুপাত = 9/99 = 1/11, তাই P = (1/11)/(1 + 1/11) = **1/12 = 0.083** ✓ — একই উত্তর, কোথাও ভাগ নয়। ভগ্নাংশ জটিল হলে অনুপাত আকারই ধরো।

২ নেইভ বেইজ শ্রেণিবিন্যাস

সংজ্ঞা: নেইভ বেইজ শ্রেণিবিন্যাসকারী (naive Bayes classifier) প্রতিটি বৈশিষ্ট্যের জন্য একটি শর্তসম্ভাবনা গুণ করে সেই class-কে বেছে নেয় যার পরবর্তী সম্ভাবনা সবচেয়ে বেশি। স্বাভাবিকীকরণ P(x) সব class-এ এক, তাই বাদ পড়ে যায়:

$$\hat{C} = \text{argmax}_C\ P(C)\cdot P(x_1|C)\cdot P(x_2|C)\cdots P(x_n|C)$$



প্রতি class-এর একটি স্কোর, তারপর তুলনা

অংশ	অর্থ
$P(C)$	পূর্ব — class-এর প্রচুতি
$P(x_i\|C)$	C-এর ভেতরে x_i-এর সম্ভাবনা
$\prod_i P(x_i\|C)$	**নেইভ ধাপ**
argmax	সর্বোচ্চ স্কোরধারী class

তিন রকম: মাল্টিনোমিয়াল (শব্দের গণনা): $P(w|C) = \text{count}(w,C)/\Sigma\ \text{count}(\cdot,C)$
বার্নৌলি (শব্দ আছে/নেই)
গাউসিয়ান (বাস্তব বৈশিষ্ট্য): $P(x_i|C) = \mathcal{N}(x_i;\ \mu,\ \sigma^2)$

পরীক্ষার ফাঁদ: "নেইভ" মানে সমান পূর্ব, সমান উপাদান বা রেখা-বিভাজনীয়তা **নয়**। এর একমাত্র অর্থ $P(x_1,\ldots,x_n|C) = \prod_i P(x_i|C)$ — বাস্তবে প্রায় কখনো মিলে না, তবুও ভালো কাজ করে, তাই স্প্যাম ফিল্টারের ভিত্তি।

সমাধানকৃত উদাহরণ ✍️: ১০০টি স্প্যাম ও ২০০টি হ্যাম মেইল। স্প্যামে ২০০০ শব্দ (offer 40, free 60, money 30); হ্যামে ১২০০ (offer 5, free 10, money 8)। **স্প্যাম** = (1/3)(40/2000)(60/2000)(30/2000) = $\mathbf{3.0\times10^{-6}}$ · **হ্যাম** = (2/3)(5/1200)(10/1200)(8/1200) = $\mathbf{1.54\times10^{-7}}$ · অনুপাত 19.4, তাই P(spam) = **95.1 %**।

মনে রাখার কৌশল: **"প্রতি বৈশিষ্ট্যের সম্ভাবনা গুণোগন, তারপর পূর্ব একবার যোগ।"** আর সবসময় **লগ স্পেসে** হিসাব করো — ১০ ০০০ বৈশিষ্ট্য হলে এটাই একমাত্র উপায়, যাতে সংখ্যা শূন্যে না নামে।

শূন্য-বার্টনার সমস্যা: class C-তে কখনো দেখা হয়নি এমন শব্দের $P(w|C) = 0$, আর একটি শূন্যই গুণশীলক মারে। সমাধান **অ্যাড-ওয়ান স্মুদিং**: (count+1)/(total+|V|) — ১২০০ শব্দে |V| = 5000 হলে 0 বার শব্দের জন্য **1/6200**।

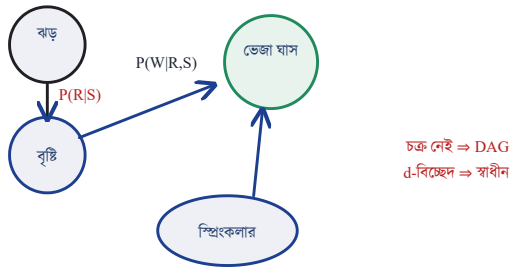
লাপ্লাসের ধারা সম্প্রসারণ সূত্র: দশটি চল এলে পরেরটির সম্ভাবনা (10+1)/(10+2) = **11/12 = 0.917** — একই হিসাব; কখনো গণনার শূন্যকে সম্ভাবনার শূন্য বানিও না।

অতি-স্মুদিং, ও NB-এর কাজ: মডেল সমতল করে দিলে কম ব্যবহৃত শব্দের সংকেতও ধ্বংস হয়। ভারসাম্যহীন লেখায় **কমপ্লিমেন্ট নেইভ বেইজ** বা **বার্নৌলি** ভালো। MNB বৈশিষ্ট্যের সরলরৈখক, তাই এক পাসে প্রশিক্ষণ — তাই স্প্যাম ফিল্টারে বেঁচে আছে।

প্রতিদিনের কাজ: স্প্যাম ফিল্টার · সেন্টিমেন্ট বিশ্লেষণ · নামচিহ্নিত সত্ত্ব শনাক্তকরণ · সংবাদ শ্রেণিবিন্যাস · ইমেইল ট্রায়াজ · রিভিউ রেটিং · লেখা থেকে মেডিকেল কোডিং। "নেইভ" মানে কেবল **class জানা থাকলে বৈশিষ্ট্যগুলো স্বাধীন** — কখনো সমান পূর্ব নয়, কখনো সমান উপাদান নয়।

৩ বেইজিয়ান নেটওয়ার্ক: DAG, CPT, গুণফল

সংজ্ঞা: **বেইজিয়ান নেটওয়ার্ক** (belief network) হলো এমন একটি নির্দেশিত অ্যাসাইক্লিক গ্রাফ (DAG) যার node গুলো এলোমেলো চলক এবং $X \to Y$ তীরের অর্থ "X হলো Y-এর **সরাসরি কারণ**"। প্রতিটি node-এ থাকে **CPT** (শর্তসম্ভাবনা সারণি) **P(node | পিতা বা পিতারা)**, আর পিতাহীন node-এ মার্জিনাল। পুরো যৌগ বিতরণ লেখা হয় $\mathbf{P(x_1,\ldots,x_n) = \prod_i P(x_i \mid Pa(x_i))}$ — 2^n ঘরের একটি বড় টেবিলের বদলে **n** ছোট টেবিল।



দুটি স্বাধীন কারণ, একটি প্রভাব

গ্রাফ যা বলে	নিয়ম
মূল node	মার্জিনাল P(X) রাখে
সন্তান node	P(সন্তান | পিতা) রাখে
স্থানীয় মার্কভ	পিতা জানলে নিজসংক্ষেপ থেকে **স্বাধীন**
d-বিচ্ছেদ	পথ বন্ধ ⇒ স্বাধীন
কেন DAG	চক্রে কোনো ক্রম থাকে না

ভেজা ঘাসের CPT — প্রতি পিতাসেটের জন্য এক সারি	P(W = হ্যাঁ | বৃষ্টি, স্প্রিংকলার চালু)	P(W = হ্যাঁ | বৃষ্টি, বন্ধ)	P(W = হ্যাঁ | বৃষ্টি নেই, চালু)	P(W = হ্যাঁ | বৃষ্টি নেই, বন্ধ)
সম্ভাবনা	0.90	0.80	0.40	0.10

সমাধানকৃত উদাহরণ ✍️ প্রান্তিক করে তারপর শর্তাধীন: P(Rain) = 0.30, P(S=on|Rain) = 0.10, P(S=on|¬Rain) = 0.50 নিলে: $P(W=yes) = \Sigma_{r,s} P(r)P(s|r)P(W|r,s) = 0.30[0.10(0.90)+0.90(0.80)] + 0.70[0.50(0.40)+0.50(0.10)] = 0.30(0.86) + 0.70(0.25) = \mathbf{0.418}$। · P(Rain|yes) = 0.243/0.418 = **0.581** — ভেজা ঘাস পূর্বসম্ভাবনা প্রায় তিন গুণ করে। P(Sprinkler|yes) = 0.167/0.418 = 0.399।

মনে রাখার কৌশল: "BN **প্রতি পিতাসেটের জন্য একটি সারি** রাখে, পুরো টেবিল কখনো নয়।" গুণফলীকরণ হলো গাণিতিক শৃঙ্খল ও প্রতি node-এ মার্কভ অনুমান: **ফ্যাক্টরগুলো গুণো, তারপর যা ঠিক করা যায়নি তার ওপর Σ করো**।

পরীক্ষার ফাঁদ: (i) BN একটি **DAG**: চক্র হলে node নিজেই পূর্বপুরুষ হয়, তাই ক্রম ও বৈধ CPT দুটোই অসম্ভব। (ii) তীর মানে সরাসরি নির্ভরশীলতা, **প্রমাণিত কারণ নয়**। (iii) দুটি **সংঘর্ষক** $A \to C \leftarrow B$ সরাসরি স্বাধীন, কিন্তু C পর্যবেক্ষণ করলে নির্ভরশীল হয়ে যায়।

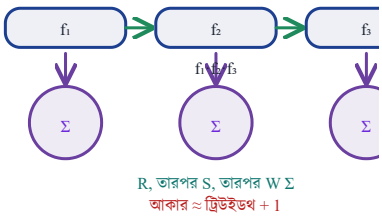
প্যারামিটার শেখা: **MLE**: P(data | θ) সর্বাধিক করে এমন θ বেছে নাও — বার্নৌলির ক্ষেত্রে $\hat{p} = 7/20 = 0.35$। **EM**: **E**-ধাপে গোপন লেবেলের প্রত্যাশা, **M**-ধাপে θ পুনরায় মাপা; সম্ভাবনা কখনো কমে না। EM দিয়ে মিশ্রণ মডেল ও HMM-এর প্যারামিটার প্রশিক্ষণ হয়।

প্রশ্নের উত্তর তিনভাবে: **সম্পূর্ণ গণনা** — CPT গুণে প্রতিটি গোপন চলকের ওপর Σ; দশটি চলক পর্যন্ত ঠিক আছে।
ভ্যারিয়েবল বিলুপ্তি — একই যোগ, একবারে একটি চলক (পরের পাতা)।
নমুনায়ন — গাছ-প্রস্থ বেশি হলে importance sampling বা MCMC; আনুমানিক, কিন্তু বড় হয়।

৪ অনুমান: ভ্যারিয়েবল বিলুপ্তি, নয়জি-ওআর, D-S

সংজ্ঞা: BN-এ সঠিক অনুমান মানে গোপন চলকের প্রতিটি বিন্যাসের ওপর Σ — তিনটি চলকে ভালো, তিনশো চলকে আর আদৌ হয় না। **ভ্যারিয়েবল ইলিমিনেশন** (variable elimination) একই যোগ **একবারে একটি চলক** করে: যে ফ্যাক্টরগুলোতে চলকটি আছে তা গুণো, তারপর চলকটি Σ করে বাদ দাও। খরচ হলো সবচেয়ে বড় মধ্যবর্তী ফ্যাক্টরের আকার, মোটামুটি **ট্রিউইডথ + 1** চলক — তাই বিলুপ্তির ক্রমই আসলে বেছে নেওয়া হয়।

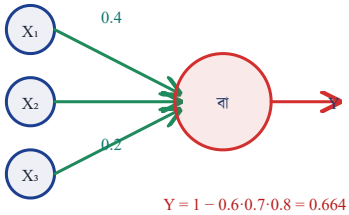
সমাধানকৃত উদাহরণ ✍️ আগে বৃষ্টি বিলুপ্তি: $f_1 = P(R)$, $f_2 = P(S|R)$, $f_3 = P(W|R,S)$। f_1 ও f_2 গুণো (দুটোতেই R আছে), তারপর $\Sigma_R\, P(R)P(S|R) = P(S) = 0.30(0.10) + 0.70(0.50) = \mathbf{0.38}$। ফ্যাক্টরটি এখন কেবল S-এর কথা বলে, তাই পরের গুণফল খুব ছোট। R **সবার শেষে** বিলুপ্ত করলে (R, S, W)-এর ফ্যাক্টর থেকে যায় — উত্তর এক, খরচ অনেক।



আগে গুণো, তারপর Σ করে বাদ দাও

নয়জি-ওআর — সংক্ষিপ্ত কারণ মডেল: একাধিক স্বাধীন কারণের প্রভাবের জন্য একটিও যথেষ্ট: $\mathbf{P(Y|X_1 \ldots X_n) = 1 - \prod_i (1 - P(Y|X_i = 1, \text{বাকিগুলো } 0))}$। 0.4 ও 0.3 ও 0.2 দিলে $1 - 0.6 \cdot 0.7 \cdot 0.8 = \mathbf{0.664}$, কখনোই সরল যোগ 0.9 নয়। এতে 2^n-এর বদলে মাত্র **n** প্যারামিটার, তাই নির্ণয়ের BN node-এ এটি ব্যবহৃত হয়।

ডেম্পস্টার-শেফার — অজ্ঞতার কথা বলা: m(A) বিশ্বাসটি একটি বিন্দুর বদলে একটি **ফোকাল উপাদানের** (set) ওপর দেওয়া হয়। **বন্ধ-জগত** অনুমানে $\mathbf{m(\emptyset) = 0}$, এবং প্রতিটি সম্ভাবনা একটি বন্ধনে থাকে: $\mathbf{Bel(A) = \Sigma_{B \subseteq A}\, m(B) \le P(A) \le \Sigma_{B \cap A \neq \emptyset}\, m(B) = Pl(A)}$। ডেম্পস্টারের সংযোজনী নিয়ম দুই উৎস মেলায় এবং দ্বন্দ্ব $k = \Sigma_{B \cap C = \emptyset}\, m_1(B)m_2(C)$ দিয়ে স্বাভাবিকীকরণ করে।



একটি কারণই Y চালু করতে যথেষ্ট

পরীক্ষার ফাঁদ: বেইজ ধরে নেয় **একটিই সত্য মান** যার সম্ভাবনাগুলোর যোগ ১, আর তালিকাভুক্ত নয় এমন ঘটনা অসম্ভব; ডেম্পস্টার-শেফার **অজ্ঞতা** মেনে নেয়, তাই শুধু **বন্ধন** দিতে পারে। Bel ≤ Pl, উল্টো কখনো নয়। দুই সেন্সর {s}-এ 0.6 ও {s, f}-এ 0.4 দিলে Bel(s) = **0.84** ও Pl(s) = **1.00**।

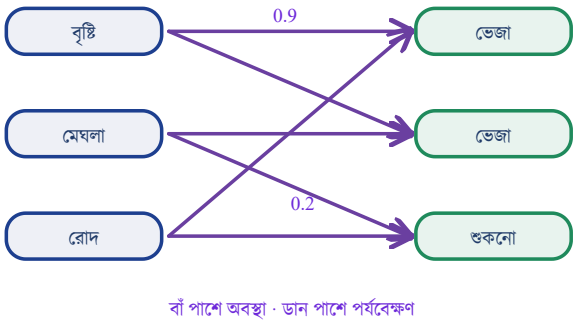
মনে রাখার কৌশল: সাক্ষ্য মেলানোর তিনটি রূপ, তিনটি আকৃতি: **Σ** = চলক Σ করে বাদ দেওয়া (ইলিমিনেশন), **∏(1−p)** = নয়জি-ওআর, **m(∅)=0 ও একটি বন্ধন** = ডেম্পস্টার-শেফার। সব ক্ষেত্রে একই নীতি: **আগে গুণো, পরে স্বাভাবিকীকরণ করো**।

IT সংযোগ: ভ্যারিয়েবল ইলিমিনেশন আসলে ডেটাবেসের join-ক্রম: **β-join**-এর শৃঙ্খল। ফ্যাক্টর গুণো = সম্পর্ক জোড়া লাগানো; চলক Σ করা = একটি কলাম বাদ দেওয়া। "সবচেয়ে ছোট scope আগে" নিয়মটি query planner-এর নিয়মেরই সমতুল্য।

৫ মার্কভ শৃঙ্খল ও গোপন মার্কভ মডেল

সংজ্ঞা: **প্রকৃতির সম্ভাবনার নিয়ম** (Markov's chain) বলে: আগের সব ইতিহাসের বদলে **সাম্প্রতিক অবস্থাটুকুই** ভবিষ্যতের বিতরণ নির্ধারণ করে — $\mathbf{P(X_{t+1} \mid X_t, X_{t-1}, \ldots) = P(X_{t+1} \mid X_t)}$, অর্থাৎ **প্রথম-শ্রেণি মার্কভ শর্ত**। **গোপন মার্কভ মডেল** (HMM) তারই রূপ, যেখানে প্রকৃত অবস্থা **লুকানো** আছে আর আমরা শুধু পর্যবেক্ষণ (observation) দেখি। একটি HMM পাঁচটি জিনিস দিয়ে ঠিক হয়: $\mathbf{H = (S, O, A, B, \pi)}$

HMM-এর পাঁচটি অংশ	কী রাখে
$S = \{s_1,\ldots,sN\}$	গোপন অবস্থার সংখ্যা
$O = \{o_1,\ldots,oM\}$	পর্যবেক্ষণের বর্ণমালা
a_{ij}	$s_i \to s_j$ স্থানান্তর
$b_j(o)$	s_j থেকে o আসার সম্ভাবনা
π_i	প্রথম অবস্থার বিতরণ



বাঁ পাশে অবস্থা · ডান পাশে পর্যবেক্ষণ

অবস্থা লুকানো, তাই পর্যবেক্ষণ থেকে অবস্থার অনুমান

অ্যাসুম্পশন: মার্কভ + স্বাধীনতর পর্যবেক্ষণ emission। অডিও-স্পিচ ছাড়া HMM-এর ভিত্তি এই দুটি অ্যাসুম্পশন; ভাঙলে **স্থান-নির্ভর (dependent)** মডেল লাগে।

আবহাওয়ার ধরন	পরের রোদ	পরের মেঘলা	পরের বৃষ্টি
রোদ (π)	0.50	0.30	0.20
রোদ	0.50	0.30	0.20
মেঘলা	0.20	0.40	0.40
বৃষ্টি	0.40	0.40	0.20

সমাধানকৃত উদাহরণ ✍️ দুই দিন পরে: $\pi = (0.5, 0.3, 0.2)$। দ্বিতীয় দিন: $\pi \cdot A = (0.39, 0.35, 0.26)$। তৃতীয় দিন: (0.369, 0.361, 0.270)। তাই **P(তৃতীয় দিন বৃষ্টি) = 0.27** — গতকাল বৃষ্টি হয়েছিল বলেই আজকের সম্ভাবনা এত বেড়েছে।

মনে রাখার কৌশল: **"স্মৃতি শুধু আগেরটা।"** মার্কভ = মেমোরি ১। লুকানো অবস্থা থাকলে সেটাই HMM, আর emission-এর সাথে জোড়া লাগলে বাক্য-মডেলিং।

পরীক্ষার ফাঁদ: "HMM হলো Markov chain" — **বিভ্রান্তিকর**। Markov chain-এ অবস্থাই লুকানো নয়; HMM-এ অবস্থা hidden, শুধু observation দেখা যায়। HMM মডেল করে, Markov chain নয় — Markov chain-এর **বিস্তার** করে।

ব্যবহার: ASR · ভাষা শনাক্তকরণ (প্রাথমিক) · বায়ো-ইনফরমেটিকসে DNA প্রোটিন-স্ট্রাকচার · স্প্যাম ফিল্টারে markov chain এবং Markov random field।

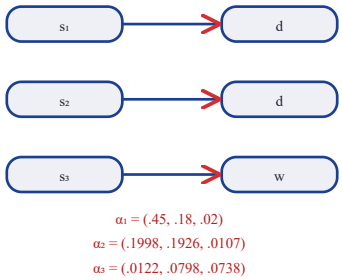
৬ ফরওয়ার্ড, ব্যাকওয়ার্ড ও ভিটার্বি

সংজ্ঞা: পর্যবেক্ষণ বাক্য $o_1,\ldots,oT$ দেখে **তিনটি আলাদা প্রশ্নের** উত্তর চাই: (i) **ফরওয়ার্ড** — পুরো বাক্যের দেওয়া-করা কত? (ii) **ব্যাকওয়ার্ড** — সব ভবিষ্যতের তথ্য মিলিয়ে বর্তমান অবস্থার সম্ভাবনা কত? (iii) **ভিটার্বি** — সবচেয়ে সম্ভাব্য অবস্থা-পথ কোনটি? তিনটিই গুণফল-সম্প্রসারণ (product-sum) DP, শুধু স্বাভাবিকীকরণ আলাদা।

১ · ফরওয়ার্ড (আগে): $\alpha_t(j) = b_j(o_t)\cdot\Sigma_i\,[a_{ij}\cdot\alpha_{t-1}(i)]$
$\alpha_1(j) = \pi_j\cdot b_j(o_1)$। পুরো বাক্যের সম্ভাবনা $= \Sigma_j\,\alpha T(j) = \mathbf{P(O)}$। $O(N^2)$ সময়, $O(NT)$ স্মৃতি।

২ · ব্যাকওয়ার্ড (পিছনে): $\beta_t(i) = \Sigma_j\,[a_{ij}\cdot b_j(o_{t+1})\cdot\beta_{t+1}(j)]$
$\beta T(j) = 1$, $\beta_1(i) = P(\text{ভবিষ্যত} \mid \text{সময় ১-এ অবস্থা } i)$।

৩ · পোস্টেরিয়র ও ভিটার্বি: $\gamma_t(i) = \alpha_t(i)\beta_t(i) / \Sigma_k\,\alpha_t(k)\beta_t(k)$ · ভিটার্বি: $\boldsymbol{\delta_t(j) = b_j(o_t)\cdot\max_i\,[a_{ij}\cdot\delta_{t-1}(i)]}$, পথ তখন ব্যাকট্র্যাক করে।



$\alpha_1 = (.45, .18, .02)$
$\alpha_2 = (.1998, .1926, .0107)$
$\alpha_3 = (.0122, .0798, .0738)$

অবস্থা বামে, পর্যবেক্ষণ ডানে

সমাধানকৃত উদাহরণ ১ ✍ তিন অবস্থা, পর্যবেক্ষণ (শুকনো, শুকনো, ভেজা): $\pi = (0.5, 0.3, 0.2)$; A আগের পাতার; b(শুকনো) = (0.9, 0.6, 0.1), b(ভেজা) = (0.1, 0.4, 0.9)। · $\alpha_1 = (0.45, 0.18, 0.02)$ · $\alpha_2 = (0.1998, 0.1926, 0.0107)$ · $\alpha_3 = (0.0122, 0.0798, 0.0738)$ · **P(O) = 0.1658** · $\delta_3 = (0.0065, 0.0324, 0.0365)$ ⇒ সেরা পথ $\mathbf{S_1 \to S_2 \to S_3}$।

সমাধানকৃত উদাহরণ ২ ✍ প্রান্তিক সেরা পথ থেকে আলাদা: $\gamma_3 = \alpha_3(j)\beta_3(j)/P(O) = (0.073, 0.481, 0.445)$: সময় t = 3-এ সবচেয়ে সম্ভাব্য অবস্থা S_2, অথচ সবচেয়ে সম্ভাব্য **পথ** S_3-এ শেষ হয়। প্রান্তিক ≠ পথ।

অ্যালগরিদম	কোন প্রশ্নের উত্তর দেয়	কীভাবে জোড়া লাগে
ফরওয়ার্ড	P(O) — কতটা অবাক হব?	সব অবস্থার ওপর Σ
ব্যাকওয়ার্ড	অবস্থা j-এর "ভবিষ্যৎ" ওজন	সব অবস্থার ওপর Σ
ফরওয়ার্ড-ব্যাকওয়ার্ড	$P(\text{অবস্থা}_t \mid O)$ — **পোস্টেরিয়র স্মুদিং**	$\alpha(j)\beta(j)/P(O)$
ভিটার্বি	সেরা একক পথ	অবস্থার ওপর max
বম-ওয়েলচ	A, B ও π শেখে (EM)	E-ধাপ, M-ধাপ

মনে রাখার কৌশল: **"ফরওয়ার্ড যোগ করে, ভিটার্বি max নেয়, ব্যাকওয়ার্ড পিছনে তাকায়।"** ফরওয়ার্ড একবার লিখে নাও; তারপর **max** Σ-এর জায়গা নিলে, α-এর জায়গায় ψ এলেই ভিটার্বি।

পরীক্ষার ফাঁদ: ফরওয়ার্ড **P(O)** দেয়, ভিটার্বি **সেরা পথ**, আর সেরা পথ প্রতি মুহূর্তে **সবচেয়ে সম্ভাব্য অবস্থা** নয়। দীর্ঘ বাক্যে সংখ্যা শূন্যে পড়ে যায়: প্রতি ধাপে $c_t = \Sigma_j\,\alpha_t(j)$ দিয়ে ভাগ এবং শেষে গুণ করতে হয়।

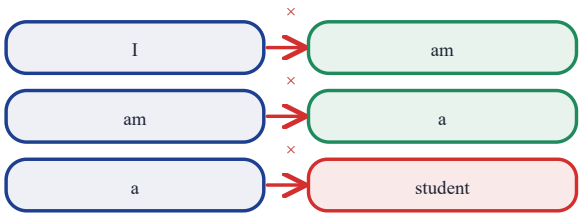
EM + HMM: E-ধাপে γ দিয়ে প্রত্যাশা গণনা, M-ধাপে b আর a পুনরায় মাপা। γ কেবল পর্যবেক্ষণের সাক্ষ্যেই মিলিত হয়, তাই ফরওয়ার্ড-ব্যাকওয়ার্ড হলো HMM-এর EM; ভিটার্বি হলো hard EM।

IT সংযোগ: এই পুনরাবৃত্তিগুলো আসলে একটি **ল্যাটিসের ওপর গতিশীল প্রোগ্রামিং-ভিত্তিক সবচেয়ে ছোট পথ** — ওজনযুক্ত DAG-তে সবচেয়ে ছোট পথের মতো একই আকৃতি, আর স্পীচ রিকগনাইজারের beam search-এর মতো।

৭ NLP পত্র ১: n-গ্রাম, স্মুদিং, পেরপ্লেক্সিটি

সংজ্ঞা: প্রাকৃতিক ভাষা প্রক্রিয়াকরণ (NLP) হলো কম্পিউটারে মানুষের ভাষা বোঝা ও তৈরি করা। সবচেয়ে সহজ পদ্ধতি: **n-গ্রাম** — পরপর **n** শব্দের টুকরো। n = 1 ইউনিগ্রাম, n = 2 বাইগ্রাম, n = 3 ট্রাইগ্রাম। সুবীকরণের যুক্তি: "মানুষ পরের শব্দটি **আগের কয়েকটির ভেতরে** খোঁজে"।

মডেল	যা মনে রাখে
ইউনিগ্রাম	একটি শব্দের গণনা
বাইগ্রাম	শব্দের জোড়া — পরের শব্দ
ট্রাইগ্রাম	তিন শব্দ — ব্যাকরণের ছোঁয়া
প্রায়ই	**সব শব্দের জোড়া**

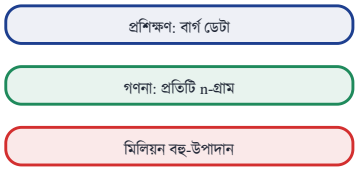


শব্দের পর একটি শব্দ ⟶ বাইগ্রাম

শর্ত সম্ভাবনা: $P(w_i \mid w_{i-1}) \cdot P(w_i \mid w_{i-2}, w_{i-1}) \cdot$ **P(w | পূর্ব n−১টি)**

$$P(w_i \mid \text{পূর্ব}) = \text{count}(\text{পূর্ব}, w_i)/\text{count}(\text{পূর্ব})$$

সমাধানকৃত উদাহরণ ✍️: বাক্য "I am a student"-এ ৪টি শব্দ, N = 19 (আগের বাক্যের সাথে), V = 6। P(I) = 6/19, P(am|I) = 3/12, P(a|am) = 3/9, P(student|a) = 4/11 P = **0.0789** (স্মুদিং ছাড়া)। একই বাক্য অ্যাড-ওয়ানে, |V| = 7 ধরে: 6/26 · 3/12 · 3/9 · 4/11 = **0.0070** — শব্দ না দেখা থাকলেও কোনো শূন্য হয় না।



শব্দের দফা ⟶ গণনা ⟶ সম্ভাবনা

তিন ধরনের স্মুদিং: **Laplace (অ্যাড-ওয়ান)** — (count+1)/(total+V)। **Good-Turing** — দুইবারের মধ্যে দেখা যায়নি এমন শব্দের জন্য count-এর সমন্বয়। **Kneser-Ney** — শুধু কতবার নয়, **কোন শব্দের পরে** এসেছে তা দেখে।

পেরপ্লেক্সিটি ও NLL: NLL = −(1/N) Σ log $P(w_i)$ = **exp(NLL)** = পেরপ্লেক্সিটি। m_1 = (.4, .4, .2) হলে NLL = **1.147** ও পেরপ্লেক্সিটি **3.15**; m_2 = (.2, .2, .6) হলে NLL = 1.243 ও পেরপ্লেক্সিটি **3.47**। ছোট পেরপ্লেক্সিটি = ভালো মডেল।

মনে রাখার কৌশল: "গুনো যেখানে শূন্য, বাড়াও এক।" কিন্তু n বাড়ালে গণনা ব্যাহারিক, তাই ভাষা মডেলে n = ৩–৫ সাধারণ।

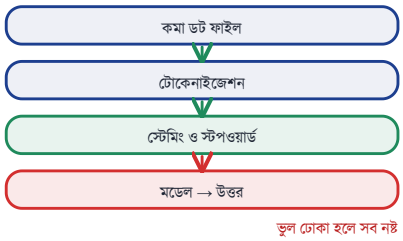
পরীক্ষার ফাঁদ: বাইগ্রামে (শুরু) হিসাব হয় **count(w_{i-1}, w_i)/count(w_{i-1})** — ভবিষ্যৎ নয়, অতীত। আর "শব্দের সংখ্যা" মানে কখনো ngram নয়, কখনো ngram-এর count।

শব্দের সাজানোর ধরন: **অনুক্রমে** (word, লেখার ক্রম বদলায় না): free text, ভাষা মডেল · **অবস্থানে** (ব্যাগ-অফ-ওয়ার্ডস, শব্দের ব্যাগ পরিসংখ্যান): বিচ্ছিন্নতা, পুনরাবৃত্তি নয় · **সমন্বয়** (skip-gram/CBOW): নেইভ বেইজ ও Word2Vec-এ কাজে লাগে।

IT সংযোগ: n-গ্রাম গণনা হলো MapReduce-এর শব্দ-গণনা প্যাটার্ন; স্মুদিং ছাড়া ভবিষ্যতের শব্দ গুণে শূন্য হয়ে যায়, তাই বড় সিস্টেমে Kneser-Ney ব্যবহার হয়।

৮ NLP পত্র ২: স্টেমিং, POS, চাঙ্কিং, পার্সিং

স্টেমিং বনাম লেম্মাটাইজেশন: **স্টেমিং** নিয়ম দিয়ে শব্দের শেষ ছিঁড়ে দেয় (Porter, **১৯৮০**): relational → relat, connected → connect — ফল **আসল শব্দ নয়**। **লেম্মাটাইজেশন** অভিধান ও পদ-বিভাগ ব্যবহার করে: better → good, teeth → tooth।



প্রক্রিয়াকরণ-পূর্ব পাইপলাইন

ধাপ	কী করে
টোকেনাইজেশন	লেখা ভাঙে শব্দে/বাক্যে
নরমালাইজেশন	ছোট হাত, কোড-সংখ্যা সরানো
স্টপওয়ার্ড তালিকা	a, the, of, is, and… সরানো
স্টেমিং	মূল শব্দের অংশে কাটা

শব্দ: শব্দ · স্টেম · লেম্মা · ট্যাগ: playing/ **play / play / VBG** · better/**better / good / JJR** · flies/**fli / fly / NNS** · mice/**mice / mouse / NNS**।

মনে রাখার কৌশল: **স্টেমিং কাটে, লেম্মা অভিধানে খোঁজে।** Porter stemmer (১৯৮০): `caresses→caress, ponies→poni` · লেম্মাটাইজার: `better→good, ran→run`। ঘন শব্দ বাদ দিলে অর্থ হারায়: **good** ≠ **best** ≠ **well** — তাই মূল্যায়নের সময় স্টপওয়ার্ড রাখা ভালো।

POS ট্যাগিং ও চাঙ্কিং: **POS tagging** প্রতিটি টোকেনের পদ-বিভাগ বলে। **Penn Treebank: ৪৫ ট্যাগ** (৩৬ ট্যাগের ছোট সেটও বলা হয়); **Universal POS** সেটে **১৭টি** ট্যাগ। **চাঙ্কিং** (অগভীর পার্সিং) ট্যাগগুলো জুড়ে সমতল পদগুচ্ছ বানায় — NP, VP, PP।

সমাধানকৃত উদাহরণ ১ ✍️ ট্যাগ দাও: "The *flies* hit the wall" → The/DT flies/NNS hit/VBD the/DT wall/NN। কিন্তু "The flies *hit* the wall"-ও একটি পূর্ণ ব্যাকরণসম্মত বাক্য — শুধু প্রসঙ্গই সিদ্ধান্ত নেয়।

সমাধানকৃত উদাহরণ ২ ✍️ চাঙ্ক বানাও: "The boy hit the ball in the park" → [**NP** The boy] [**VP** hit the ball] [**PP** in the park]। চাঙ্কিং এখানেই থেমে যায় — কোন পদগুচ্ছ কোন ক্রিয়ার সাথে যুক্ত, তা বলে না।

পার্সিং: **কনস্টিটুয়েন্সি পার্সিং** ব্যাকরণিক শব্দচিহ্ন ব্যবহার করে বাস্তবে থাকা স্তর তৈরি করে। **ডিপেনডেন্সি পার্সিং** প্রতিটি শব্দকে তার ব্যাকরণিক **head**-এর সাথে জুড়ে; Universal Dependencies-এ **১৬টি** সর্বজনীন সম্পর্ক — nsubj, obj, det, amod, ROOT, case, nmod।

মনে রাখার কৌশল: "স্টেমিং হলো **কাঁচি**, লেম্মাটাইজেশন হলো **অভিধান**।" POS ট্যাগ বলে শব্দটি কী ধরনের; চাঙ্কিং আরেক স্তর যোগ করে; পার্সিং সব স্তর যোগ করে। সংখ্যা: **৪৫** Penn · **১৭** Universal POS · **১৬** UD সম্পর্ক।

পরীক্ষার ফাঁদ: **POS tagging পার্সিং নয়** — ট্যাগার বলে "এটি কী ধরনের শব্দ?", পার্সার বলে "শব্দগুলো কীভাবে জোড়া লাগে?" স্টেমিং **লেম্মাটাইজেশনের সমান নয়**। আর "flies"-এ একাই **তিন** অর্থ: বহুবচন বিশেষ্য, তৃতীয় পুরুষ ক্রিয়া, বা পুতুল-নাচক।

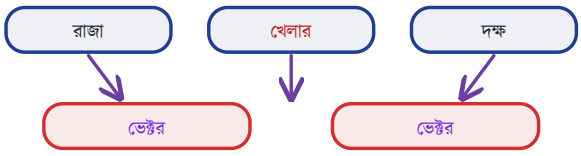
বহুত্বতা — চার ধরনের, সবই পরীক্ষায়: **শাব্দিক** (bank: নদী / টাকা) · **বাক্যগত** ("আমি দূরবিনীতে মানুষটিকে দেখলাম") · **অর্থগত** ("He kicked the bucket") · **ব্যবহারিক/সম্প্রসারণ** ("তাকে কুকুরসহ দেখলাম")।

IT সংযোগ: একটি **inverted index** প্রতিটি পরিভাষার জন্য সেটি ধরে এমন নথির ক্রমাঙ্কৃত তালিকা রাখে; চাঙ্ক ও ডিপেনডেন্সি আর্ক তার পাশে বসে। র‍্যাংকার এরপর প্রতিটি (নথি, পরিভাষা) জোড়া স্কোর করে — নেইভ বেইজের নথি-স্কোরের মতোই আকৃতি, TF-IDF ওজনে।

৯ NLP পত্র ৩: এমবেডিং ও ট্রান্সফর্মার

সংজ্ঞা: **ওয়ার্ড এমবেডিং** (word embedding) হলো প্রতিটি শব্দকে ঘন সংখ্যা-ভেক্টরে প্রতিস্থাপন করা, যেখানে অর্থ-কাছের শব্দের ভেক্টর কাছাকাছি থাকে। বাইলোয়াল "কাছাকাছি" = সাইকোসাইন তুলনামূলক কম।

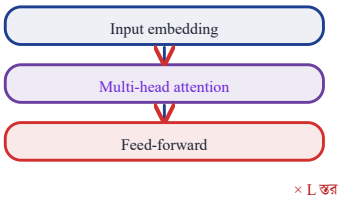
মডেল	কী করে	সীমাবদ্ধতা
Word2Vec (২০১৩)	CBOW মাঝের শব্দ থেকে আশপাশ · Skip-gram আশপাশ থেকে মাঝের শব্দ	স্থির ভেক্টর
GloVe (২০১৪)	গ্লোবাল কো-ঘনিষ্ঠতা থেকে ভেক্টর	স্থির ভেক্টর
FastText (২০১৬)	শব্দকে অক্ষরের n-গ্রামে ভাঙে	অজানা শব্দও চিনতে পারে
Transformer (২০১৭)	অ্যাটেনশন দিয়ে লম্বা পরিসর — সমান্তরাল	$O(n^2)$ মনোযোগ
BERT (২০১৮)	দুই-পাশের Transformer-এর encoder; ভাষা বোঝার Pretrained model	আসল উদ্দেশ্য ছাড়াই pretrain



king ≈ king-of-the-hill ≈ ruler

অর্থ-কাছের শব্দ = ভেক্টরে কাছে

অ্যাটেনশনের ধারণা: কোন শব্দ বাক্যের কোন অংশে বেশি গুরুত্বপূর্ণ তা নিজেই শেখে — প্রতিটি শব্দ বাক্যের **প্রত্যেকটি শব্দ থেকে** তথ্য নেয়। এতে দূরত্বের সমস্যা কমে, তাই বহু-স্তরের নেটওয়ার্ক সম্ভব হয়।



একটি Transformer ব্লক

সমাধানকৃত উদাহরণ ✍️: "Ravi খেলছে", "Ravi বই পড়ছে" — দুই বাক্যে Ravi একই মানুষ। প্রথম কথায় ক্রিয়া খেলা (খেলোয়াড়), দ্বিতীয়ে পড়া (পাঠক)। চারপাশের শব্দ থেকে ভেক্টর বদলালেই শব্দটির অর্থ বদলায় — এই কারণেই স্ট্যাটিক Word2Vec "Ravi"-এর একটাই অর্থ দিতে পারে।

মনে রাখার কৌশল: "Word2Vec দেখায় কখন, GloVe কত, FastText কী, BERT কে।" ২০১৩ → ২০১৪ → ২০১৬ → ২০১৭ → ২০১৮ — বছর মিলিয়ে লেখা খুব সহজ।

পরীক্ষার ফাঁদ: FastText-কে "subword" বলা যায়, **"subword নয়"** বলা যায় **না** — এটি উপাদান-ভেক্টর। BERT **encoder**-ধরনের, GPT **decoder**-ধরনের।

one-hot বনাম এমবেডিং: one-hot: উপাদানশীল, প্রতিটি শব্দের দূরত্ব **সমান**, কোনো অর্থ নেই, কিন্তু দ্রুত ও উঁচু (n টি বাস্তব, n^2 পরিসর)। এমবেডিং: ঘন, অর্ধেকের বেশি ০, কিন্তু অর্থ-অনুভূতি আছে।

IT সংযোগ: এমবেডিং আজকাল ভেক্টর ডেটাবেসে (Chroma, FAISS, pgvector) কাজ করে; "সবচেয়ে কাছের k ভেক্টর" খোঁজা মানে সেই ডেটাবেসের ওপর ANN সূচক — একই অনুসন্ধান, অন্য বিন্যাসে।

১০ রাতের পাতা: বারো এক লাইনে সব

#	এক লাইনে
১	$P(A\|B) = P(A \wedge B)/P(B)$
২	$P(H\|E) = P(E\|H)P(H)/P(E)$
৩	অনুপাত: পরবর্তী = পূর্ব × সম্ভাবনা অনুপাত
৪	নেইভ বেইজ: $\hat{C} = \text{argmax}\, P(C)\prod P(x_i\|C)$
৫	নেইভ মানে **শুধু বৈশিষ্ট্য স্বাধীন**
৬	BN: DAG, CPT, $\prod P(x_i\|Pa)$
৭	d-বিচ্ছেদ ⇒ স্বাধীন; চক্র নেই
৮	অনুমান: Σ করে বিলুপ্তি, ক্রম বেছে নাও
৯	নয়জি-ওআর: $1 - \prod(1-p_i)$
১০	D-S: $Bel \le P \le Pl$, $m(\emptyset)=0$
১১	মার্কভ: সাম্প্রতিক অবস্থাই যথেষ্ট
১২	HMM = (S, O, A, B, π)

#	এক লাইনে
১৩	$\alpha_t = b_j(o_t)\cdot\Sigma_i\, a_{ij}\, \alpha_{t-1}(i)$
১৪	$\beta_t = \Sigma_j\, a_{ij}\, b_j(o_{t+1})\, \beta_{t+1}(j)$
১৫	$\gamma = \alpha\beta/\Sigma\alpha\beta$; δ-তে max
১৬	বাইগ্রাম: $count(w_{-1},w)/count(w_{-1})$
১৭	অ্যাড-ওয়ান: $(c+1)/(N+V)$
১৮	পেরপ্লেক্সিটি = $\exp(NLL)$
১৯	স্টেমিং কাটে, লেম্মা ফেরায়
২০	EM: E-তে γ, M-তে a, b
২১	Word2Vec ২০১৩ · GloVe ২০১৪ · FastText ২০১৬
২২	Transformer ২০১৭ · BERT ২০১৮ (encoder)

সবচেয়ে বড় ফাঁদগুলো: বিশ্বাস-ফাংশন লাইকলিহুড **নয়**, পরবর্তী পূর্ব **নয়** · "নেইভ" মানে শর্তগত স্বাধীনতা, সমান পূর্ব নয় · BN একটি **DAG**, চক্রযুক্ত গ্রাফ কখনো নয় · নয়জি-ওআর হলো $\mathbf{1 - \prod(1-p)}$, যোগ নয় · hidden মানে পর্যবেক্ষকের কাছে **লুকানো**, অ্যালগরিদমের কাছে নয় · ভিটার্বি একটি পথে max করে, ফরওয়ার্ড সব যোগ করে · স্টেমিং ≠ লেম্মাটাইজেশন · POS tagging ≠ পার্সিং · এমবেডিং ভাষা-মডেল নয় · পেরপ্লেক্সিটি একটি সমীকরণ, সম্ভাবনা নয়।

সব কৌশল একসাথে: "পূর্ব ঢোকে, পরবর্তী বেরোয়" (বেইজ) · "প্রতি বৈশিষ্ট্যের সম্ভাবনা গুণো, পূর্ব একবার যোগ, লগ স্পেসে" (নেইভ বেইজ) · "প্রতি পিতাসেটে একটি সারি" (BN) · "আগে গুণো, পরে Σ করে বাদ দাও; সবচেয়ে ছোট scope আগে" (বিলুপ্তি, নয়জি-ওআর, D-S) · "মার্কভ = মেমোরি ১; hidden = পর্যবেক্ষকের কাছে লুকানো" (HMM) · "স্টেমিং হলো কাঁচি, লেম্মাটাইজেশন হলো অভিধান" (NLP) · "n বাড়লে মডেল ভালো, শূন্যও বেশি" (ভাষা-মডেল)।

ছয়টি সংখ্যা যা মনে থাকলে কাজ হয়: 0.083 (পরীক্ষা-পরবর্তী সম্ভাবনা) · 95.1 % (স্প্যাম) · 0.418 (ভেজা ঘাস) · 0.664 (নয়জি-ওআর) · 0.1658 (HMM বাক্য) · 0.27 (তৃতীয় দিন বৃষ্টি)।

রাতের শেষ ১৫ মিনিট: শুধু **ফাঁদের তালিকা** পড়ো — আর কিছু নয়। নতুন কিছু শিখবে না, পুরনো ঝালসাল ঠিক করবে।

ফর্মুলা পাতা: শুধু চারটি সূত্র লিখলেই বেশিরভাগ লিখিত প্রশ্ন হয়: **বেইজ**, **নেইভ বেইজের argmax**, **BN-এর গুণফল**, **হিস্টোগ্রাম/বাইগ্রাম**। ফর্মুলা মুখস্থ না হলে কেবল চার শব্দ লিখলেই কাজ চলে।

✓ অনুশীলনী বহুনির্বাচনী (পরীক্ষার ধরন, ১০ নম্বর)

১. $P(A|B) = 0.4$, $P(A) = 0.3$ হলে:

ক) 0.7 খ) $P(A \wedge B) = 0.12$

গ) 1.33 ঘ) 0.24

২. রোগ ১ %, পরীক্ষা ৯৯ % সংবেদনশীল, ৯৯ % নির্দিষ্ট:

ক) 0.99 খ) 0.10

গ) ≈ 0.50 ঘ) 0.01

৩. নেইভ বেইজে "নেইভ" মানে:

ক) শ্রেণি দেওয়ায় স্বাধীন খ) সমান পূর্ব

গ) রেখা-বিভাজনীয় ঘ) সম বৈশিষ্ট্য

৪. বেইজিয়ান নেটওয়ার্ক যেভাবে গুণফলী হয়:

ক) $\prod_i P(x_i)$ খ) সবার ওপর max

গ) $\Sigma_i P(x_i \mid Pa)$ ঘ) $\prod_i P(x_i \mid Pa(x_i))$

৫. বেইজিয়ান নেটওয়ার্ক কেন DAG:

ক) তীর নিচে যায় খ) চক্র মানে নিজেই পূর্বপুরুষ

গ) CPT-তে ২ পিতা লাগে ঘ) যৌগ বিতরণ সমরূপ

৬. নয়জি-ওআর, ০.৪ করার দুটি কারণ:

ক) 0.80 খ) 0.16

গ) 0.64 ঘ) 0.36

৭. ডেম্পস্টার-শেফার সম্পর্কে ঠিক:

ক) $Bel \le P \le Pl$ খ) সবসময় $Pl \le Bel$

গ) প্রতি ঘটনায় একটিই সম্ভাবনা ঘ) নেইভ বেইজের সমান

৮. ফরওয়ার্ড ও ভিটার্বির পার্থক্য:

ক) ফরওয়ার্ড উপকরণ উপেক্ষা করে খ) ভিটার্বি সঠিক

গ) ভিন্ন HMM ঘ) এক পথে Σ বনাম max

৯. অভিধান দিয়ে "flies" → "fly":

ক) স্টেমিং খ) লেম্মাটাইজেশন

গ) টোকেনাইজেশন ঘ) চাঙ্কিং

১০. ওয়ার্ড এমবেডিং সম্পর্কে ঠিক:

ক) one-hot = অর্থ খ) GloVe = সমান্তরাল জোড়া

গ) king ও queen কাছে ঘ) ট্রাইগ্রাম = এমবেডিং

উত্তর → ১-খ · ২-গ · ৩-ক · ৪-ঘ · ৫-খ · ৬-গ · ৭-ক · ৮-ঘ · ৯-খ · ১০-গ

লিখিত প্রশ্ন: বেইজের উপপাদটি চারটি পরিভাষাসহ লেখো। একটি পরীক্ষা ৯০ % ক্ষেত্রে রোগ ধরে, রোগ ১ % মানুষের এবং সুস্থদের ১০ %-এর ক্ষেত্রে পরীক্ষা ইতিবাচক — $P(\text{রোগ} \mid \text{ধনাত্মক})$ বের করো, তারপর নেইভ বেইজের সূত্রটি লেখো এবং কেন তাকে নেইভ বলা হয় তা বলো। ১০ নম্বর

১ **উপপাদ (৩)** — $P(H|E) = P(E|H)P(H)/P(E)$। পূর্ব $P(H)$: প্রমাণের আগে। সম্ভাবনা $P(E|H)$: H সত্য হলে প্রমাণ। সাক্ষ্য $P(E)$: স্বাভাবিকীকরণ পদ। পরবর্তী $P(H|E)$: পরে। ৩

২ অঙ্গের ওপর $0.9 \times 0.01 = 0.009$; অঙ্গের নিচে $0.009 + 0.1 \times 0.99 = 0.108$। ২

৩ $P(D|+) = 0.009/0.108 = \mathbf{0.083}$ — ভালো পরীক্ষা, ক্ষুদ্র পূর্ব, ছোট পরবর্তী। ২

৪ **সূত্র (২)** — $\hat{C} = \text{argmax}_C\, P(C)P(x_1|C)\cdots P(x_n|C)$; $P(x)$ স্বাভাবিকীকরণ পদ বাতিল হয়ে যায়। ২

৫ **কেন নেইভ (১)** — এটি ধরে নেয় $P(x_1,\ldots,x_n|C) = \prod_i P(x_i|C)$: শ্রেণি দেওয়ায় বৈশিষ্ট্যগুলো স্বাধীন। ১

পরীক্ষার আগে ✓

- ✓ $P(A|B)$, চেইন নিয়ম
- ✓ অনুপাতে বেইজ
- ✓ নথির স্কোর বানানো
- ✓ BN এঁকে গণনা
- ✓ ফরওয়ার্ড, ব্যাকওয়ার্ড, ভিটার্বি
- ✓ ৪৫ / ১৭ / ১৬ নাম বলো