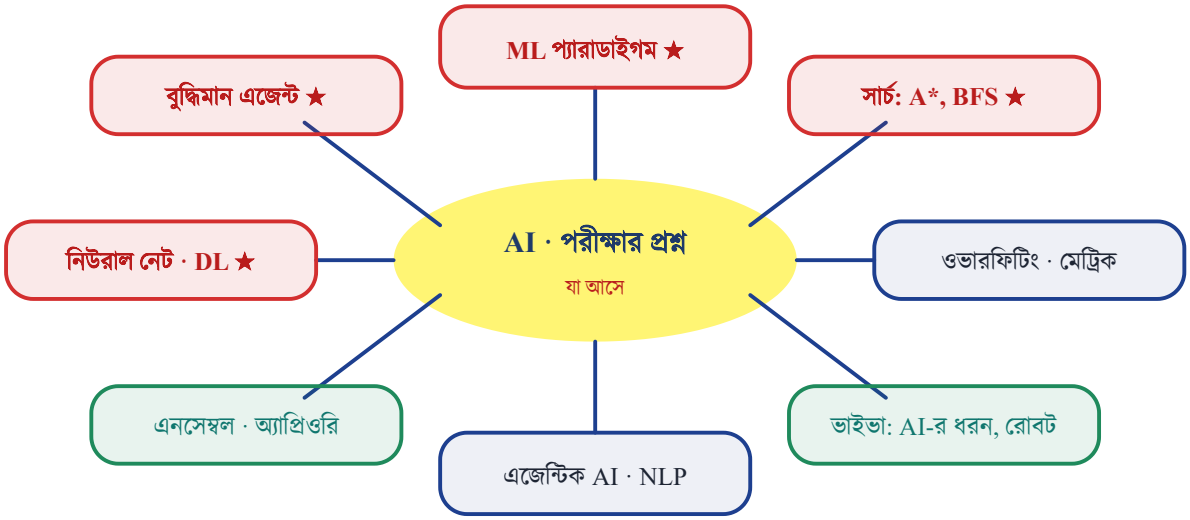
সমাধানসহ পরীক্ষার প্রশ্ন: কৃত্রিম বুদ্ধিমত্তা

BCS, BUET-ধরনের, পাওয়ার সেক্টর ও ব্যাংকের পত্র ও ভাইভার ৩০টি প্রশ্ন, ১২ পাতায় সমাধান



↑ লাল = সবচেয়ে বেশি আসে (লিখিত + MCQ + ভাইভা মিলিয়ে)

যেসব পত্র নেওয়া হয়েছে

- **৪৫তম BCS লিখিত (CSE-971)**, ৩১.০১.২০২৪
- **৪৯তম BCS (ICT-281)** MCQ পত্র, ২০২৫: ৯টি AI MCQ
- BPDB AE (CSE) ২৪.০২.২০২৩ · GTCL AE (CSE) ২০২২
- DPDC AM (ICT) ২৭.০৬.২০২৫ · BUET MSc in CSE ০৩.১০.২০২৬
- ব্যাংক সহকারী প্রোগ্রামার লিখিত · ব্যাংক আইটি ভাইভা

সবচেয়ে বেশি আসে

① Supervised বনাম unsupervised বনাম reinforcement (৩টি লিখিত)
② এজেন্ট: rational agent, ৫ ধরন
③ A* বনাম BFS, hill climbing
④ DL, backprop, RNN

সংকেত: **হলুদ** = মূল শব্দ · **লাল বৃত্ত** = মুখস্থ রাখার তথ্য · **বেগুনি** = মনে রাখার কৌশল · **লাল বক্স** = পরীক্ষার ফাঁদ · **সবুজ** = সমাধানকৃত উদাহরণ · **নীল বক্স** = প্রশ্ন যেমন এসেছে

সূচিপত্র

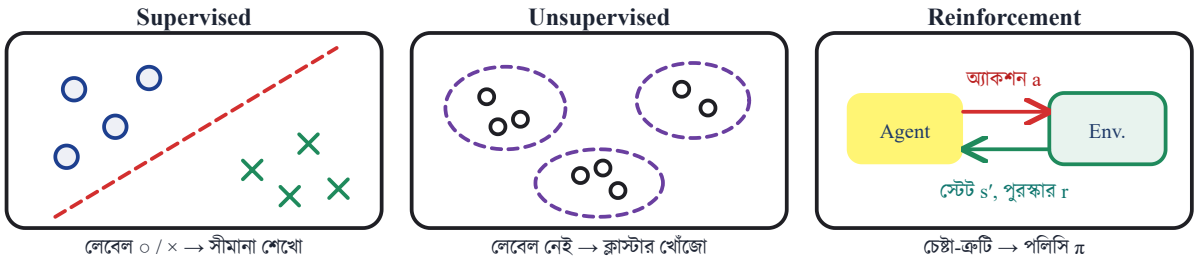
- ✓ ML: তিনটি প্যারাডাইগম ..... পৃ. ২
- ✓ Reinforcement ও local search ... পৃ. ৩
- ✓ বুদ্ধিমান ও rational এজেন্ট ... পৃ. ৪
- ✓ A* বনাম BFS ..... পৃ. ৫
- ✓ ওভারফিটিং, এনসেম্বল ..... পৃ. ৬
- ✓ এজেন্টিক AI বনাম চ্যাটবট ..... পৃ. ৭
- ✓ মার্কেট বাস্কেট: অ্যাপ্রিওরি ..... পৃ. ৮
- ✓ ডিপ লার্নিং, NLP ..... পৃ. ৯
- ✓ MCQ + ভাইভা ..... পৃ. ১০
- ✓ রাতের পাতা ..... পৃ. ১১
- ✓ অনুশীলন MCQ + লিখিত ..... পৃ. ১২

১ মেশিন লার্নিং: তিনটি প্যারাডাইগম

প্রশ্ন: মেশিন লার্নিং কী? supervised, unsupervised ও reinforcement learning-এর মধ্যে পার্থক্য লেখো। ৪৫তম BCS লিখিত (CSE-971) · ৩১.০১.২০২৪; অন্য একটি লিখিত পত্রেও এসেছে

প্রশ্ন: ML-এর তিনটি মৌলিক প্যারাডাইগম তুলনা করো। ১০ নম্বর ব্যাংক সহকারী প্রোগ্রামার লিখিত

মেশিন লার্নিং: AI-এর সেই শাখা যেখানে সিস্টেম স্পষ্টভাবে প্রোগ্রাম না করে **তথ্য বা অভিজ্ঞতা থেকে শেখে** (Samuel, **১৯৫৯**)। মিচেল: কোনো প্রোগ্রাম কাজ **T**-তে অভিজ্ঞতা **E** থেকে মাপ **P** অনুযায়ী শিখলে যদি T-তে তার কর্মক্ষমতা E-এর সাথে **বাড়ে**।



বিষয়	Supervised	Unsupervised	Reinforcement
তথ্য	**লেবেলযুক্ত** জোড় (x, y)	শুধু লেবেলবিহীন x	প্রতিক্রিয়া থেকে অভিজ্ঞতা (s, a, r, s′)
ফিডব্যাক	প্রতি উদাহরণে সঠিক উত্তর	কিছু নেই	একটি স্কেলার **reward**, প্রায়ই বিলম্বিত
লক্ষ্য	f : x → y শেখা; অনুমান	লুকানো কাঠামো আবিষ্কার	এমন **পলিসি π(s) → a** শেখা যা মোট পুরস্কার বাড়ায়
কাজ	শ্রেণিবিন্যাস, রিগ্রেশন	ক্লাস্টারিং, PCA, অ্যাসোসিয়েশন নিয়ম	ধারাবাহিক সিদ্ধান্ত, নিয়ন্ত্রণ
অ্যালগরিদম	লিনিয়ার/লজিস্টিক রিগ্রেশন, ডিসিশন ট্রি, SVM, k-NN, নেভ বেস	k-means, হায়ারার্কিক্যাল, DBSCAN, PCA, অ্যাপ্রিওরি	Q-learning, SARSA, DQN, পলিসি গ্রেডিয়েন্ট
মূল্যায়ন	accuracy, F1, RMSE টেস্ট তথ্যে	সিলুয়েট, support/lift	প্রতি এপিসোডে মোট পুরস্কার
উদাহরণ	ঋণ ডিফল্ট অনুমান, স্প্যাম ফিল্টার	ক্রেতা সেগমেন্ট, অস্বাভাবিক লেনদেন	গেম খেলা, ট্রেডিং বট, রোবট নিয়ন্ত্রণ

সাধারণ ভিত্তি: তিনটিই অতীত তথ্য বা অভিজ্ঞতা থেকে **দেখা** (unseen) কেসে সাধারণীকরণ করে। পার্থক্য **ফিডব্যাকের ধরনে**: পূর্ণ উত্তর, কিছু নেই, কিংবা একটি নম্বর।

মনে রাখার কৌশল: একজন **শিক্ষক** উত্তর দেন (supervised) · **শিক্ষক নেই**, গোষ্ঠী খোঁজো (unsupervised) · একজন **সমালোচক** কেবল নম্বর দেন (reinforcement)।

২ Reinforcement Learning: পলিসি, পুরস্কার, ε-Greedy

উপাদান: **এজেন্ট** · **পরিবেশ** · স্টেট s · অ্যাকশন a · পুরস্কার r · **পলিসি π** (স্টেট → অ্যাকশন: RL যেটি শেখে) · ভ্যালু V(s) ও অ্যাকশন-ভ্যালু Q(s, a) · ডিসকাউন্ট γ ($0 \le \gamma \le 1$)। লক্ষ্য: রিটার্ন $G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$ সর্বোচ্চ করা।



MCQ: _____ অ্যালগরিদমে পলিসি প্রয়োজন। (supervised learning / fuzzy logic / deep learning / reinforcement learning) → **reinforcement learning** ৪৯তম BCS (ICT-281), ২০২৫

সমাধানকৃত উদাহরণ: একটি Q-learning আপডেট ✍️: সূত্র: $\mathbf{Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)]}$

Q(s, Right) = 2, পুরস্কার r = 5, s′-এ সেরা Q = 4, $\alpha = 0.5$, $\gamma = 0.9$.

১. লক্ষ্য = $r + \gamma \cdot \max Q(s') = 5 + 0.9 \times 4 = 8.6$

২. TD ত্রুটি = $8.6 - 2 = 6.6$

৩. নতুন Q(s, Right) = $2 + 0.5 \times 6.6 =$ **5.3**

ε-greedy: ε সম্ভাবনায় একটি **এলোমেলো** অ্যাকশন নাও (explore); নইলে সবচেয়ে বেশি Q-এর অ্যাকশন (exploit)। $\varepsilon = 0.1$ ও ৪টি অ্যাকশন হলে সেরা অ্যাকশন 0.9 + 0.1/4 = **0.925** সম্ভাবনায় বাছাই হয়। সাধারণত সময়ের সাথে ε কমানো হয়।

- **Q-learning**: off-policy (greedy পলিসি শেখে)
- **SARSA**: on-policy (যে পলিসি অনুসরণ করে সেটিই শেখে)
- **DQN**: নিউরাল নেট Q অনুমান করে
- ব্যবহার: গেম (AlphaGo), রোবট, ট্রেডিং, অ্যাড বিডিং

পরীক্ষার ফাঁদ: RL **অনিষ্কারিত শিক্ষা নয়**: পুরস্কার অ্যাকশনকে নম্বর দেয় কিন্তু সঠিকটা কখনো বলে না। শুধু exploitation ($\varepsilon = 0$) খারাপ অ্যাকশনে চিরকাল আটকে থাকতে পারে।

৩ লোকাল সার্চ: হিল ক্লাইম্বিং ও র‍্যান্ডম সার্চ



হিল ক্লাইম্বিং কেবল উপরে ওঠে

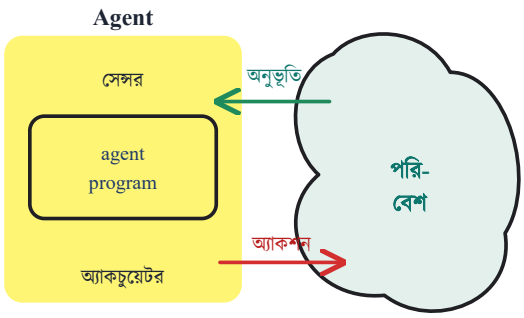
হিল ক্লাইম্বিং যতক্ষণ উন্নতি হচ্ছে সেরা প্রতিবেশীতে যায়; O(1) মেমরি। দুষ্টি: **স্থানীয় অভিসারে আটকে যায়**, সমতল ও চূড়ায়। সমাধান: র‍্যান্ডম রিস্টার্ট, সিমুলেটেড অ্যানিলিং ($e^{-\Delta E/T}$ সম্ভাবনায় খারাপ চাল গ্রহণ করে), লোকাল বিম সার্চ।

র‍্যান্ডম সার্চ গোটা স্থান থেকে প্রার্থী নমুনা নেয় এবং সেরাটি রাখে, তাই এটি একটি **গ্লোবাল অপটিমাইজেশন** পদ্ধতি: গ্রেডিয়েন্ট লাগে না, আটকে যায় না, কিন্তু ধীর এবং সর্বোচ্চ অভিসারের নিশ্চয়তা নেই। দুটি MCQ: ৪৯তম BCS (ICT-281), ২০২৫।

৪ বুদ্ধিমান ও Rational এজেন্ট

প্রশ্ন: কৃত্রিম বুদ্ধিমত্তার এজেন্ট হলো এমন একটি সত্তা যা নিরন্দন তার পরিবেশ সম্পর্কে অনুভব করে এবং তার উপর কাজ করে। ব্যাখ্যা করো। BPDB সহকারী প্রকৌশলী (CSE) · ২৪.০২.২০২৩

এজেন্ট: যা কোনো **সেন্সরের মাধ্যমে পরিবেশকে অনুভব করে** এবং **অ্যাকচুয়েটরের মাধ্যমে তার উপর কাজ করে**। এজেন্ট ফাংশন অনুভূতির ধারাকে অ্যাকশনে ম্যাপ করে; এজেন্ট = **আর্কিটেকচার** + **প্রোগ্রাম**।



Rational এজেন্ট: প্রতিটি অনুভূতির ধারায় এটি সেই অ্যাকশনটি বেছে নেয় যা **তার কর্মক্ষমতার মাপ অনুযায়ী সর্বোচ্চ করার আশা করে**, প্রাপ্ত অনুভূতি ও স্নায়ুবদ্ধ জ্ঞানের ভিত্তিতে। AI হলো rational এজেন্টের অধ্যয়ন।

বুদ্ধিমানতা নির্ভর করে: কর্মক্ষমতার মাপ, পূর্বজ্ঞান, উপলব্ধ অ্যাকশন, অনুভূতির ধারা। Rational ≠ **সর্বজ্ঞ**: এটি প্রকৃত নয়, **প্রত্যাশিত** ফলাফল সর্বোচ্চ করে। কাজের বর্ণনা **PEAS**, যেমন স্বয়ংক্রিয় ট্যাক্সি: P = নিরাপদ, দ্রুত, বৈধ যাত্রা · E = রাস্তা, যানজট · A = স্টিয়ারিং, ব্রেক, হর্ন · S = ক্যামেরা, GPS, স্পিডোমিটার।

বৈশিষ্ট্য: পরিবেশে অবস্থান · **স্বায়ত্তশাসন** (সরাসরি মানুষের নিয়ন্ত্রণ নেই) · **সাড়িশীলতা** (সময়মতো পরিবর্তনে সাড়া) · **প্রক্রিয়াশীলতা** (লক্ষ্যের দিকে উদ্যোগ নেয়) · **সামাজিক দক্ষতা** (মানুষ ও এজেন্টের সাথে কাজ করে) · শেখা।

প্রশ্ন: AI-তে এজেন্টের ধরনগুলো কী? তাদের কাজ লেখো। ৫ নম্বর ৪৫তম BCS লিখিত (CSE-971) · ৩১.০১.২০২৪

ধরন	অ্যাকশন বাছাই করে …	উদাহরণ	সীমাবদ্ধতা
① সরল রিফ্লেক্স	বর্তমান অনুভূতি + **শর্ত–অ্যাকশন নিয়ম**	থার্মোস্ট্যাট	আংশিকভাবে পর্যবেক্ষণযোগ্য হলে ব্যর্থ
② মডেল-ভিত্তিক রিফ্লেক্স	অনুভূতি + **অভ্যন্তরীণ অবস্থা** (জগৎ কীভাবে বদলায়, আমার কাজ কী করে)	অন্ধকোণের গাড়ি ট্র্যাক করা গাড়ি	সুস্পষ্ট লক্ষ্য নেই
③ লক্ষ্যভিত্তিক	মডেল + **লক্ষ্য**; **সার্চ ও পরিকল্পনা**	GPS রুট পরিকল্পক	প্রতিটি লক্ষ্য-অবস্থা সমান ভালো
④ উপযোগিতাভিত্তিক	**উপযোগিতা ফাংশন** U(state); প্রত্যাশিত উপযোগিতা সর্বোচ্চ করে	ট্যাক্সি: গতি বনাম নিরাপত্তা বনাম জ্বালানি	উপযোগিতা বানানো কঠিন
⑤ শিখনবিদ	পারফরম্যান্স এলিমেন্ট + **লার্নিং এলিমেন্ট** + সমালোচক + সমস্যা উৎপাদক	স্প্যাম ফিল্টার	তথ্য ও অন্বেষণ দরকার

মনে রাখার কৌশল: প্রতিটি ধরনে যোগ হয় **একটি** জিনিস: রিফ্লেক্স → + মেমরি → + লক্ষ্য → + খুশির নম্বর → + স্ব-উন্নতি।

পরীক্ষার ফাঁদ: লক্ষ্যভিত্তিক জিজ্ঞেস করে "**এটি লক্ষ্যে পৌঁছাবে?**"; উপযোগিতাভিত্তিক জিজ্ঞেস করে "**এই পথ কতটা ভালো?**"

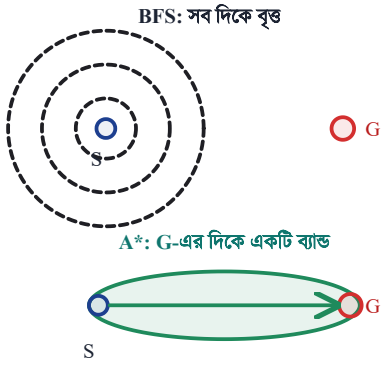
৫ হিউরিস্টিক (A*) বনাম অন্ধ (BFS) সার্চ

প্রশ্ন: একটি যুক্তিসঙ্গত যুক্তি উপস্থাপন করো যে কেন হিউরিস্টিক সার্চ (যেমন A*) অন্ধ সার্চের (যেমন BFS) চেয়ে দ্রুত হতে পারে, যদিও সব ক্ষেত্রে তা নিশ্চিতভাবে একেবারে পারফেক্ট পথ দেয় না। ১০ নম্বর ব্যাংক সহকারী প্রোগ্রামার লিখিত

১ **খরচ = বিস্তারিত নোড।** BFS তৈরি করে $1 + b + b^2 + \ldots + b^d = \mathbf{O(b^d)}$ নোড এবং সবগুলোই সংরক্ষণ করে (b = শাখা-ফ্যাক্টর, d = লক্ষ্যের গভীরতা)।

২ **BFS অন্ধ।** এটি জানে না লক্ষ্য কোথায়, তাই গভীরতা k+1-এর আগে k-তে **প্রতিটি** নোড বিস্তার করে: সব দিকে ঢেউ।

৩ **A* সূচিত।** এটি সবচেয়ে ছোট **f(n) = g(n) + h(n)** নোড বিস্তার করে (g = এখনকার খরচ, h = লক্ষ্যে আনুমানিক খরচ)। লক্ষ্যের বিপরীতে নিয়ে যাওয়া নোডের f বড় হয় এবং কখনো বিস্তার হয় না।



একই S ও G, অনেক কম নোড

৪ **ছোট কার্যকর শাখা-ফ্যাক্টর।** ভালো h b*-কে 1-এর কাছাকাছি আনে, তাই কাজ ≈ $(b^*)^d$, b^d নয়। 8-puzzle, গভীরতা 12: অন্ধ পুনরাবৃত্তিমূলক গভীরতা ≈ **৩.৬ মিলিয়ন** নোড; A* (ভুলে বসা টাইল) 227; A* (ম্যানহাটন দূরত্ব) **73**।

৫ **পথ পারফেক্ট না হওয়ার কারণ।** A* কেবল তখনই অপটিমাল যখন h **admissible** (কখনো আধিক মানায় না; গ্রাফ সার্চে **consistent**-ও: $h(n) \le c(n, n') + h(n')$)। বাস্তব সিস্টেম আরও শক্তিশালী, non-admissible h ব্যবহার করে — **ওজনযুক্ত A*** ($f = g + w \cdot h$, $w > 1$, খরচ ≤ w × অপটিমাল) বা greedy best-first (f = h): অনেক কম বিস্তার, তবে সবচেয়ে সস্তা পথ বাদ পড়তে পারে।

৬ **সিদ্ধান্ত।** গতি আসে **h-এর তথ্য থেকে** (h = 0 হলে A* হয়ে যায় uniform-cost search, অর্থাৎ সমান ধাপ-খরচে BFS)। নিশ্চিত অপটিমালিটি বদলে নির্দেশকতা দিয়ে একটি অবস্থাপূর্ণ, অফোকাস অনুসন্ধানকে কেন্দ্রিক অনুসন্ধানে রূপ দেয়; মিলিসেকেন্ডে পাওয়া প্রায়-অপটিমাল রুট (GPS, গেম, রোবট) দেরি করে পাওয়া পারফেক্ট রুটের চেয়ে ভালো।

	BFS	Uniform-cost	Greedy best-first	A*
সাজায়	গভীরতা	g(n)	h(n)	g(n) + h(n)
সম্পূর্ণ?	হ্যাঁ	হ্যাঁ	না (ট্রি সার্চ)	হ্যাঁ
অপটিমাল?	শুধু সমান ধাপ-খরচে	হ্যাঁ	না	হ্যাঁ, যদি h admissible
মেমরি	$O(b^d)$	অবস্থাপূর্ণ	অবস্থাপূর্ণ (সর্বোচ্চ)	সব নোড রাখে

পরীক্ষার ফাঁদ: "A* সবসময় সবচেয়ে ছোট পথ খোঁজে" কেবল admissible h-এর সাথে সত্য। এর সর্বোচ্চ ক্ষেত্রও অবস্থাপূর্ণ এবং আসল সীমা হলো **মেমরি** (তাই IDA*, SMA*)।

মনে রাখার কৌশল: **g** = "**গ**তো যা পার হয়েছে", **h** = "**হ**যদুরুতো বাকি"। Admissible = একজন **আশাবাদী**: লক্ষ্য আসলের চেয়ে দূর বলে কখনো বলে না।

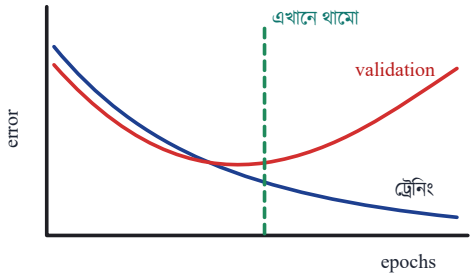
৬ ট্রেনিং বেশি, টেস্ট কম

প্রশ্ন: মেশিন লার্নিং মডেলে ট্রেনিং অ্যাকুরেসি বেশি কিন্তু টেস্টিং অ্যাকুরেসি কম হওয়ার কারণ কী, এবং এর প্রতিকারের কৌশলগুলো কী? BUET MSc in CSE · ০৩.১০.২০২৬

উত্তর: overfitting: মডেলটি সাধারণীকৃত প্যাটার্নের বদলে **ট্রেনিং সেট মুখস্থ করেছে, নয়েজসহ**: কম বায়াস, **বেশি ভ্যারিয়েন্স**; ট্রেন–টেস্টের পার্থক্যই generalization gap।

কারণ

- মডেল খুব **জটিল** (অনেক প্যারামিটার, গভীর ট্রি)
- **অল্প** তথ্য, বা অতিরিক্ত ফিচার
- **নয়েজি লেবেল** ও আউটলায়ারও ফিট হয়ে যায়
- **অনেক বেশি epoch** ট্রেনিং
- টেস্ট তথ্য **ভিন্ন বণ্টন** থেকে



প্রতিকার: ① **আরও তথ্য** / augmentation ② সরল মডেল, ফিচার সিলেকশন, ট্রি প্রুনিং ③ **রেগুলারাইজেশন**: L2 (loss + $\lambda\Sigma w^2$), L1, dropout ④ ভ্যালিডেশন লসে **early stopping** ⑤ **k-fold cross-validation** ⑥ এনসেম্বল (bagging, random forest) ⑦ পরিষ্কার লেবেল; ট্রেন ও টেস্টের একই বণ্টন। Underfitting এর বিপরীত: ট্রেন **ও** টেস্ট উভয়েই কম অ্যাকুরেসি (বেশি বায়াস)।

৭ দুর্বল বনাম শক্তিশালী শিক্ষক (এনসেম্বল)

প্রশ্ন: এনসেম্বল লার্নিং-এ দুর্বল ও শক্তিশালী শিক্ষক ব্যাখ্যা করো। GTCL সহকারী প্রকৌশলী (CSE) · ২০২২

দুর্বল শিক্ষক: কেবল **এলোমেলো অনুমানের চেয়ে সামান্য ভালো** (বাইনারি ত্রুটি 0.5-এর ঠিক নিচে), যেমন একটি **ডিসিশন স্টাম্প**।

শক্তিশালী শিক্ষক: যথেষ্ট তথ্যে **যত খুশি উচ্চ নির্ভুলতা** অর্জন করতে পারে। শাপিরে (**১৯৯০**): দুর্বল শিক্ষককে **boost** করে শক্তিশালী করা যায়।

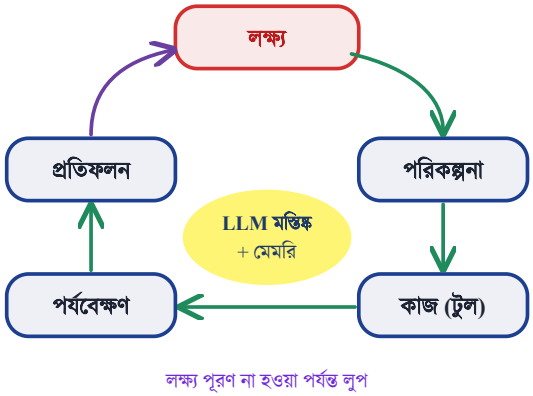
	Bagging	**Boosting**
ট্রেনিং	**সমান্তরাল**, প্রতিটি bootstrap নমুনায়	**ধারাবাহিক**; ভুল হওয়া সারিতে বেশি ওজন
সমন্বয়	সংখ্যাগরিষ্ঠ ভোট / গড়	ওজনযুক্ত ভোট $H(x) = \text{sign}(\Sigma\, \alpha_t h_t(x))$
যা কমায়	**ভ্যারিয়েন্স**	**বায়াস** (ও ভ্যারিয়েন্স)
উদাহরণ	Random Forest	AdaBoost, Gradient Boosting, XGBoost

সমাধানকৃত উদাহরণ ✍️: তিনটি স্বাধীন ক্লাসিফায়ার, প্রতিটি 70% নির্ভুল, ভোট দেয়। $P(\text{সংখ্যাগরিষ্ঠ সঠিক}) = 0.7^3 + 3(0.7^2)(0.3) = 0.343 + 0.441 = \mathbf{0.784} > 0.7$। AdaBoost-এর ওজন $\alpha_t = \tfrac{1}{2}\ln((1-\varepsilon_t)/\varepsilon_t)$ কেবল $\varepsilon_t < 0.5$ থাকা অবস্থায় ধনাত্মক।

৮ এজেন্টিক AI বনাম প্রচলিত চ্যাটবট

প্রশ্ন: Agentive AI কী? প্রচলিত Chatbot AI-এর সাথে তুলনা করো। BUET MSc in CSE · ০৩.১০.২০২৬

এজেন্টিক (agentive) AI: এমন AI সিস্টেম যাকে শুধু প্রম্পট নয়, **একটি লক্ষ্য** দেওয়া হয় এবং সে সামান্য মানব তত্ত্বাবধানে তা অনুসরণ করে: এটি ধাপ **পরিকল্পনা** করে, টুলের (API, সার্চ, কোড, ডাটাবেস, ইমেইল) মাধ্যমে **কাজ** করে, ফলাফল **পর্যবেক্ষণ** করে, **মেমরি** রাখে এবং লক্ষ্য পূরণ না হওয়া পর্যন্ত লুপে **নিজেকে সংশোধন** করে। সাধারণত একটি বড় ভাষা মডেলের (LLM) উপর গড়ে ওঠে।



গঠন-উপাদান

- **রিজনিং**: LLM লক্ষ্যকে উপ-কাজে ভাগ করে
- **পরিকল্পনা**: ব্যর্থ হলে ধাপ সংশোধন (ReAct: reason → act → observe)
- **টুল ব্যবহার**: API, কোড, ডাটাবেসে ফাংশন কল
- **মেমরি**: কনটেক্সট + দীর্ঘমেয়াদি (ভেক্টর স্টোর)
- **গার্ডরেল**: পারমিশন, মানব অনুমোদন, অডিট লগ

প্রচলিত চ্যাটবট একটি **প্রতিক্রিয়ামূলক প্রশ্নোত্তর** প্রোগ্রাম: নিয়মভিত্তিক (প্যাটার্ন বা ইনটেন্ট মিলিং, যেমন ELIZA, **১৯৬৬**) কিংবা কেবল উত্তর দেওয়া একটি LLM।

বিষয়	প্রচলিত চ্যাটবট	এজেন্টিক AI
শুরু হয়	প্রতিটি ব্যবহারকারীর বার্তা থেকে	একটি **লক্ষ্য** (বা কোনো ঘটনা) থেকে
স্বায়ত্তশাসন	নেই: প্রতিটি ধাপ ব্যবহারকারী চালায়	**বেশি**: নিজের পরবর্তী ধাপ বাছাই করে
পরিকল্পনা	নেই	ভাগ করে ও পুনরায় পরিকল্পনা করে
অ্যাকশন	শুধু লেখার উত্তর	টুলের মাধ্যমে অন্য সিস্টেমে **কাজ** করে
মেমরি	সর্বোচ্চ বর্তমান কথোপকথন	স্বল্প ও দীর্ঘমেয়াদি
মানিয়ে নেয়	নির্দিষ্ট স্ক্রিপ্ট	ফলাফল যাচাই করে, নিজেকে সংশোধন করে
ঝুঁকি	ভুল উত্তর	ভুল **কাজ**: তত্ত্বাবধান দরকার
ব্যাংকের উদাহরণ	"আমার ব্যালেন্স কত?" বলে উত্তর দেয়	ব্যর্থ ট্রান্সফার খুঁজে, লগ পড়ে, আবার চেষ্টা করে, টিকিট খোলে, গ্রাহককে জানায়

মনে রাখার কৌশল: চ্যাটবট **কথা** বলে; এজেন্ট **কাজ** করে। এজেন্টিক AI = লক্ষ্য/উপযোগিতাভিত্তিক একটি **শিখনবিদ এজেন্ট** (পাতা ৪) যার প্রোগ্রাম একটি LLM।

পরীক্ষার ফাঁদ: এজেন্টিক AI **AGI নয়**, আর শুধু "বড় চ্যাটবট"ও নয়: পার্থক্য হলো **স্বায়ত্তশাসন** + **টুল** + **লক্ষ্য-লুপ**।

৯ মার্কেট বাস্কেট বিশ্লেষণ: অ্যাপ্রিওরি

প্রশ্ন: মার্কেট বাস্কেট বিশ্লেষণের জন্য কোন মেশিন লার্নিং অ্যালগরিদম উপযুক্ত? এতে জড়িত ধাপগুলো ব্যাখ্যা করো। DPDC সহকারী ম্যানেজার (ICT) · ২৭.০৬.২০২৫

উত্তর: **অ্যাসোসিয়েশন-রুল মাইনিং অ্যাপ্রিওরি** অ্যালগরিদমে (Agrawal & Srikant, **১৯৯৪**), একটি **অনিষ্কারিত** পদ্ধতি (দ্রুত বিকল্প FP-Growth)। এটি {Diaper} → {Beer}-এর মতো নিয়ম খোঁজে: একসাথে কেনা জিনিস।

মাপ: support(X) = count(X) / N · confidence(X → Y) = support(X ∪ Y) / support(X) · lift = confidence / support(Y), > 1 = আসল সম্পর্ক।
অ্যাপ্রিওরির ধর্ম: ঘন আইটেমসেটের প্রতিটি সাবসেট ঘন, তাই কোনো ক্যান্ডিডেটে অঘন সাবসেট থাকলে সেটি গোনা ছাড়াই বাদ দেওয়া যায়।

১. **min_support** ও **min_confidence** ঠিক করো।
২. তথ্য স্ক্যান করে একক আইটেম গোনো (C_1), ≥ min_support রাখো → L_1।
৩. L_{k-1} কে নিজের সাথে **join** করে ক্যান্ডিডেট C_k; যেগুলোতে অঘন (k−1)-সাবসেট আছে তা **prune** করো।
৪. স্ক্যান করে C_k গোনো, ≥ min_support রাখো → L_k; L_k = ∅ না হওয়া পর্যন্ত ৩–৪ বার পুনরাবৃত্তি।
৫. প্রতিটি ঘন আইটেমসেট থেকে নিয়ম X → Y বানাও; confidence ≥ min_confidence রাখো, lift দেখো।

সমাধানকৃত উদাহরণ ✍️: ৫টি বাস্কেট, min_support = 3 (60%), min_confidence = 70%।

T	আইটেম
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Cola
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Cola

C_1: Bread 4, Milk 4, Diaper 4, Beer 3, Cola 2 ✗, Eggs 1 ✗

C_2: {B,M} 3 · {B,D} 3 · {M,D} 3 · {D,Beer} 3 · {B,Beer} 2 ✗ · {M,Beer} 2 ✗

C_3: {B,D,Beer}, {M,D,Beer} pruned (অঘন সাবসেট); {B,M,D} = 2 ✗ → **L_3 = ∅, থামো**

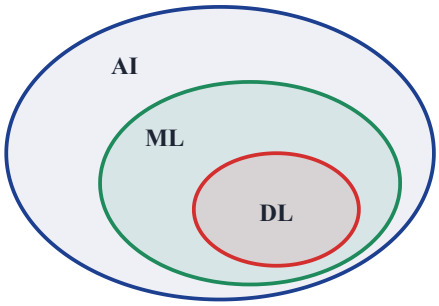
নিয়ম	Support	Confidence	Lift	রায়
Beer → Diaper	3/5	3/3 = 100%	1.0/0.8 = **1.25**	**শক্তিশালী ✓**
Diaper → Beer	3/5	3/4 = 75%	0.75/0.6 = **1.25**	**শক্তিশালী ✓**
Bread → Milk	3/5	3/4 = 75%	0.75/0.8 = 0.94	lift < 1: আসল সংযোগ নেই

পরীক্ষার ফাঁদ: শুধু confidence ভোলায়: Bread → Milk-এর confidence 75%, কিন্তু মোট বাস্কেটের 80%-তেই Milk আছে, তাই lift 0.94।

মনে রাখার কৌশল: **"একটি বিরল সেট, প্রতিটি বড় সেটকেও বিরল করে দেয়"**: এটিই pruning। ব্যবহার: শেলফ সাজানো, ক্রস-সেলিং, ব্যাংকের পণ্য বান্ডিল।

FP-Growth বাস্কেটগুলো একটি **FP-tree**-তে সংকুচিত করে এবং মাত্র **২বার ডাটাবেস স্ক্যানে, কোনো ক্যান্ডিডেট তৈরি না করেই** খনন করে, তাই বড় তথ্যে অ্যাপ্রিওরির চেয়ে দ্রুত।

১০ ডিপ লার্নিং, ব্যাকপ্রোপাগেশন, RNN



AI ⊃ ML ⊃ ডিপ লার্নিং

ডিপ লার্নিং: ML-এর সেই অংশ যা **অনেক হিডলেন লেয়ারের নিউরাল নেট** ব্যবহার করে, যা কাঁচা তথ্য থেকে সরাসরি ফিচার শেখে।

	প্রচলিত ML	ডিপ লার্নিং
ফিচার	হাতে তৈরি	**স্বয়ংক্রিয়ভাবে শেখা**
তথ্য, কমপিউট	অল্প–মাঝারি, CPU	বড় তথ্য, GPU
ব্যাখ্যাযোগ্যতা	সহজ	"কালো বাক্স"

ব্যাকপ্রোপাগেশন: ① **ফরওয়ার্ড পাস**: আউটপুট ও লস L ② **ব্যাকওয়ার্ড পাস**: **চেইন রুল** প্রতিটি ওজনের $\partial L/\partial w$ দেয়, আউটপুট লেয়ার থেকে শুরু করে ③ **আপডেট** গ্রেডিয়েন্ট ডিসসেন্টে $\mathbf{w} \leftarrow \mathbf{w} - \eta \cdot \partial L/\partial \mathbf{w}$ (η = লার্নিং রেট)। এতে MLP, CNN ও RNN (সময়ের মাধ্যমে ব্যাকপ্রোপাগেশন, BPTT) প্রশিক্ষিত হয়।

নেটওয়ার্ক	কীসের জন্য	মূল ভাবনা
MLP / ANN	ট্যাবুলার তথ্য	সম্পূর্ণ সংযুক্ত লেয়ার
CNN	ছবি (স্থানিক তথ্য)	কনভোলিউশন ফিল্টার, পুলিং, শেয়ার্ড ওজন
RNN / LSTM / GRU	**ধারাবাহিকতা, টাইম সিরিজ**, বাকি	হিডলেন স্টেট অতীত বহন করে: $h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$
Transformer	ভাষা (LLM)	গোটা ধারার উপর self-attention

পরীক্ষার ফাঁদ: সাধারণ RNN দীর্ঘ ধারায় **ভ্যানিশিং গ্রেডিয়েন্ট**-এ ভোগে; LSTM/GRU-র গেট এটি ঠিক করে। গ্রেডিয়েন্ট ডিসসেন্ট একটি **অপটিমাইজেশন পদ্ধতি** যা শেখার ভেতরে ব্যবহৃত হয়, নিজে AI-র কৌশল নয়।

১১ ন্যাচারাল ল্যাঙ্গুয়েজ প্রসেসিং

পাইপলাইন: টোকেনাইজেশন → স্টপ-ওয়ার্ড সরানো → স্টেমিং / লেম্মাটাইজেশন → POS ট্যাগিং → পার্সিং → সেমান্টিক্স।

ওয়ার্ড এমবেডিং (Word2Vec, GloVe) শব্দকে ঘন ভেক্টরে ম্যাপ করে যেখানে কাছাকাছি অর্থ কাছাকাছি থাকে: **king − man + woman ≈ queen**।

মূল চ্যালেঞ্জ: অস্পষ্টতা

- শব্দগত: "bank" (নদী না টাকা)
- বাক্যগত: "I saw the man with the telescope"
- নির্দেশক: "Rahim told Karim he passed": কে পাশ করেছে?

মনে রাখার কৌশল: ক্যামেরার ছবির জন্য **C**NN, পুনরাবৃত্ত ধারার জন্য **R**NN; stemming **কাটে** ("studies" → "studi"), lemmatisation **খোঁজে** ("studies" → "study")।

১২ যে MCQ এসেছে: ৪৯তম BCS (ICT-281), ২০২৫

প্রশ্ন (অপশন)	উত্তর	কেন
AI-র কৌশল নয়? (gradient descent / genetic algorithm / deep learning / reinforcement learning)	**gradient descent**	একটি ক্যালকুলাস অপটিমাইজার; বাকিগুলো AI পদ্ধতি
কোন ML মডেলে ব্যাকপ্রোপাগেশন? (MLP / CNN / RNN / সবগুলো)	**সবগুলোই**	RNN BPTT-এর মাধ্যমে
টাইম-সিরিজের জন্য সেরা? (CNN / RNN / DNN / ANN)	**RNN**	হিডলেন স্টেট অতীত মনে রাখে
___ অ্যালগরিদমে পলিসি লাগে (supervised / fuzzy / deep / reinforcement)	**reinforcement**	পলিসি π: স্টেট → অ্যাকশন
হিল ক্লাইম্বিং-এর মূল দুষ্টি? (memory / local optima / সব বিস্তার / heuristic দরকার)	**local optima**	greedy, কখনো নিচে যায় না
র‍্যান্ডম সার্চ হলো ___ (greedy / local opt. / optimal / global optimisation)	**গ্লোবাল অপটিমাইজেশন**	গোটা স্থান থেকে নমুনা নেয়
রিগ্রেশন মেট্রিক নয়? (R^2 / RMSE / Recall / MAE)	**Recall**	TP/(TP + FN): শ্রেণিবিন্যাস
শব্দ → অর্থ ভেক্টর? (tokenisation / embeddings / stemming / POS)	**word embeddings**	Word2Vec, GloVe
NLP-এর মূল চ্যালেঞ্জ? (ambiguity / POS / syntax / tokenisation)	**অস্পষ্টতা**	এক বাক্য, অনেক অর্থ

রিগ্রেশন: MAE = mean$|y - \hat{y}|$ · RMSE = $\sqrt{\text{mean}(y - \hat{y})^2}$ · $R^2 = 1 - SS_{res}/SS_{tot}$। শ্রেণিবিন্যাস: accuracy, precision TP/(TP + FP), recall, **F1**।

১৩ ভাইভা দ্রুত-প্রশ্ন (ব্যাংক আইটি ভাইভা)

AI কী? → মানুষের বুদ্ধিমত্তা লাগে এমন কাজ মেশিন করা: শেখা, যুক্তি, উপলব্ধি, ভাষা, সিদ্ধান্ত। পরিভাষা: জন ম্যাকার্থি, ডার্টমাউথ **১৯৫৬**।

ML কী? → তথ্য থেকে প্যাটার্ন শিখে ও স্পষ্ট প্রোগ্রামিং ছাড়াই উন্নত হওয়া AI (অনেক বোতল দেখিয়ে একটি নতুন চিনতে শেখে)।

ডিপ লার্নিং কী? → অনেক লেয়ারের নিউরাল নেট দিয়ে ML, যেখানে ফিচার নিজেরাই শেখে।

ML বনাম DL? → ML: হাতে বানানো ফিচার, কম তথ্য, ব্যাখ্যাযোগ্য। DL: স্বয়ংক্রিয় ফিচার, বড় তথ্য + GPU, কালো বাক্স।

Normal বনাম super AI? → Narrow AI একটি কাজ করে (ভয়েস অ্যাসিস্ট্যান্ট, রিকমেন্ডার): **আজকের সব AI**। AGI মানুষের মতো হবে; super AI সব ক্ষেত্রে মানুষকে ছাপিয়ে যাবে: কল্পনামূলক।

স্বায়ত্তশাসিত অস্ত্র? → সামান্য বা কোনো মানব হস্তক্ষেপ ছাড়াই লক্ষ্য শনাক্ত, নির্বাচন ও আক্রমণকারী সামরিক ব্যবস্থা।

কীভাবে কাজ করে? → সেন্সর (ক্যামেরা, রাডার, GPS) → AI/ML লক্ষ্য চিনে → সিদ্ধান্তের যুক্তি → অ্যাকচুয়েটর গুলি করে বা পথ ঘোরায়। সমস্যা: দায়বদ্ধতা, অর্থবহ মানব নিয়ন্ত্রণ।

রোবোটিক্স? → এমন রোবট ডিজাইন, নির্মাণ ও প্রোগ্রাম করা যারা ন্যূনতম মানব সহায়তায় অনুভব, সিদ্ধান্ত ও কাজ করে।

ব্যাংকে রোবোটিক্স? → নগদ সাজানোর মেশিন, ডকুমেন্ট স্ক্যানিং, সার্ভিস রোবট ও চ্যাটবট, এবং নিয়ম-ভিত্তিক ব্যাক-অফিস কাজের জন্য **RPA** বট (KYC যাচাই, রিকন্সিলিয়েশন, রিপোর্ট)।

AI-তে কেন Python? → সহজ সিনট্যাক্স; লাইব্রেরি NumPy, pandas, scikit-learn, TensorFlow, PyTorch, Keras।

পরীক্ষার আগের রাতের পাতা

সূত্র ও তথ্য:

A*: $f(n) = g(n) + h(n)$

Admissible: $h(n) \le$ প্রকৃত খরচ

Consistent: $h(n) \le c(n, n') + h(n')$

BFS: $O(b^d)$ সময় ও স্থান

$G = \Sigma\, \gamma^k\, r_{t+k+1}$

$Q \leftarrow Q + \alpha[r + \gamma \max Q' - Q]$

ε-greedy: ε সম্ভাবনায় এলোমেলো

$w \leftarrow w - \eta\, \partial L/\partial w$

$\text{conf}(X \to Y) = \text{sup}(X \cup Y)/\text{sup}(X)$

lift = conf/sup(Y), > 1 ভালো

AdaBoost $\alpha = \frac{1}{2} \ln((1 - \varepsilon)/\varepsilon)$

৩ ভোটার $0.7 \to 0.784$

এক লাইনে

1. Supervised = লেবেল; unsupervised = নেই; RL = পুরস্কার
2. পলিসি → reinforcement learning
3. এজেন্ট = সেন্সর + অ্যাকচুয়েটর
4. ৫ এজেন্ট: রিফ্লেক্স, মডেল, লক্ষ্য, উপযোগিতা, শেখা
5. Rational ≠ সর্বজ্ঞ; কাজ = PEAS
6. A* অপটিমাল iff h admissible (ট্রি)
7. হিল ক্লাইম্বিং → স্থানীয় অভিসার
8. র‍্যান্ডম সার্চ → গ্লোবাল অপটিমাইজেশন
9. ট্রেন বেশি, টেস্ট কম = overfitting
10. Bagging ↓ ভ্যারিয়েন্স; boosting ↓ বায়াস
11. দুর্বল শিক্ষক ≈ এলোমেলোর সামান্য উপরে
12. মার্কেট বাস্কেট → অ্যাপ্রিওরি, FP-Growth
13. Backprop: MLP, CNN, RNN (BPTT)
14. টাইম সিরিজ → RNN; ছবি → CNN

সবচেয়ে বড় ফাঁদ: RL অনিষ্কারিত শিক্ষা নয় · A* কেবল admissible h-এ অপটিমাল · greedy best-first অপটিমাল নয় · BFS কেবল সমান ধাপ-খরচে অপটিমাল · gradient descent একটি অপটিমাইজার · lift ছাড়া confidence ভোলায় · এজেন্টিক AI ≠ AGI · আজকের সব AI narrow AI

সব কৌশল একসাথে: শিক্ষক / শিক্ষক নেই / সমালোচক · প্রতিটি এজেন্টের ধরনে একটি জিনিস যোগ · g = গতো যা পার হয়েছে, h = হযদুরুতো বাকি · একটি বিরল সেট বড় সেটকেও বিরল করে · চ্যাটবট কথা বলে, এজেন্ট কাজ করে · CNN = ক্যামেরা, RNN = recurring



এজেন্টের সিঁড়ি: প্রতিটি ধাপে একটি যোগ ক্ষমতা

লিখিতের কৌশল: "পার্থক্য লেখো" → ৬–৮ সারির টেবিল, প্রতিটি কলামে একটি উদাহরণ। "ব্যাখ্যা করো" → সংজ্ঞা, চিত্র, বৈশিষ্ট্য, উদাহরণ। ১০ নম্বরের "যুক্তি দাও" → নম্বরযুক্ত প্রকল্প ও এক লাইনের সিদ্ধান্ত।

✓ অনুশীলন MCQ (পরীক্ষায় আসা টপিক থেকে)

১. লেবেলযুক্ত ইনপুট–আউটপুট জোড় থেকে শেখা কী?
ক) reinforcement খ) unsupervised
গ) supervised ঘ) clustering

২. শুধু বর্তমান অনুভূতি ও if-then নিয়মে কাজ করা এজেন্ট:
ক) সরল রিফ্লেক্স খ) লক্ষ্যভিত্তিক
গ) উপযোগিতাভিত্তিক ঘ) শিখনবিদ

৩. A* (ট্রি সার্চ) কখন অপটিমাল? h(n) যখন:
ক) এলোমেলো খ) প্রকৃত খরচের চেয়ে বড়
গ) ঋণাত্মক ঘ) admissible

৪. ট্রেনিং বেশি কিন্তু টেস্ট অ্যাকুরেসি কম মানে:
ক) underfitting খ) overfitting
গ) high bias ঘ) পরিষ্কার তথ্য

৫. Random Forest কোনের উদাহরণ?
ক) bagging খ) boosting
গ) stacking ঘ) clustering

৬. sup({A, B}) = 0.4, sup({A}) = 0.5. conf(A → B) =
ক) 0.2 খ) 0.4
গ) 0.8 ঘ) 0.9

৭. শেয়ার দামের টাইম-সিরিজের জন্য সেরা নেটওয়ার্ক:
ক) CNN খ) decision stump
গ) k-means ঘ) LSTM

৮. ε-greedy-তে ε কীসের সম্ভাবনা?
ক) exploit করা খ) এলোমেলো explore করা
গ) থামা ঘ) ডিসকাউন্ট করা

৯. একটি শ্রেণিবিন্যাস মেট্রিক (রিগ্রেশন নয়):
ক) F1 score খ) MAE
গ) RMSE ঘ) R^2

১০. এজেন্টিক AI ও চ্যাটবটের মধ্যে প্রধান পার্থক্য কী?
ক) লেখার উত্তর খ) LLM ব্যবহার
গ) টুলের মাধ্যমে পরিকল্পনা ও কাজ ঘ) অনেক ভাষা

উত্তরমালা → ১-গ · ২-ক · ৩-ঘ · ৪-খ · ৫-ক · ৬-গ · ৭-ঘ · ৮-খ · ৯-ক · ১০-গ

লিখিত প্রশ্ন: একটি rational এজেন্ট সংজ্ঞায়িত করো। এজেন্টের পাঁচ ধরন বর্ণনা করো এবং বলো স্বয়ংক্রিয় ট্যাক্সি কোন ধরনের হওয়া উচিত ও কেন। ১০ নম্বর

১ Rational এজেন্ট: নিজের অনুভূতি ও জ্ঞান থেকে যে অ্যাকশনের কর্মক্ষমতার মাপ সর্বোচ্চ হবে আশা করে সেটি বাছাই করে; rational ≠ সর্বজ্ঞ। ২

২ পাঁচ ধরন, একেকটি এক লাইনে: সরল রিফ্লেক্স (বর্তমান অনুভূতিতে নিয়ম), মডেল-ভিত্তিক (অভ্যন্তরীণ অবস্থা), লক্ষ্যভিত্তিক (সার্চ/পরিকল্পনা), উপযোগিতাভিত্তিক (প্রত্যাশিত উপযোগিতা সর্বোচ্চ), শিখনবিদ (সমালোচক + লার্নিং এলিমেন্ট)। ৫

৩ ট্যাক্সি = **উপযোগিতাভিত্তিক শিখনবিদ এজেন্ট**: আংশিকভাবে পর্যবেক্ষণযোগ্য, স্টোকাস্টিক রাস্তা মডেল দরকার; এটি গতি, নিরাপত্তা, আরাম, জ্বালানির (উপযোগিতা) আপস করে এবং অভিজ্ঞতায় উন্নত হয়। ২

৪ শেষে তার PEAS লাইনটি লেখো। ১

পরীক্ষার আগে যাচাই ✓

- ✓ Supervised / unsupervised / RL-এর টেবিল
- ✓ এজেন্টের চিত্র + ৫ ধরন
- ✓ A* বনাম BFS-এর যুক্তি ধাপে ধাপে
- ✓ lift সহ ৫ বাস্কেটে অ্যাপ্রিওরি

আরও অনুশীলন:
① এজেন্টিক AI বনাম চ্যাটবট
② ওভারফিটিং: কারণ, সমাধান
③ Bagging বনাম boosting