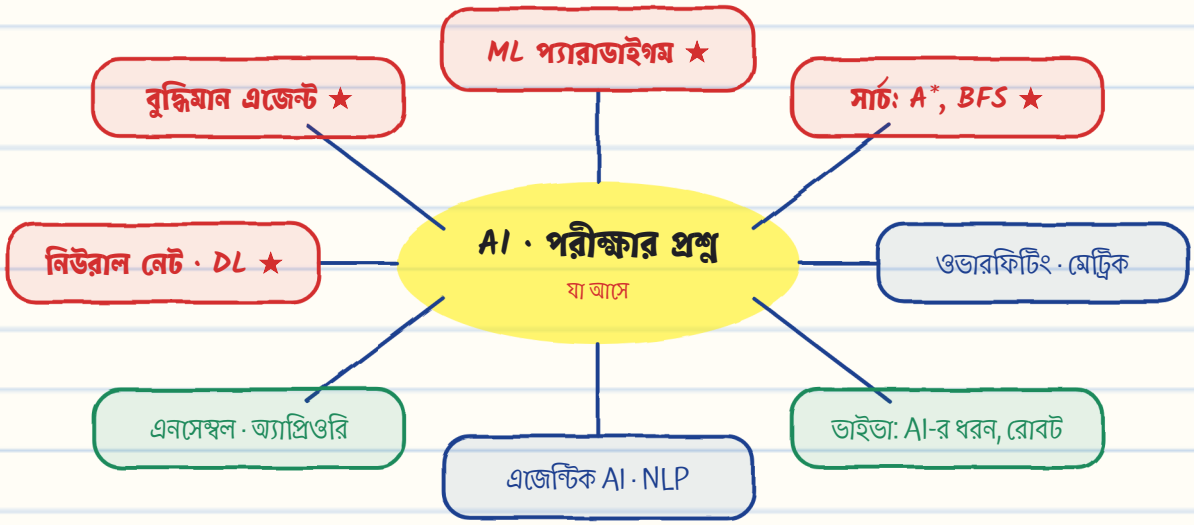
# সমাধানসহ পরীক্ষার প্রশ্ন: কৃত্রিম বুদ্ধিমত্তা

*BCS, BUET-ধরনের, পাওয়ার সেক্টর ও ব্যাংকের পত্র ও ভাইভার ৩০টি প্রশ্ন, ১২ পাতায় সমাধান*




↑ লাল = সবচেয়ে বেশি আসে (লিখিত + MCQ + ভাইভা মিলিয়ে)

## ➜ যেসব পত্র নেওয়া হয়েছে

- ৪৫তম BCS লিখিত (CSE-971), ৩১.০১.২০২৪
- ৪৯তম BCS (ICT-281) MCQ পত্র, ২০২৫: ৯টি AI MCQ
- BPDB AE (CSE) ২৪.০২.২০২৩ · GTCL AE (CSE) ২০২২
- DPDC AM (ICT) ২৭.০৬.২০২৫ · BUET MSc in CSE ০৩.১০.২০২৬
- ব্যাংক সহকারী প্রোগ্রামার লিখিত · ব্যাংক আইটি ভাইভা

**সবচেয়ে বেশি আসে**

① Supervised বনাম unsupervised বনাম reinforcement (৩টি লিখিত)
② এজেন্ট: rational agent, ৫ ধরন
③ A* বনাম BFS, hill climbing
④ DL, backprop, RNN

**সংকেত** হলুদ = মূল শব্দ · **লাল বৃত্ত** = মুখস্থ রাখার তথ্য · **বেগুনি** = মনে রাখার কৌশল · **লাল বক্স** = পরীক্ষার ফাঁদ · **সবুজ** = সমাধানকৃত উদাহরণ · **নীল বক্স** = প্রশ্ন যেমন এসেছে

## ➜ সূচিপত্র

✓ ML: তিনটি প্যারাডাইগম ..... পৃ. ২
✓ Reinforcement ও local search ... পৃ. ৩
✓ বুদ্ধিমান ও rational এজেন্ট ... পৃ. ৪
✓ A* বনাম BFS ..... পৃ. ৫
✓ ওভারফিটিং, এনসেম্বল ..... পৃ. ৬
✓ এজেন্টিক AI বনাম চ্যাটবট ..... পৃ. ৭
✓ মার্কেট বাস্কেট: অ্যাপ্রিওরি ..... পৃ. ৮
✓ ডিপ লার্নিং, NLP ..... পৃ. ৯
✓ MCQ + ভাইভা ..... পৃ. ১০
✓ রাতের পাতা ..... পৃ. ১১
✓ অনুশীলন MCQ + লিখিত ..... পৃ. ১২

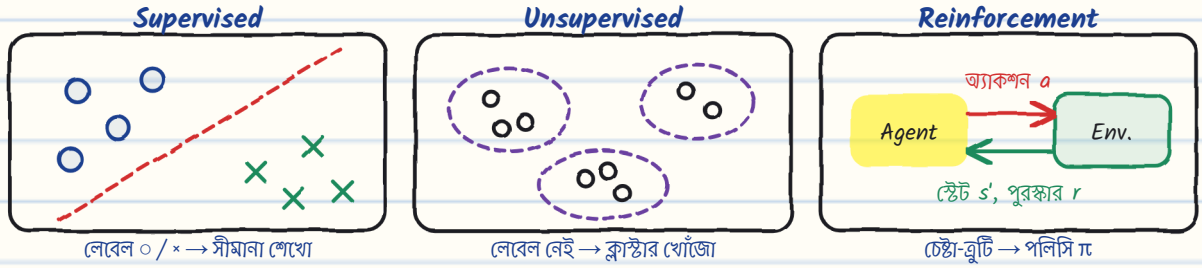
# ১ মেশিন লার্নিং: তিনটি প্যারাডাইগম

৩টি লিখিত + ভাইভা

**প্রশ্ন** মেশিন লার্নিং কী? *supervised, unsupervised* ও *reinforcement learning*-এর মধ্যে পার্থক্য লেখো। ৪৫তম BCS লিখিত (CSE-971) · ৩১.০১.২০২৪; অন্য একটি লিখিত পত্রেও এসেছে

**প্রশ্ন** ML-এর তিনটি মৌলিক প্যারাডাইগম তুলনা করো। ১০ নম্বর ব্যাংক সহকারী প্রোগ্রামার লিখিত

**মেশিন লার্নিং** AI-এর সেই শাখা যেখানে সিস্টেম স্পষ্টভাবে প্রোগ্রাম না করে তথ্য বা অভিজ্ঞতা থেকে শেখে (Samuel, ১৯৫৯)। মিচেল: কোনো প্রোগ্রাম কাজ **T**-তে অভিজ্ঞতা **E** থেকে মাপ **P** অনুযায়ী শিখলে যদি T-তে তার কর্মক্ষমতা E-এর সাথে **বাড়ে**।




লেবেল ○ / × → সীমানা শেখো | লেবেল নেই → ক্লাস্টার খোঁজো | চেষ্টা-ত্রুটি → পলিসি π

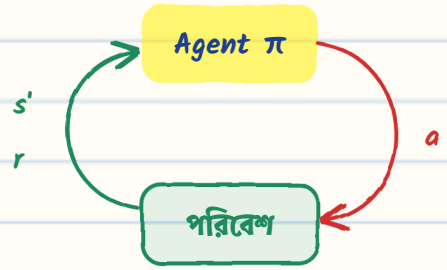
| বিষয় | Supervised | Unsupervised | Reinforcement |
|---|---|---|---|
| তথ্য | লেবেলযুক্ত জোড় (x, y) | শুধু লেবেলবিহীন x | প্রতিক্রিয়া থেকে অভিজ্ঞতা (s, a, r, s') |
| ফিডব্যাক | প্রতি উদাহরণে সঠিক উত্তর | কিছু নেই | একটি স্কেলার **reward**, প্রায়ই বিলম্বিত |
| লক্ষ্য | $f : x \to y$ শেখা; অনুমান | লুকানো কাঠামো আবিষ্কার | এমন পলিসি $\pi(s) \to a$ শেখা যা মোট পুরস্কার বাড়ায় |
| কাজ | শ্রেণিবিন্যাস, রিগ্রেশন | ক্লাস্টারিং, PCA, অ্যাসোসিয়েশন নিয়ম | ধারাবাহিক সিদ্ধান্ত, নিয়ন্ত্রণ |
| অ্যালগরিদম | লিনিয়ার/লজিস্টিক রিগ্রেশন, ডিসিশন ট্রি, SVM, k-NN, নেভ বেস | k-means, হায়ারার্কিক্যাল, DBSCAN, PCA, অ্যাপ্রিওরি | Q-learning, SARSA, DQN, পলিসি গ্রেডিয়েন্ট |
| মূল্যায়ন | accuracy, F1, RMSE টেস্ট তথ্যে | সিলুয়েট, support/lift | প্রতি এপিসোডে মোট পুরস্কার |
| উদাহরণ | ঋণ ডিফল্ট অনুমান, স্প্যাম ফিল্টার | ক্রেতা সেগমেন্ট, অস্বাভাবিক লেনদেন | গেম খেলা, ট্রেডিং বট, রোবট নিয়ন্ত্রণ |

**সাধারণ ভিত্তি** তিনটিই অতীত তথ্য বা অভিজ্ঞতা থেকে **দেখা** (unseen) কেসে সাধারণীকরণ করে। পার্থক্য ফিডব্যাকের ধরনে: পূর্ণ উত্তর, কিছু নেই, কিংবা একটি নম্বর।

**মনে রাখার কৌশল** একজন **শিক্ষক** উত্তর দেন (supervised) · **শিক্ষক নেই**, গোষ্ঠী খোঁজো (unsupervised) · একজন **সমালোচক** কেবল নম্বর দেন (reinforcement)।

## ২ Reinforcement Learning: পলিসি, পুরস্কার, ε-Greedy

**উপাদান** **এজেন্ট** · **পরিবেশ** · স্টেট $s$ · অ্যাকশন $a$ · পুরস্কার $r$ · পলিসি $\pi$ (স্টেট → অ্যাকশন; RL যেটি শেখে) · ভ্যালু $V(s)$ ও অ্যাকশন-ভ্যালু $Q(s, a)$ · ডিসকাউন্ট $\gamma$ ($0 \le \gamma \le 1$)। লক্ষ্য: রিটার্ন $G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$ সর্বোচ্চ করা।




**MCQ** _____ অ্যালগরিদমে পলিসি প্রয়োজন। (supervised learning / fuzzy logic / deep learning / reinforcement learning) → **reinforcement learning** ৪৯তম BCS (ICT-281), ২০২৫

**সমাধানকৃত উদাহরণ: একটি Q-learning আপডেট** সূত্র: $Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)]$

$Q(s, Right) = 2$, পুরস্কার $r = 5$, $s'$-এ সেরা $Q = 4$, $\alpha = 0.5$, $\gamma = 0.9$.

১. লক্ষ্য $= r + \gamma \cdot \max Q(s') = 5 + 0.9 \times 4 = 8.6$
২. TD ত্রুটি $= 8.6 - 2 = 6.6$
৩. নতুন $Q(s, Right) = 2 + 0.5 \times 6.6 =$ **5.3**

**ε-greedy** ε সম্ভাবনায় একটি **এলোমেলো** অ্যাকশন নাও (explore); নইলে সবচেয়ে বেশি Q-এর অ্যাকশন (exploit)। $\varepsilon = 0.1$ ও ৪টি অ্যাকশন হলে সেরা অ্যাকশন $0.9 + 0.1/4 =$ **0.925** সম্ভাবনায় বাছাই হয়। সাধারণত সময়ের সাথে ε কমানো হয়।

- **Q-learning**: off-policy (greedy পলিসি শেখে)
- **SARSA**: on-policy (যে পলিসি অনুসরণ করে সেটিই শেখে)
- **DQN**: নিউরাল নেট Q অনুমান করে
- ব্যবহার: গেম (AlphaGo), রোবট, ট্রেডিং, অ্যাড বিডিং

**পরীক্ষার ফাঁদ** RL **অনিষ্কারিত শিক্ষা নয়**: পুরস্কার অ্যাকশনকে নম্বর দেয় কিন্তু সঠিকটা কখনো বলে না। শুধু exploitation ($\varepsilon = 0$) খারাপ অ্যাকশনে চিরকাল আটকে থাকতে পারে।

## ৩ লোকাল সার্চ: হিল ক্লাইম্বিং ও র‍্যান্ডম সার্চ ২টি MCQ




হিল ক্লাইম্বিং কেবল উপরে ওঠে

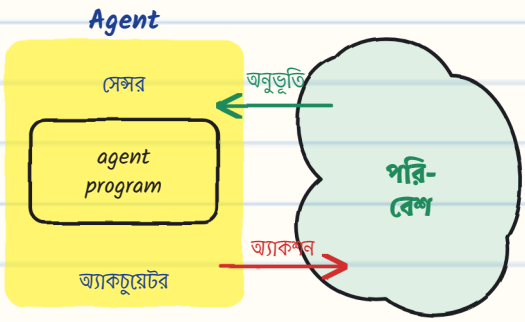
**হিল ক্লাইম্বিং** যতক্ষণ উন্নতি হচ্ছে সেরা প্রতিবেশীতে যায়; $O(1)$ মেমরি। দুষ্টি: স্থানীয় অভিসারে আটকে যায়, সমতল ও চূড়ায়। সমাধান: র‍্যান্ডম রিস্টার্ট, সিমুলেটেড অ্যানিলিং ($e^{-\Delta E/T}$ সম্ভাবনায় খারাপ চাল গ্রহণ করে), লোকাল বিম সার্চ।

**র‍্যান্ডম সার্চ গোটা** স্থান থেকে প্রার্থী নমুনা নেয় এবং সেরাটি রাখে, তাই এটি একটি গ্লোবাল অপটিমাইজেশন পদ্ধতি: গ্রেডিয়েন্ট লাগে না, আটকে যায় না, কিন্তু ধীর এবং সর্বোচ্চ অভিসারের নিশ্চয়তা নেই। দুটি MCQ: ৪৯তম BCS (ICT-281), ২০২৫।

## ৪ বুদ্ধিমান ও Rational এজেন্ট ২টি লিখিত

**প্রশ্ন** কৃত্রিম বুদ্ধিমত্তার এজেন্ট হলো এমন একটি সত্তা যা নিরন্দন তার পরিবেশ সম্পর্কে অনুভব করে এবং তার উপর কাজ করে। ব্যাখ্যা করো। *BPDB সহকারী প্রকৌশলী (CSE) · ২৪.০২.২০২৩*

**এজেন্ট** যা কোনো সেন্সরের মাধ্যমে পরিবেশকে অনুভব করে এবং অ্যাকচুয়েটরের মাধ্যমে তার উপর কাজ করে। এজেন্ট ফাংশন অনুভূতির ধারাকে অ্যাকশনে ম্যাপ করে; এজেন্ট = **আর্কিটেকচার + প্রোগ্রাম**।




**Rational এজেন্ট** প্রতিটি অনুভূতির ধারায় এটি সেই অ্যাকশনটি বেছে নেয় যা **তার কর্মক্ষমতার মাপ অনুযায়ী সর্বোচ্চ করার আশা করে**, প্রাপ্ত অনুভূতি ও স্নায়ুবদ্ধ জ্ঞানের ভিত্তিতে। *AI হলো rational এজেন্টের অধ্যয়ন।*

**বুদ্ধিমানতা নির্ভর করে:** কর্মক্ষমতার মাপ, পূর্বজ্ঞান, উপলব্ধ অ্যাকশন, অনুভূতির ধারা। *Rational ≠* **সর্বজ্ঞ**; এটি প্রকৃত নয়, **প্রত্যাশিত** ফলাফল সর্বোচ্চ করে। কাজের বর্ণনা *PEAS*, যেমন স্বয়ংক্রিয় ট্যাক্সি: *P* = নিরাপদ, দ্রুত, বৈধ যাত্রা · *E* = রাস্তা, যানজট · *A* = স্টিয়ারিং, ব্রেক, হর্ন · *S* = ক্যামেরা, *GPS*, স্পিডোমিটার।

**বৈশিষ্ট্য:** পরিবেশে অবস্থান · **স্বায়ত্তশাসন** (সরাসরি মানুষের নিয়ন্ত্রণ নেই) · **সাড়িশীলতা** (সময়মতো পরিবর্তনে সাড়া) · **প্রক্রিয়াশীলতা** (লক্ষ্যের দিকে উদ্যোগ নেয়) · **সামাজিক দক্ষতা** (মানুষ ও এজেন্টের সাথে কাজ করে) · শেখা।

**প্রশ্ন** *AI-তে এজেন্টের ধরনগুলো কী? তাদের কাজ লেখো।* ৫ নম্বর *৪৫তম BCS লিখিত (CSE-971) · ৩১.০১.২০২৪*

| ধরন | অ্যাকশন বাছাই করে … | উদাহরণ | সীমাবদ্ধতা |
|---|---|---|---|
| ① সরল রিফ্লেক্স | বর্তমান অনুভূতি + **শর্ত–অ্যাকশন নিয়ম** | থার্মোস্ট্যাট | আংশিকভাবে পর্যবেক্ষণযোগ্য হলে ব্যর্থ |
| ② মডেল-ভিত্তিক রিফ্লেক্স | অনুভূতি + **অভ্যন্তরীণ অবস্থা** (জগৎ কীভাবে বদলায়, আমার কাজ কী করে) | অন্ধকোণের গাড়ি ট্র্যাক করা গাড়ি | সুস্পষ্ট লক্ষ্য নেই |
| ③ লক্ষ্যভিত্তিক | মডেল + **লক্ষ্য**; সার্চ ও পরিকল্পনা | *GPS* রুট পরিকল্পক | প্রতিটি লক্ষ্য-অবস্থা সমান ভালো |
| ④ উপযোগিতাভিত্তিক | **উপযোগিতা ফাংশন** *U(state)*; প্রত্যাশিত উপযোগিতা সর্বোচ্চ করে | ট্যাক্সি: গতি বনাম নিরাপত্তা বনাম জ্বালানি | উপযোগিতা বানানো কঠিন |
| ⑤ শিখনবিদ | পারফরম্যান্স এলিমেন্ট + **লার্নিং এলিমেন্ট** + সমালোচক + সমস্যা উৎপাদক | স্প্যাম ফিল্টার | তথ্য ও অন্বেষণ দরকার |

**মনে রাখার কৌশল** প্রতিটি ধরনে যোগ হয় **একটি** জিনিস: রিফ্লেক্স → + মেমরি → + লক্ষ্য → + খুশির নম্বর → + স্ব-উন্নতি।

**পরীক্ষার ফাঁদ** লক্ষ্যভিত্তিক জিজ্ঞেস করে "**এটি লক্ষ্যে পৌঁছাবে?**"; উপযোগিতাভিত্তিক জিজ্ঞেস করে "**এই পথ কতটা ভালো?**"

# ৫ হিউরিস্টিক (A*) বনাম অন্ধ (BFS) সার্চ

১০ নম্বর লিখিত

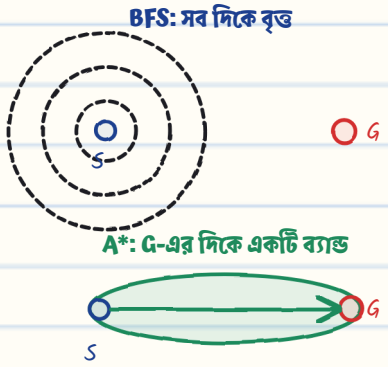
**প্রশ্ন** একটি যুক্তিসঙ্গত যুক্তি উপস্থাপন করো যে কেন হিউরিস্টিক সার্চ (যেমন A*) অন্ধ সার্চের (যেমন BFS) চেয়ে দ্রুত হতে পারে, যদিও সব ক্ষেত্রে তা নিশ্চিতভাবে একেবারে পারফেক্ট পথ দেয় না।

১০ নম্বর ব্যাংক সহকারী প্রোগ্রামার লিখিত

১ **খরচ = বিস্তারিত নোড।** BFS তৈরি করে $1 + b + b^2 + \dots + b^d = O(b^d)$ নোড এবং সবগুলোই সংরক্ষণ করে ($b$ = শাখা-ফ্যাক্টর, $d$ = লক্ষ্যের গভীরতা)।

২ **BFS অন্ধ।** এটি জানে না লক্ষ্য কোথায়, তাই গভীরতা $k+1$-এর আগে $k$-তে **প্রতিটি** নোড বিস্তার করে: সব দিকে ঢেউ।

৩ **A* সূচিত।** এটি সবচেয়ে ছোট $f(n) = g(n) + h(n)$ নোড বিস্তার করে ($g$ = এখনকার খরচ, $h$ = লক্ষ্যে আনুমানিক খরচ)। লক্ষ্যের বিপরীতে নিয়ে যাওয়া নোডের $f$ বড় হয় এবং কখনো বিস্তার হয় না।




একই S ও G, অনেক কম নোড

৪ **ছোট কার্যকর শাখা-ফ্যাক্টর।** ভালো $h$ $b^*$-কে 1-এর কাছাকাছি আনে, তাই কাজ $\approx (b^*)^d$, $b^d$ নয়। 8-puzzle, গভীরতা 12: অন্ধ পুনরাবৃত্তিমূলক গভীরতা ≈ **৩.৬ মিলিয়ন** নোড; A* (ভুলে বসা টাইল) 227; A* (ম্যানহাটন দূরত্ব) 73।

৫ **পথ পারফেক্ট না হওয়ার কারণ।** A* কেবল তখনই অপটিমাল যখন $h$ admissible (কখনো আধিক মানায় না; গ্রাফ সার্চে **consistent**-ও: $h(n) \le c(n, n') + h(n')$)। বাস্তব সিস্টেম আরও শক্তিশালী, non-admissible $h$ ব্যবহার করে — **ওজনযুক্ত A*** ($f = g + w \cdot h$, $w > 1$, খরচ ≤ $w$ × অপটিমাল) বা greedy best-first ($f = h$): অনেক কম বিস্তার, তবে সবচেয়ে সস্তা পথ বাদ পড়তে পারে।

৬ **সিদ্ধান্ত।** গতি আসে **$h$-এর তথ্য থেকে** ($h = 0$ হলে A* হয়ে যায় uniform-cost search, অর্থাৎ সমান ধাপ-খরচে BFS)। নিশ্চিত অপটিমালিটি বদলে নির্দেশকতা দিয়ে একটি অবস্থাপূর্ণ, অফোকাস অনুসন্ধানকে কেন্দ্রিক অনুসন্ধানে রূপ দেয়; মিলিসেকেন্ডে পাওয়া প্রায়-অপটিমাল রুট (GPS, গেম, রোবট) দেরি করে পাওয়া পারফেক্ট রুটের চেয়ে ভালো।

| | BFS | Uniform-cost | Greedy best-first | A* |
|---|---|---|---|---|
| সাজায় | গভীরতা | $g(n)$ | $h(n)$ | $g(n) + h(n)$ |
| সম্পূর্ণ? | হ্যাঁ | হ্যাঁ | না (ট্রি সার্চ) | হ্যাঁ |
| অপটিমাল? | শুধু সমান ধাপ-খরচে | হ্যাঁ | **না** | হ্যাঁ, যদি $h$ admissible |
| মেমরি | $O(b^d)$ | অবস্থাপূর্ণ | অবস্থাপূর্ণ (সর্বোচ্চ) | সব নোড রাখে |

**পরীক্ষার ফাঁদ** "A* সবসময় সবচেয়ে ছোট পথ খোঁজে" কেবল admissible $h$-এর সাথে সত্য। এর সর্বোচ্চ ক্ষেত্রও অবস্থাপূর্ণ এবং আসল সীমা হলো **মেমরি** (তাই IDA*, SMA*)।

**মনে রাখার কৌশল** $g$ = "**গ**তো যা পার হয়েছে", $h$ = "**হ**যদুরুতো বাকি"। Admissible = একজন **আশাবাদী**: লক্ষ্য আসলের চেয়ে দূর বলে কখনো বলে না।

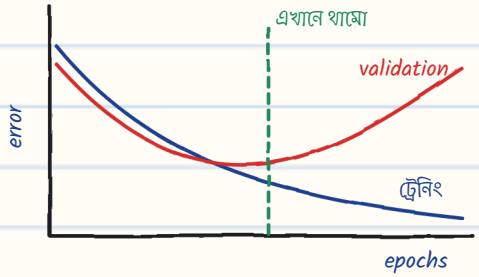
## ৬ ট্রেনিং বেশি, টেস্ট কম BUET লিখিত

**প্রশ্ন** মেশিন লার্নিং মডেলে ট্রেনিং অ্যাকুরেসি বেশি কিন্তু টেস্টিং অ্যাকুরেসি কম হওয়ার কারণ কী, এবং এর প্রতিকারের কৌশলগুলো কী? *BUET MSc in CSE · ০৩.১০.২০২৬*

**উত্তর: overfitting** মডেলটি সাধারণীকৃত প্যাটার্নের বদলে ট্রেনিং সেট মুখস্থ করেছে, নয়েজসহ: কম বায়াস, **বেশি ভ্যারিয়েন্স**; ট্রেন–টেস্টের পার্থক্যই *generalization gap*।

**কারণ**

- মডেল খুব **জটিল** (অনেক প্যারামিটার, গভীর ট্রি)
- **অল্প** তথ্য, বা অতিরিক্ত ফিচার
- **নয়েজি লেবেল** ও আউটলায়ারও ফিট হয়ে যায়
- **অনেক বেশি *epoch*** ট্রেনিং
- টেস্ট তথ্য **ভিন্ন বণ্টন** থেকে




**প্রতিকার:** ① আরও তথ্য / *augmentation* ② সরল মডেল, ফিচার সিলেকশন, ট্রি প্রুনিং ③ রেগুলারাইজেশন: *L2 (loss + λΣw²), L1, dropout* ④ ভ্যালিডেশন লসে ***early stopping*** ⑤ ***k-fold cross-validation*** ⑥ এনসেম্বল *(bagging, random forest)* ⑦ পরিষ্কার লেবেল; ট্রেন ও টেস্টের একই বণ্টন। *Underfitting* এর বিপরীত: ট্রেন **ও** টেস্ট উভয়েই কম অ্যাকুরেসি (বেশি বায়াস)।

## ৭ দুর্বল বনাম শক্তিশালী শিক্ষক (এনসেম্বল) BUET-ধরনের লিখিত

**প্রশ্ন** এনসেম্বল লার্নিং-এ দুর্বল ও শক্তিশালী শিক্ষক ব্যাখ্যা করো। *GTCL সহকারী প্রকৌশলী (CSE) · ২০২২*

**দুর্বল শিক্ষক** কেবল এলোমেলো অনুমানের চেয়ে সামান্য ভালো (বাইনারি ত্রুটি 0.5-এর ঠিক নিচে), যেমন একটি **ডিসিশন স্টাম্প**।

**শক্তিশালী শিক্ষক** যথেষ্ট তথ্যে যত খুশি উচ্চ নির্ভুলতা অর্জন করতে পারে। শাপিরে (১৯৯০): দুর্বল শিক্ষককে ***boost*** করে শক্তিশালী করা যায়।

| | *Bagging* | *Boosting* |
|---|---|---|
| ট্রেনিং | **সমান্তরাল**, প্রতিটি *bootstrap* নমুনায় | **ধারাবাহিক**; ভুল হওয়া সারিতে বেশি ওজন |
| সমন্বয় | সংখ্যাগরিষ্ঠ ভোট / গড় | ওজনযুক্ত ভোট $H(x) = \text{sign}(\Sigma\, \alpha_t h_t(x))$ |
| যা কমায় | **ভ্যারিয়েন্স** | **বায়াস** (ও ভ্যারিয়েন্স) |
| উদাহরণ | *Random Forest* | *AdaBoost, Gradient Boosting, XGBoost* |

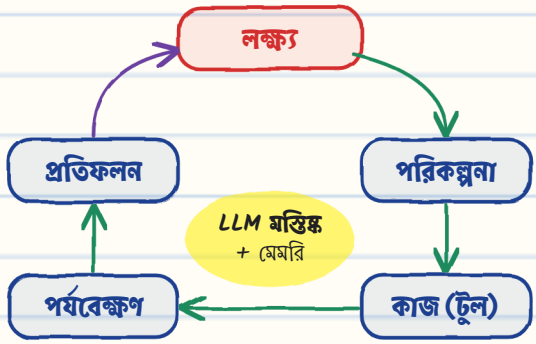
**সমাধানকৃত উদাহরণ** তিনটি স্বাধীন ক্লাসিফায়ার, প্রতিটি 70% নির্ভুল, ভোট দেয়। $P(\text{সংখ্যাগরিষ্ঠ সঠিক}) = 0.7^3 + 3(0.7^2)(0.3) = 0.343 + 0.441 = 0.784 > 0.7$। AdaBoost-এর ওজন $\alpha_t = \tfrac{1}{2}\ln((1-\varepsilon_t)/\varepsilon_t)$ কেবল $\varepsilon_t < 0.5$ থাকা অবস্থায় ধনাত্মক।

# ৮ এজেন্টিক AI বনাম প্রচলিত চ্যাটবট

BUET লিখিত

**প্রশ্ন** Agentive AI কী? প্রচলিত Chatbot AI-এর সাথে তুলনা করো। BUET MSc in CSE · ০৩.১০.২০২৬

**এজেন্টিক (agentive) AI** এমন AI সিস্টেম যাকে শুধু প্রম্পট নয়, একটি লক্ষ্য দেওয়া হয় এবং সে সামান্য মানব তত্ত্বাবধানে তা অনুসরণ করে: এটি ধাপ **পরিকল্পনা** করে, টুলের (API, সার্চ, কোড, ডাটাবেস, ইমেইল) মাধ্যমে **কাজ** করে, ফলাফল **পর্যবেক্ষণ** করে, **মেমরি** রাখে এবং লক্ষ্য পূরণ না হওয়া পর্যন্ত লুপে **নিজেকে সংশোধন** করে। সাধারণত একটি বড় ভাষা মডেলের (LLM) উপর গড়ে ওঠে।



লক্ষ্য পূরণ না হওয়া পর্যন্ত লুপ

**গঠন-উপাদান**

- **রিজনিং**: LLM লক্ষ্যকে উপ-কাজে ভাগ করে
- **পরিকল্পনা**: ব্যর্থ হলে ধাপ সংশোধন (ReAct: reason → act → observe)
- **টুল ব্যবহার**: API, কোড, ডাটাবেসে ফাংশন কল
- **মেমরি**: কনটেক্সট + দীর্ঘমেয়াদি (ভেক্টর স্টোর)
- **গার্ডরেল**: পারমিশন, মানব অনুমোদন, অডিট লগ

প্রচলিত চ্যাটবট একটি প্রতিক্রিয়ামূলক প্রশ্নোত্তর প্রোগ্রাম: নিয়মভিত্তিক (প্যাটার্ন বা ইনটেন্ট মিলিং, যেমন ELIZA, ১৯৬৬) কিংবা কেবল উত্তর দেওয়া একটি LLM।

| বিষয় | প্রচলিত চ্যাটবট | এজেন্টিক AI |
|---|---|---|
| শুরু হয় | প্রতিটি ব্যবহারকারীর বার্তা থেকে | একটি **লক্ষ্য** (বা কোনো ঘটনা) থেকে |
| স্বায়ত্তশাসন | নেই: প্রতিটি ধাপ ব্যবহারকারী চালায় | বেশি: নিজের পরবর্তী ধাপ বাছাই করে |
| পরিকল্পনা | নেই | ভাগ করে ও পুনরায় পরিকল্পনা করে |
| অ্যাকশন | শুধু লেখার উত্তর | টুলের মাধ্যমে অন্য সিস্টেমে **কাজ** করে |
| মেমরি | সর্বোচ্চ বর্তমান কথোপকথন | স্বল্প ও দীর্ঘমেয়াদি |
| মানিয়ে নেয় | নির্দিষ্ট স্ক্রিপ্ট | ফলাফল যাচাই করে, নিজেকে সংশোধন করে |
| ঝুঁকি | ভুল উত্তর | ভুল **কাজ**: তত্ত্বাবধান দরকার |
| ব্যাংকের উদাহরণ | "আমার ব্যালেন্স কত?" বলে উত্তর দেয় | ব্যর্থ ট্রান্সফার খুঁজে, লগ পড়ে, আবার চেষ্টা করে, টিকিট খোলে, গ্রাহককে জানায় |

**মনে রাখার কৌশল** চ্যাটবট **কথা** বলে; এজেন্ট **কাজ** করে। এজেন্টিক AI = লক্ষ্য/উপযোগিতাভিত্তিক একটি **শিখনবিদ এজেন্ট** (পাতা ৪) যার প্রোগ্রাম একটি LLM।

**পরীক্ষার ফাঁদ** এজেন্টিক AI **AGI নয়**, আর শুধু "বড় চ্যাটবট"ও নয়: পার্থক্য হলো **স্বায়ত্তশাসন + টুল + লক্ষ্য-লুপ**।

# ৯ মার্কেট বাস্কেট বিশ্লেষণ: অ্যাপ্রিওরি DPDC লিখিত

**প্রশ্ন** মার্কেট বাস্কেট বিশ্লেষণের জন্য কোন মেশিন লার্নিং অ্যালগরিদম উপযুক্ত? এতে জড়িত ধাপগুলো ব্যাখ্যা করো। DPDC সহকারী ম্যানেজার (ICT) · ২৭.০৬.২০২৫

**উত্তর** অ্যাসোসিয়েশন-রুল মাইনিং **অ্যাপ্রিওরি** অ্যালগরিদমে (Agrawal & Srikant, ১৯৯৪), একটি **অনিষ্কারিত** পদ্ধতি (দ্রুত বিকল্প FP-Growth)। এটি {Diaper} → {Beer}-এর মতো নিয়ম খোঁজে: একসাথে কেনা জিনিস।

**মাপ** $support(X) = count(X) / N$ · $confidence(X \to Y) = support(X \cup Y) / support(X)$ · $lift = confidence / support(Y)$, $> 1$ = আসল সম্পর্ক।
**অ্যাপ্রিওরির ধর্ম:** **ঘন আইটেমসেটের প্রতিটি সাবসেট ঘন**, তাই কোনো ক্যান্ডিডেটে অঘন সাবসেট থাকলে সেটি গোনা ছাড়াই বাদ দেওয়া যায়।

১. ***min_support*** ও ***min_confidence*** ঠিক করো।
২. তথ্য স্ক্যান করে একক আইটেম গোনো ($C_1$), $\geq min_support$ রাখো → $L_1$।
৩. $L_{k-1}$ কে নিজের সাথে ***join*** করে ক্যান্ডিডেট $C_k$; যেগুলোতে অঘন $(k-1)$-সাবসেট আছে তা ***prune*** করো।
৪. স্ক্যান করে $C_k$ গোনো, $\geq min_support$ রাখো → $L_k$; $L_k = \emptyset$ না হওয়া পর্যন্ত ৩–৪ বার পুনরাবৃত্তি।
৫. প্রতিটি ঘন আইটেমসেট থেকে নিয়ম $X \to Y$ বানাও; $confidence \geq min_confidence$ রাখো, $lift$ দেখো।

**সমাধানকৃত উদাহরণ** ✍️ ৫টি বাস্কেট, $min_support = 3$ (60%), $min_confidence = 70\%$।

| T | আইটেম |
|---|---|
| 1 | Bread, Milk |
| 2 | Bread, Diaper, Beer, Eggs |
| 3 | Milk, Diaper, Beer, Cola |
| 4 | Bread, Milk, Diaper, Beer |
| 5 | Bread, Milk, Diaper, Cola |

$C_1$: Bread 4, Milk 4, Diaper 4, Beer 3, Cola 2 ✓, Eggs 1 ✗
$C_2$: {B,M} 3 · {B,D} 3 · {M,D} 3 · {D,Beer} 3 · {B,Beer} 2 ✗ · {M,Beer} 2 ✗
$C_3$: {B,D,Beer}, {M,D,Beer} *pruned* (অঘন সাবসেট); {B,M,D} = 2 ✗ → $L_3 = \emptyset$, থামো

| নিয়ম | Support | Confidence | Lift | রায় |
|---|---|---|---|---|
| Beer → Diaper | 3/5 | 3/3 = 100% | 1.0/0.8 = **1.25** | **শক্তিশালী ✓** |
| Diaper → Beer | 3/5 | 3/4 = 75% | 0.75/0.6 = **1.25** | **শক্তিশালী ✓** |
| Bread → Milk | 3/5 | 3/4 = 75% | 0.75/0.8 = 0.94 | lift < 1: আসল সংযোগ নেই |

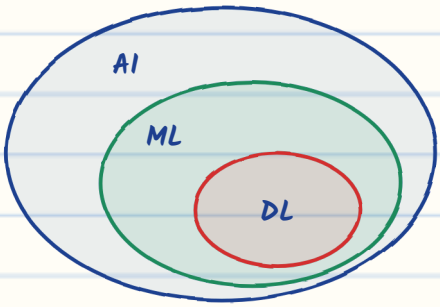
**পরীক্ষার ফাঁদ** শুধু confidence ভোলায়: Bread → Milk-এর confidence 75%, কিন্তু মোট বাস্কেটের 80%-তেই Milk আছে, তাই lift 0.94।

**মনে রাখার কৌশল** **"একটি বিরল সেট, প্রতিটি বড় সেটকেও বিরল করে দেয়"**: এটিই *pruning*। ব্যবহার: শেলফ সাজানো, ক্রস-সেলিং, ব্যাংকের পণ্য বান্ডিল।

***FP-Growth*** বাস্কেটগুলো একটি ***FP-tree***-তে সংকুচিত করে এবং মাত্র ২বার ডাটাবেস স্ক্যানে, কোনো ক্যান্ডিডেট তৈরি না করেই খনন করে, তাই বড় তথ্যে অ্যাপ্রিওরির চেয়ে দ্রুত।

## ১০ ডিপ লার্নিং, ব্যাকপ্রোপাগেশন, RNN

MCQ + ভাইভা




AI ⊃ ML ⊃ ডিপ লার্নিং

**ডিপ লার্নিং** ML-এর সেই অংশ যা অনেক হিডেন লেয়ারের নিউরাল নেট ব্যবহার করে, যা কাঁচা তথ্য থেকে সরাসরি ফিচার শেখে।

| | প্রচলিত ML | ডিপ লার্নিং |
|---|---|---|
| ফিচার | হাতে তৈরি | **স্বয়ংক্রিয়ভাবে শেখা** |
| তথ্য, কমপিউট | অল্প-মাঝারি, CPU | বড় তথ্য, GPU |
| ব্যাখ্যাযোগ্যতা | সহজ | "কালো বাক্স" |

**ব্যাকপ্রোপাগেশন** ① **ফরওয়ার্ড পাস**: আউটপুট ও লস $L$ ② **ব্যাকওয়ার্ড পাস**: চেইন রুল প্রতিটি ওজনের $\partial L/\partial w$ দেয়, আউটপুট লেয়ার থেকে শুরু করে ③ **আপডেট** গ্রেডিয়েন্ট ডিসেন্টে $w \leftarrow w - \eta \cdot \partial L/\partial w$ ($\eta$ = লার্নিং রেট)। এতে MLP, CNN ও RNN (সময়ের মাধ্যমে ব্যাকপ্রোপাগেশন, BPTT) প্রশিক্ষিত হয়।

| নেটওয়ার্ক | কীসের জন্য | মূল ভাবনা |
|---|---|---|
| MLP / ANN | ট্যাবুলার তথ্য | সম্পূর্ণ সংযুক্ত লেয়ার |
| CNN | ছবি (স্থানিক তথ্য) | কনভোলিউশন ফিল্টার, পুলিং, শেয়ার্ড ওজন |
| **RNN / LSTM / GRU** | ধারাবাহিকতা, টাইম সিরিজ, বাকি | হিডেন স্টেট অতীত বহন করে: $h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$ |
| Transformer | ভাষা (LLM) | গোটা ধারার উপর self-attention |

**পরীক্ষার ফাঁদ** সাধারণ RNN দীর্ঘ ধারায় **ভ্যানিশিং গ্রেডিয়েন্ট**-এ ভোগে; LSTM/GRU-র গেট এটি ঠিক করে। গ্রেডিয়েন্ট ডিসেন্ট একটি **অপটিমাইজেশন পদ্ধতি** যা শেখার ভেতরে ব্যবহৃত হয়, নিজে AI-র কৌশল নয়।

## ১১ ন্যাচারাল ল্যাঙ্গুয়েজ প্রসেসিং

২টি MCQ

**পাইপলাইন:** টোকেনাইজেশন → স্টপ-ওয়ার্ড সরানো → স্টেমিং / লেম্মাটাইজেশন → POS ট্যাগিং → পার্সিং → সেমান্টিক্স।

ওয়ার্ড এমবেডিং (Word2Vec, GloVe) শব্দকে ঘন ভেক্টরে ম্যাপ করে যেখানে কাছাকাছি অর্থ কাছাকাছি থাকে: ***king − man + woman ≈ queen***।

**মূল চ্যালেঞ্জ: অস্পষ্টতা**

- শব্দগত: "bank" (নদী না টাকা)
- বাক্যগত: "I saw the man with the telescope"
- নির্দেশক: "Rahim told Karim he passed": কে পাশ করেছে?

**মনে রাখার কৌশল** ক্যামেরার ছবির জন্য **CNN**, পুনরাবৃত্ত ধারার জন্য **RNN**; stemming **কাটে** ("studies" → "studi"), lemmatisation **খোঁজে** ("studies" → "study")।

## ১২ যে MCQ এসেছে: ৪৯তম BCS (ICT-281), ২০২৫ ৯টি প্রশ্ন

| প্রশ্ন (অপশন) | উত্তর | কেন |
|---|---|---|
| AI-র কৌশল নয়? (gradient descent / genetic algorithm / deep learning / reinforcement learning) | **gradient descent** | একটি ক্যালকুলাস অপটিমাইজার; বাকিগুলো AI পদ্ধতি |
| কোন ML মডেলে ব্যাকপ্রোপাগেশন? (MLP / CNN / RNN / সবগুলো) | **সবগুলোই** | RNN BPTT-এর মাধ্যমে |
| টাইম-সিরিজের জন্য সেরা? (CNN / RNN / DNN / ANN) | **RNN** | হিডেন স্টেট অতীত মনে রাখে |
| ___ অ্যালগরিদমে পলিসি লাগে (supervised / fuzzy / deep / reinforcement) | **reinforcement** | পলিসি $\pi$: স্টেট → অ্যাকশন |
| হিল ক্লাইম্বিং-এর মূল দুষ্টি? (memory / local optima / সব বিস্তার / heuristic দরকার) | **local optima** | greedy, কখনো নিচে যায় না |
| র‍্যান্ডম সার্চ হলো ___ (greedy / local opt. / optimal / global optimisation) | **গ্লোবাল অপটিমাইজেশন** | গোটা স্থান থেকে নমুনা নেয় |
| রিগ্রেশন মেট্রিক নয়? ($R^2$ / RMSE / Recall / MAE) | **Recall** | $TP/(TP+FN)$: শ্রেণিবিন্যাস |
| শব্দ → অর্থ ভেক্টর? (tokenisation / embeddings / stemming / POS) | **word embeddings** | Word2Vec, GloVe |
| NLP-এর মূল চ্যালেঞ্জ? (ambiguity / POS / syntax / tokenisation) | **অস্পষ্টতা** | এক বাক্য, অনেক অর্থ |

রিগ্রেশন: $MAE = mean|y - \hat{y}|$ · $RMSE = \sqrt{mean(y-\hat{y})^2}$ · $R^2 = 1 - SS_{res}/SS_{tot}$। শ্রেণিবিন্যাস: accuracy, precision $TP/(TP+FP)$, recall, F1।

## ১৩ ভাইভা দ্রুত-প্রশ্ন (ব্যাংক আইটি ভাইভা) পুনরাবৃত্ত একত্রে

**AI কী?** → মানুষের বুদ্ধিমত্তা লাগে এমন কাজ মেশিন করা: শেখা, যুক্তি, উপলব্ধি, ভাষা, সিদ্ধান্ত। পরিভাষা: জন ম্যাকার্থি, ডার্টমাউথ ১৯৫৬।

**ML কী?** → তথ্য থেকে প্যাটার্ন শিখে ও স্পষ্ট প্রোগ্রামিং ছাড়াই উন্নত হওয়া AI (অনেক বোতল দেখিয়ে একটি নতুন চিনতে শেখে)।

**ডিপ লার্নিং কী?** → অনেক লেয়ারের নিউরাল নেট দিয়ে ML, যেখানে ফিচার নিজেরাই শেখে।

**ML বনাম DL?** → ML: হাতে বানানো ফিচার, কম তথ্য, ব্যাখ্যাযোগ্য। DL: স্বয়ংক্রিয় ফিচার, বড় তথ্য + GPU, কালো বাক্স।

**Normal বনাম super AI?** → Narrow AI একটি কাজ করে (ভয়েস অ্যাসিস্ট্যান্ট, রিকমেন্ডার): আজকের সব AI। AGI মানুষের মতো হবে; super AI সব ক্ষেত্রে মানুষকে ছাপিয়ে যাবে: কল্পনামূলক।

**স্বায়ত্তশাসিত অস্ত্র?** → সামান্য বা কোনো মানব হস্তক্ষেপ ছাড়াই লক্ষ্য শনাক্ত, নির্বাচন ও আক্রমণকারী সামরিক ব্যবস্থা।

**কীভাবে কাজ করে?** → সেন্সর (ক্যামেরা, রাডার, GPS) → AI/ML লক্ষ্য চিনে → সিদ্ধান্তের যুক্তি → অ্যাকচুয়েটর গুলি করে বা পথ ঘোরায়। সমস্যা: দায়বদ্ধতা, অর্থবহ মানব নিয়ন্ত্রণ।

**রোবোটিক্স?** → এমন রোবট ডিজাইন, নির্মাণ ও প্রোগ্রাম করা যারা ন্যূনতম মানব সহায়তায় অনুভব, সিদ্ধান্ত ও কাজ করে।

**ব্যাংকে রোবোটিক্স?** → নগদ সাজানোর মেশিন, ডকুমেন্ট স্ক্যানিং, সার্ভিস রোবট ও চ্যাটবট, এবং নিয়ম-ভিত্তিক ব্যাক-অফিস কাজের জন্য RPA বট (KYC যাচাই, রিকন্সিলিয়েশন, রিপোর্ট)।

**AI-তে কেন Python?** → সহজ সিনট্যাক্স; লাইব্রেরি NumPy, pandas, scikit-learn, TensorFlow, PyTorch, Keras।

# পরীক্ষার আগের রাতের পাতা

## সূত্র ও তথ্য

$A^*$: $f(n) = g(n) + h(n)$

Consistent: $h(n) \le c(n, n') + h(n')$

$G = \Sigma\, \gamma^k\, r_{t+k+1}$

ε-greedy: ε সম্ভাবনায় এলোমেলো

$conf(X \to Y) = sup(X \cup Y)/sup(X)$

AdaBoost $\alpha = \frac{1}{2} \ln((1-\varepsilon)/\varepsilon)$

Admissible: $h(n) \le$ প্রকৃত খরচ

BFS: $O(b^d)$ সময় ও স্থান

$Q \leftarrow Q + \alpha[r + \gamma \max Q' - Q]$

$w \leftarrow w - \eta\, \partial L/\partial w$

$lift = conf/sup(Y)$, $> 1$ ভালো

৩ ভোটার 0.7 → 0.784

## ➜ এক লাইনে

1. *Supervised* = লেবেল; *unsupervised* = নেই; *RL* = পুরস্কার
2. পলিসি → *reinforcement learning*
3. এজেন্ট = সেন্সর + অ্যাকচুয়েটর
4. ৫ এজেন্ট: রিফ্লেক্স, মডেল, লক্ষ্য, উপযোগিতা, শেখা
5. *Rational* ≠ সর্বজ্ঞ; কাজ = *PEAS*
6. $A^*$ অপটিমাল *iff h admissible* (ট্রি)
7. হিল ক্লাইম্বিং → স্থানীয় অভিসার
8. র‍্যান্ডম সার্চ → গ্লোবাল অপটিমাইজেশন
9. ট্রেন বেশি, টেস্ট কম = *overfitting*
10. *Bagging* ↓ ভ্যারিয়েন্স; *boosting* ↓ বায়াস
11. দুর্বল শিক্ষক ≈ এলোমেলোর সামান্য উপরে
12. মার্কেট বাস্কেট → অ্যাপ্রিওরি, *FP-Growth*
13. *Backprop*: *MLP*, *CNN*, *RNN* (*BPTT*)
14. টাইম সিরিজ → *RNN*; ছবি → *CNN*

**সবচেয়ে বড় ফাঁদ** *RL* অনিষ্কারিত শিক্ষা নয় · $A^*$ কেবল *admissible h*-এ অপটিমাল · *greedy best-first* অপটিমাল নয় · *BFS* কেবল সমান ধাপ-খরচে অপটিমাল · *gradient descent* একটি অপটিমাইজার · *lift* ছাড়া *confidence* ভোলায় · এজেন্টিক *AI* ≠ *AGI* · আজকের সব *AI narrow AI*

**সব কৌশল একসাথে** শিক্ষক / শিক্ষক নেই / সমালোচক · প্রতিটি এজেন্টের ধরনে একটি জিনিস যোগ · *g* = গতো যা পার হয়েছে, *h* = হযদুরুতো বাকি · একটি বিরল সেট বড় সেটকেও বিরল করে · চ্যাটবট কথা বলে, এজেন্ট কাজ করে · *CNN* = ক্যামেরা, *RNN* = *recurring*




এজেন্টের সিঁড়ি: প্রতিটি ধাপে একটি যোগ ক্ষমতা

**লিখিতের কৌশল** "পার্থক্য লেখো" → ৬–৮ সারির টেবিল, প্রতিটি কলামে একটি উদাহরণ। "ব্যাখ্যা করো" → সংজ্ঞা, চিত্র, বৈশিষ্ট্য, উদাহরণ। ১০ নম্বরের "যুক্তি দাও" → নম্বরযুক্ত প্রকল্প ও এক লাইনের সিদ্ধান্ত।

## ✓ অনুশীলন MCQ (পরীক্ষায় আসা টপিক থেকে)

আগে নিজে করো, পরে মেলাও

১. লেবেলযুক্ত ইনপুট–আউটপুট জোড় থেকে শেখা কী?
ক) reinforcement খ) unsupervised
গ) supervised ঘ) clustering

২. শুধু বর্তমান অনুভূতি ও if-then নিয়মে কাজ করা এজেন্ট:
ক) সরল রিফ্লেক্স খ) লক্ষ্যভিত্তিক
গ) উপযোগিতাভিত্তিক ঘ) শিখনবিদ

৩. A* (ট্রি সার্চ) কখন অপটিমাল? h(n) যখন:
ক) এলোমেলো খ) প্রকৃত খরচের চেয়ে বড়
গ) ঋণাত্মক ঘ) admissible

৪. ট্রেনিং বেশি কিন্তু টেস্ট অ্যাকুরেসি কম মানে:
ক) underfitting খ) overfitting
গ) high bias ঘ) পরিষ্কার তথ্য

৫. Random Forest কোনের উদাহরণ?
ক) bagging খ) boosting
গ) stacking ঘ) clustering

৬. $sup(\{A, B\}) = 0.4$, $sup(\{A\}) = 0.5$. $conf(A \rightarrow B) =$
ক) 0.2 খ) 0.4
গ) 0.8 ঘ) 0.9

৭. শেয়ার দামের টাইম-সিরিজের জন্য সেরা নেটওয়ার্ক:
ক) CNN খ) decision stump
গ) k-means ঘ) LSTM

৮. ε-greedy-তে ε কীসের সম্ভাবনা?
ক) exploit করা খ) এলোমেলো explore করা
গ) থামা ঘ) ডিসকাউন্ট করা

৯. একটি শ্রেণিবিন্যাস মেট্রিক (রিগ্রেশন নয়):
ক) F1 score খ) MAE
গ) RMSE ঘ) $R^2$

১০. এজেন্টিক AI ও চ্যাটবটের মধ্যে প্রধান পার্থক্য কী?
ক) লেখার উত্তর খ) LLM ব্যবহার
গ) টুলের মাধ্যমে পরিকল্পনা ও কাজ ঘ) অনেক ভাষা

উত্তরমালা → ১-গ · ২-ক · ৩-ঘ · ৪-খ · ৫-ক · ৬-গ · ৭-ঘ · ৮-খ · ৯-ক · ১০-গ

**লিখিত প্রশ্ন** একটি rational এজেন্ট সংজ্ঞায়িত করো। এজেন্টের পাঁচ ধরন বর্ণনা করো এবং বলো স্বয়ংক্রিয় ট্যাক্সি কোন ধরনের হওয়া উচিত ও কেন। ১০ নম্বর

১ Rational এজেন্ট: নিজের অনুভূতি ও জ্ঞান থেকে যে অ্যাকশনের কর্মক্ষমতার মাপ সর্বোচ্চ হবে আশা করে সেটি বাছাই করে; rational ≠ সর্বজ্ঞ। ২

২ পাঁচ ধরন, একেকটি এক লাইনে: সরল রিফ্লেক্স (বর্তমান অনুভূতিতে নিয়ম), মডেল-ভিত্তিক (অভ্যন্তরীণ অবস্থা), লক্ষ্যভিত্তিক (সার্চ/পরিকল্পনা), উপযোগিতাভিত্তিক (প্রত্যাশিত উপযোগিতা সর্বোচ্চ), শিখনবিদ (সমালোচক + লার্নিং এলিমেন্ট)। ৫

৩ ট্যাক্সি = **উপযোগিতাভিত্তিক শিখনবিদ এজেন্ট**: আংশিকভাবে পর্যবেক্ষণযোগ্য, স্টোকাস্টিক রাস্তা মডেল দরকার; এটি গতি, নিরাপত্তা, আরাম, জ্বালানির (উপযোগিতা) আপস করে এবং অভিজ্ঞতায় উন্নত হয়। ২

৪ শেষে তার PEAS লাইনটি লেখো। ১

### → পরীক্ষার আগে যাচাই ✓

- ✓ Supervised / unsupervised / RL-এর টেবিল
- ✓ এজেন্টের চিত্র + ৫ ধরন
- ✓ A* বনাম BFS-এর যুক্তি ধাপে ধাপে
- ✓ lift সহ ৫ বাস্কেটে অ্যাপ্রিওরি

**আরও অনুশীলন:**
① এজেন্টিক AI বনাম চ্যাটবট
② ওভারফিটিং: কারণ, সমাধান
③ Bagging বনাম boosting